Buku Panduan Model Simulasi Rupiah

Forecast dan skenario USD/IDR dengan Bayesian *Model Averaging* (BMA) dan Bayesian VAR dengan variabel eksogen (BVARX)

Versi model v4.3 · Data bulanan Januari 2013 – Oktober 2026 · Horizon 6 bulan
Repositori: Simulasi-Rupiah (Stata 19, do-file 00–10)
November 2026

Daftar Isi

Cara Membaca Buku Ini 5

1. Gambaran Besar 7

1.1 Pertanyaan yang dijawab model 7

1.2 Dua model, dua tugas 7

1.3 Alur dalam satu gambar 7

1.4 Hasil saat ini 9

2. Daftar Lengkap Variabel dan Spesifikasi 11

2.1 Spesifikasi final dalam satu tabel 11

2.2 Semua kolom di database dan statusnya 11

2.3 Bentuk setiap variabel di model 12

2.4 Komponen tambahan: konstanta, musiman, dan *dummy* 13

2.5 Yang pernah diuji tetapi tidak dipakai 14

2.6 Riwayat versi singkat 15

3. Konsep Dasar yang Dipakai 16

3.1 *Forecast* sebagai distribusi: median dan rentang 16

3.2 Persen perubahan lewat logaritma 16

3.3 Stasioneritas dan *unit root* 16

3.4 *In-sample*, *out-of-sample*, dan *overfitting* 17

3.5 *Random walk*: patokan yang sulit dikalahkan 17

3.6 Cara berpikir Bayesian: *prior*, *likelihood*, *posterior* 17

3.7 Simulasi Monte Carlo dan "*draw*" 18

3.8 Dua cara meramal beberapa bulan ke depan 19

4. Data 20

4.1 Variabel dan sumbernya 20

4.2 Logika ekonomi: bagaimana setiap variabel memengaruhi rupiah 21

4.3 Transformasi ke bentuk model 23

4.4 Information set dan jeda rilis 23

4.5 Audit dan uji *unit root* 24

5. Model 1: Bayesian *Model Averaging* (Baseline) 26

5.1 Intuisi: *model averaging* 26

5.2 Persamaan: regresi prediktif langsung 26

5.3 Ruang model: 64 kombinasi 27

5.4 g-*prior* Zellner: seberapa kuat koefisien di-*shrink* 28

5.5 Bobot model: marginal *likelihood* 28
5.6 *Posterior inclusion probability* (PIP) 29
5.7 Dari 64 model ke satu *forecast* 30
5.8 Satu persamaan per horizon, estimasi ulang setiap origin 32
5.9 Mengapa baseline naik bertahap: peran *drift* 32
6. Model 2: BVARX (Efek Skenario) 33
6.1 Intuisi: VAR sebagai sistem persamaan 33
6.2 Spesifikasi lengkap 33
6.3 Masalah utama: terlalu banyak parameter 34
6.4 *Prior* Minnesota 35
6.5 *Posterior*: rumus tertutup 36
6.6 Dari parameter ke jalur *forecast* 37
6.7 *Forecast* bersyarat (Waggoner dan Zha, 1999) 37
6.8 *Bridge*: memakai data yang sudah teramati 39
6.9 Efek DXY dan diagnostik 39
6.10 *Validation* BVARX: memilih spesifikasi 40
7. Skenario dan Penggabungan 42
7.1 Apa itu skenario di model ini 42
7.2 Mengisi asumsi: sheet scenario_inputs 43
7.3 Bagaimana skenario merambat ke kurs 45
7.4 Rumus penggabungan 45
7.5 Hasil skenario 46
8. Evaluasi: Seberapa Bisa Dipercaya 48
8.1 Desain: *validation* dan test 48
8.2 Ukuran akurasi 48
8.3 Uji statistik: apakah keunggulan itu kebetulan? 49
8.4 Hasil: baseline BMA 49
8.5 Hasil: BVARX dan perbandingan 51
9. Hasil Lengkap 52
9.1 *Forecast* per skenario, lengkap 52
9.2 Asumsi skenario yang benar-benar dipakai 54
9.3 Hasil mentah BVARX sebelum digabung 55
9.4 Hasil BMA lengkap 56
9.5 *Forecast* akhir semua model 57
9.6 Akurasi lengkap 58

9.7 Diagnostik lengkap 60
9.8 Kesimpulan dari semua hasil 61
10. Menjalankan Model 62
10.1 Struktur folder 62
10.2 Siklus bulanan 63
10.3 Output utama dan cara membacanya 64
10.4 Daftar periksa setelah run 65
10.5 Setting di 00_master.do 65
10.6 Masalah yang sering terjadi 66
11. Keterbatasan dan Pengembangan 67
11.1 Keterbatasan 67
11.2 Arah pengembangan 67
Lampiran A. Glosarium 68
Lampiran B. Referensi 70
Peta referensi: teori atau pilihan model dan dasarnya 73
Lampiran C. Sumber Data 76

Cara Membaca Buku Ini

Buku ini menjelaskan model Simulasi Rupiah dari nol. Isinya mencakup data apa yang dipakai, cara kerja dua model di dalamnya, cara keduanya digabung menjadi skenario, seberapa akurat hasilnya, dan cara menjalankannya setiap bulan. Tujuannya sederhana: setiap angka yang keluar dari model harus bisa dijelaskan asal-usulnya.

Pembaca cukup memahami ekonometrika dasar, misalnya regresi OLS, koefisien, dan uji signifikansi. Istilah lain, termasuk istilah Bayesian seperti *prior* dan *posterior*, dijelaskan pelan-pelan di Bab 3 dengan contoh angka. Semua istilah juga dikumpulkan di Lampiran A.

Peta buku

Bab	Isi	Untuk siapa
1. Gambaran besar	Model ini menjawab apa, dan bagaimana alurnya dalam satu gambar	Semua pembaca
2. Daftar lengkap variabel dan spesifikasi	Semua variabel, mana yang dipakai di model mana, memakai *dummy* atau tidak, dan apa saja yang pernah diuji lalu dibuang	Semua pembaca; rujukan cepat
3. Konsep dasar	Log, stasioneritas, *random walk*, serta *prior*, *likelihood*, *posterior*, dan simulasi, lengkap dengan contoh angka	Yang ingin memahami cara kerja model
4. Data dan logika ekonomi	Sumber data, hubungan antarvariabel, aturan data yang boleh dipakai	Semua pembaca
5. Model 1: BMA	Model untuk baseline	Teknis
6. Model 2: BVARX	Model untuk efek skenario	Teknis
7. Skenario dan penggabungan	Cara menyusun skenario, cara mengisi sheet input, rumus penggabungan	Semua pembaca
8. Evaluasi	Cara akurasi diuji	Semua pembaca
9. Hasil lengkap	Semua tabel hasil beserta cara membaca dan artinya	Semua pembaca
10. Menjalankan model	Langkah rutin bulanan, daftar output, pemecahan masalah	Operator model
11. Keterbatasan	Hal yang perlu disebutkan saat hasil dipakai	Semua pembaca

Tabel 0.1 Peta buku.

Konvensi yang dipakai di seluruh buku

Simbol / istilah	Arti
USD/IDR, S_t	Kurs rupiah per dolar AS pada akhir bulan *t*. **USD/IDR naik = rupiah melemah (depresiasi).**
t	Bulan. Data bulanan, satu observasi per bulan.
h	Horizon: berapa bulan ke depan yang diramal (1 sampai 6).

Simbol / istilah	Arti
Origin	Bulan saat *forecast* dibuat, yaitu bulan terakhir data kurs yang diketahui.
Anchor	Origin untuk *forecast* resmi saat ini: Oktober 2026, dengan USD/IDR = 18.127.
Δx_t	Perubahan dari bulan lalu: $x_t - x_{t-1}$.
$100 \times \Delta \ln x_t$	Perubahan logaritma dikali 100. Angkanya kira-kira sama dengan persen perubahan bulanan.
TB	*Trade balance* (neraca perdagangan barang), USD miliar per bulan.
Flows	*Net flows* asing: pembelian bersih saham, SBN, dan SRBI oleh investor asing, Rp triliun per bulan.
DXY	Indeks dolar AS terhadap enam mata uang utama dunia.
UST10Y	Imbal hasil (yield) obligasi pemerintah AS tenor 10 tahun, dalam persen.
RW	*Random walk* tanpa *drift*: *forecast* kurs ke depan sama dengan kurs hari ini.

Tabel 0.2 Notasi dan istilah dasar.

Angka di buku ini berasal dari run model 2 November 2026 (v4.3, data sampai Oktober 2026) dengan *anchor* Oktober 2026. Angka akan berubah setiap kali data atau asumsi skenario diperbarui, tetapi cara membacanya tetap sama.

1. Gambaran Besar

1.1 Pertanyaan yang dijawab model

Model ini dibuat untuk menjawab dua pertanyaan:

1. ***Forecast* (baseline).** Dengan data yang ada hari ini, berapa kemungkinan besar USD/IDR dalam 1 sampai 6 bulan ke depan, dan seberapa lebar ketidakpastiannya?
2. **Skenario (*what-if*).** Jika dolar global menguat, neraca perdagangan memburuk, dan modal asing keluar dengan besaran tertentu, sejauh mana rupiah bergeser dari baseline?

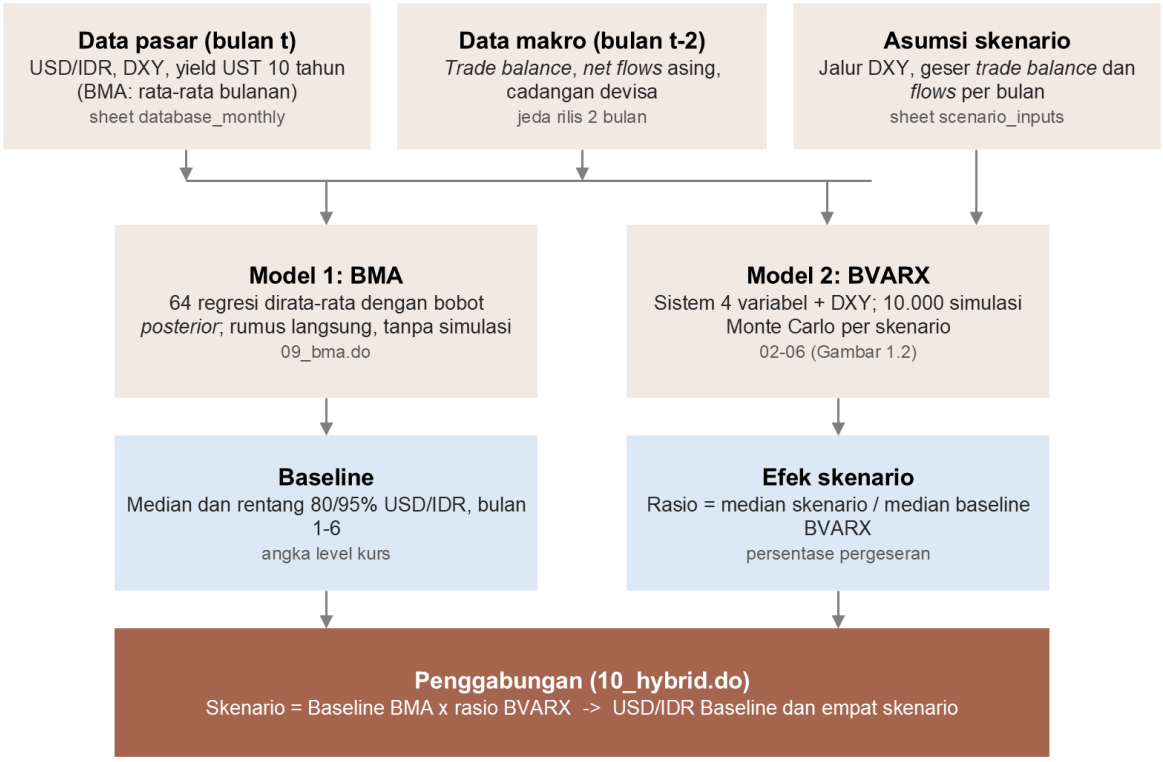
Dua pertanyaan ini butuh hal yang berbeda. Pertanyaan pertama butuh **akurasi**: angka yang sedekat mungkin dengan kenyataan nanti. Pertanyaan kedua butuh **struktur**: model harus "tahu" bagaimana dolar global, arus modal, dan neraca perdagangan memengaruhi rupiah, supaya bisa diberi asumsi ke depan. Dalam pengujian, tidak ada satu model yang unggul di kedua hal sekaligus. Ini sejalan dengan temuan bahwa kemampuan meramal kurs sangat bergantung pada model, horizon, dan periode (Rossi, 2013). Karena itu model ini memakai dua model dengan tugas masing-masing.

1.2 Dua model, dua tugas

	BMA (Bayesian *Model Averaging*)	BVARX (Bayesian VAR dengan variabel eksogen)
Tugas	Menghasilkan **baseline**: angka *forecast* dan rentangnya	Menghasilkan **efek skenario**: berapa persen tiap skenario bergeser dari baseline
Cara kerja singkat	Membuat 64 regresi dengan kombinasi indikator berbeda, lalu merata-ratakan hasilnya	Memodelkan kurs, *trade balance*, *flows*, dan cadangan devisa sebagai satu sistem yang saling memengaruhi
Butuh asumsi ke depan?	Tidak. Cukup data yang sudah ada.	Bisa diberi asumsi jalur DXY, *trade balance*, dan *flows*
Kelebihan	Paling akurat dalam pengujian; rentangnya pas	Hubungan DXY dan arus modal ke rupiah masuk akal dan signifikan
Kelemahan	Tidak bisa membuat skenario	Akurasi *forecast*-nya hanya setara *random walk*

Tabel 1.1 Pembagian tugas BMA dan BVARX.

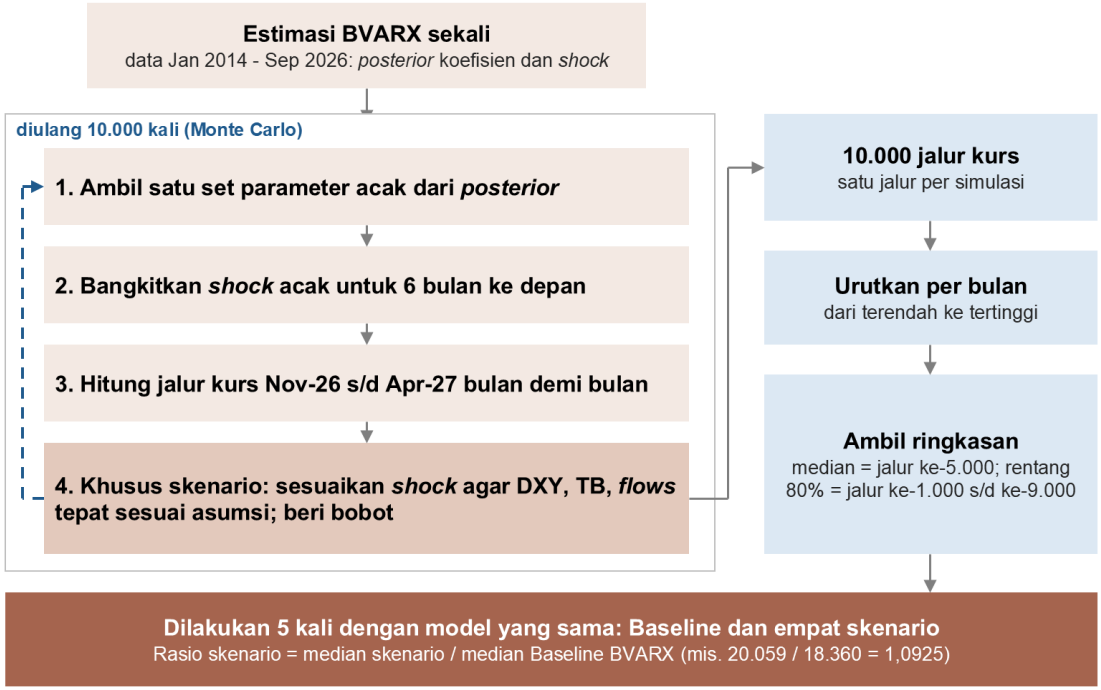
1.3 Alur dalam satu gambar



Gambar 1.1 Alur model dari data sampai hasil. Data pasar dan makro masuk ke kedua model; asumsi skenario hanya masuk ke BVARX. BMA memberi angka baseline, BVARX memberi rasio pergeseran, lalu keduanya dikalikan.

Langkah-langkahnya:

1. **Data.** Kurs, DXY, dan yield UST bulan *t* sudah diketahui di akhir bulan *t*. Data makro (*trade balance*, *flows*, cadangan devisa) dianggap baru tersedia dua bulan kemudian.
2. **BMA** meramal perubahan kurs 1 sampai 6 bulan ke depan. Hasilnya adalah **baseline**: angka tengah (median) dan rentang 80% serta 95%. BMA tidak memakai simulasi; rata-rata dan simpangan baku ramalannya dihitung langsung dengan rumus.
3. **BVARX** diestimasi sekali, lalu masa depannya disimulasikan dengan **Monte Carlo**: 10.000 kemungkinan jalur kurs, dengan parameter dan *shock* acak yang berbeda di setiap jalur (Gambar 1.2). Simulasi ini dilakukan lima kali dengan model yang sama: sekali tanpa asumsi khusus (baseline BVARX) dan sekali untuk setiap skenario, dengan jalur DXY, *trade balance*, dan *flows* diatur sesuai asumsi. Dari setiap run diambil mediannya, lalu dihitung **rasio**: median skenario dibagi median baseline BVARX.
4. **Penggabungan.** Skenario = baseline BMA × rasio dari BVARX, untuk setiap bulan.



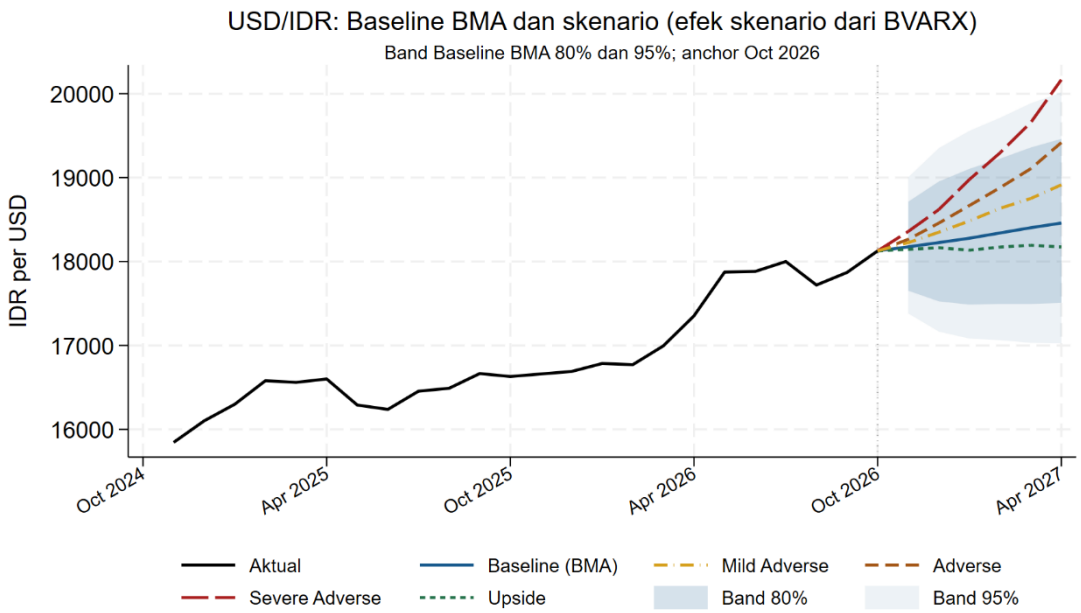
BMA tidak memakai simulasi: mean dan simpangan baku *forecast* dihitung langsung dengan rumus (bmapredict).

Gambar 1.2 Simulasi Monte Carlo di BVARX. Langkah 1–4 diulang 10.000 kali untuk setiap run; langkah 4 hanya untuk skenario. Median dan rentang diambil dari 10.000 jalur yang diurutkan, lalu rasio skenario dihitung dari median.

1.4 Hasil saat ini

Skenario	USD/IDR Apr 2027 (median)	Rentang 80%	vs Okt 2026
Baseline (BMA)	18.459	17.508 – 19.461	+1,8%
Upside	18.174	17.238 – 19.161	+0,3%
Mild Adverse	18.914	17.939 – 19.941	+4,3%
Adverse	19.417	18.417 – 20.472	+7,1%
Severe Adverse	20.166	19.128 – 21.262	+11,3%

Tabel 1.2 Hasil per skenario untuk April 2027 (*anchor* Oktober 2026 = 18.127). Mild Adverse, Adverse, dan Severe Adverse memakai *outflow* asing Rp49,58, Rp139,48, dan Rp247,53 triliun selama November 2026 – April 2027, berdasarkan estimasi dampak usulan reklasifikasi MSCI (Bab 7). Hasil lengkap per bulan ada di Bab 9.



Gambar 1.3 *Fan chart*: riwayat 24 bulan, baseline BMA dengan rentang 80% dan 95%, dan median tiap skenario.

Cara membaca: angka 18.459 adalah titik tengah dari semua kemungkinan kurs April 2027 menurut model: peluang kurs di atasnya sama dengan peluang di bawahnya. Rentang 80% (17.508–19.461) artinya model memperkirakan kurs akan jatuh di rentang itu sekitar 8 dari 10 kali. Dalam pengujian historis (Bab 8), rentang 80% BMA memang memuat kurs sebenarnya 81–93% dari waktu, jadi rentangnya tidak terlalu sempit dan tidak terlalu lebar.

2. Daftar Lengkap Variabel dan Spesifikasi

Bab ini adalah rujukan cepat: semua yang masuk ke model, dalam bentuk apa, dan apa saja yang *tidak* masuk beserta alasannya. Penjelasan lebih dalam tentang logika ekonomi tiap variabel ada di Bab 4.

2.1 Spesifikasi final dalam satu tabel

Komponen	BMA (baseline)	BVARX (efek skenario)
Yang diramal	Persen perubahan USD/IDR dari bulan origin ke *h* bulan ke depan, satu persamaan untuk tiap *h* = 1, …, 6	Empat variabel sekaligus: perubahan USD/IDR, *trade balance*, *net flows*, perubahan cadangan devisa
Sampel estimasi	Januari 2014 sampai data terakhir yang targetnya sudah diketahui	Januari 2014 – September 2026 (153 bulan)
Variabel penjelas	6 kandidat: perubahan rata-rata bulanan USD/IDR, DXY, UST10Y (bulan *t*, dari data harian); *net flows*, *trade balance*, perubahan cadangan (bulan *t*−2)	Nilai 1 dan 2 bulan lalu dari keempat variabel (*lag* 2), ditambah perubahan DXY bulan yang sama
Konstanta	**Ya**, di semua model, tidak di-*shrink* (mewakili tren depresiasi rata-rata)	**Ya**, di setiap persamaan, *prior* sangat longgar
Musiman	Tidak	**Ya**: sin dan cos periode 12 bulan dan 6 bulan (4 variabel)
Dummy outlier	Tidak	**Ya**: Okt 2015, Nov 2018, Mar 2020, Apr 2020 (nilai 1 hanya di bulan itu)
Dummy lain (rating, Lebaran)	Tidak	Tidak
Cara menyusutkan koefisien	*g-prior* Zellner, *g* = 0,25 (koefisien = 20% dari OLS) (Zellner, 1986; Fernández, Ley, & Steel, 2001)	*Prior* Minnesota, λ = 0,03 (sangat ketat); *lag trade balance* berpusat di 0,7 (Litterman, 1986; Kadiyala & Karlsson, 1997)
Jumlah model / simulasi	64 model (semua kombinasi 6 prediktor) (Raftery, Madigan, & Hoeting, 1997)	10.000 simulasi untuk *forecast* akhir dan skenario
Dipilih lewat	Uji *validation*: *g* = 0,25 dari pilihan 0,25 / 1 / 4 / *n*	Uji *validation*: 48 kombinasi awal sampel, *lag*, λ, *prior* UIP
Output yang dipakai	Median dan rentang 80%/95% (baseline)	Rasio median skenario ÷ median baseline BVARX

Tabel 2.1 Spesifikasi final kedua model (S0_settings, 00_master.do).

2.2 Semua kolom di database dan statusnya

File `input/Database_Rupiah_Bulanan.xlsx`, sheet `database_monthly`, berisi 25 kolom. Tidak semuanya dipakai model. Tabel berikut menunjukkan status setiap kolom.

Kolom	Isi	BMA	BVARX	Catatan
year, month, mdate	Penanda waktu	Dipakai sebagai indeks bulan		
usdidr	Kurs USD/IDR akhir bulan	**Ya**	**Ya**	Target kedua model
trade_bal_usdbn	*Trade balance*, USD miliar	**Ya (t–2)**	**Ya**	Bisa dikunci di skenario
net_flows_idrtn	*Net flows* asing, Rp triliun	**Ya (t–2)**	**Ya**	Bisa dikunci di skenario
fx_reserves_usdbn	Cadangan devisa, USD miliar	**Ya (t–2)**	**Ya**	
dxy	Indeks dolar AS (akhir bulan)	**Tidak (pakai dxy_avg)**	**Ya (eksogen)**	Jalurnya diisi di skenario
ust10y_pct	Yield UST 10 tahun (akhir bulan)	**Tidak (pakai ust10y_avg)**	**Tidak**	Diuji di BVARX, tidak terpilih
usdidr_avg, dxy_avg, ust10y_avg	Rata-rata bulanan USD/IDR, DXY, UST10Y dari data harian Bloomberg	**Ya (prediktor ds, ddxy, dust)**	**Tidak**	Sejak v4.2; perlu diperbarui setiap bulan
vix	Indeks volatilitas pasar saham AS	**Tidak**	**Tidak**	Diuji di BVARX, tidak terpilih bersama *dummy*
bi_rate_pct, ff_lower_pct, ff_upper_pct, ff_mid_pct, bi_ff_diff_pp	BI rate, Fed funds, dan selisihnya	**Tidak**	**Tidak**	Selisih BI–Fed diuji dua cara di BVARX, tidak terpilih
rating_up, rating_down, outlook_up, outlook_down	Kejadian perubahan rating dan outlook	**Tidak**	**Tidak**	Hanya diimpor untuk dokumentasi (A0_rating_events); kejadiannya terlalu jarang
exports_usdbn, imports_usdbn	Ekspor dan impor	**Tidak langsung**	**Tidak langsung**	Dipakai lewat selisihnya (*trade balance*)
bi_framework7d, srbi_exists	Penanda rezim instrumen BI	**Tidak**	**Tidak**	Hanya informasi
baseline_sample, core_complete	Penanda kelengkapan data	Dipakai untuk menentukan bulan lengkap terakhir		core_complete diperiksa konsistensinya

Tabel 2.2 Status setiap kolom database. Sheet flow_components (saham, SBN, SRBI) dipakai untuk memeriksa bahwa *net flows* = jumlah ketiganya.

2.3 Bentuk setiap variabel di model

Variabel	Di BMA	Di BVARX	Mengapa bentuk ini
USD/IDR	Target: persen perubahan dari *t* ke *t+h*. Prediktor `ds`: persen perubahan rata-rata bulanan, bulan *t*	Persen perubahan bulanan (endogen)	Level kurs tidak punya rata-rata tetap; perubahannya punya
Trade balance	`tb2`: nilai bulan *t*−2	Nilai apa adanya (endogen)	Sudah berupa arus bulanan yang stabil
Net flows	`flow2`: nilai bulan *t*−2, dibagi 10	Nilai dibagi 10 (endogen)	Arus bulanan; dibagi 10 agar skalanya mirip variabel lain
Cadangan devisa	`dres2`: persen perubahan bulan *t*−2	Persen perubahan bulanan (endogen)	Level tidak punya rata-rata tetap
DXY	`ddxy`: persen perubahan rata-rata bulanan, bulan *t*	Persen perubahan bulanan (eksogen)	Level tidak punya rata-rata tetap
UST10Y	`dust`: perubahan rata-rata bulanan, bulan *t* (poin persen)	Tidak dipakai	Perubahan yield lebih stabil dari levelnya

Tabel 2.3 Bentuk tiap variabel. "Persen perubahan" di sini dihitung sebagai 100 × perubahan logaritma (Bab 3.2).

Endogen dan eksogen. Di BVARX, variabel *endogen* adalah variabel yang dijelaskan oleh model dan saling memengaruhi: kurs, *trade balance*, *flows*, dan cadangan. Variabel *eksogen* memengaruhi sistem tetapi tidak dijelaskan model; nilainya ke depan harus diberikan dari luar. DXY dibuat eksogen karena ekonomi Indonesia tidak cukup besar untuk menggerakkan dolar global. Pembedaan variabel endogen dan eksogen dalam VAR mengikuti Lütkepohl (2005). Inilah yang membuat skenario DXY bisa dimasukkan langsung.

Jeda dua bulan (t−2). Di BMA, data makro diambil dari dua bulan sebelum origin karena data itu baru dirilis beberapa minggu setelah bulannya berakhir. Penjelasan lengkapnya di Bab 4.4.

2.4 Komponen tambahan: konstanta, musiman, dan *dummy*

Komponen	Dipakai?	Penjelasan
Konstanta (*drift*)	**Ya, kedua model**	Menangkap rata-rata perubahan kurs. Di BMA, konstanta inilah yang membuat baseline naik sekitar 0,3% per bulan, mencerminkan tren depresiasi rupiah sejak 2014.
Musiman sin/cos	**Ya, hanya BVARX**	Empat variabel (sin dan cos dengan periode 12 dan 6 bulan) untuk pola musiman yang halus, terutama *trade balance* (Hyndman & Athanasopoulos, 2021). Tidak dipakai di BMA karena *forecast* BMA langsung ke depan dan pola musiman kurs lemah.
Dummy outlier	**Ya, hanya BVARX**	Empat bulan dengan perubahan kurs di atas 2,5 kali simpangan baku: Oktober 2015, November 2018, Maret 2020, April 2020. *Dummy* bernilai 1 hanya di bulan itu. Tujuannya agar satu-dua bulan *outlier* tidak mendistorsi koefisien (Hendry, Johansen, & Santos, 2008; Lenza & Primiceri, 2022). Di *forecast*, *dummy* bernilai 0. Dipilih lewat uji *validation*.
Dummy rating dan outlook	**Tidak**	Hanya 12 kejadian dalam 13 tahun dan efeknya ke kurs tidak bisa diestimasi dengan andal.

Komponen	Dipakai?	Penjelasan
Dummy Lebaran / Idul Fitri	**Tidak (pernah diuji)**	Diuji di versi 3.2 untuk memperbaiki pola *trade balance*, tetapi tidak memperbaiki residual dan menurunkan akurasi, sehingga dibatalkan.
Lag	BMA: tidak ada *lag* kurs selain `ds`; BVARX: 2 bulan	*Lag* 2 di BVARX dipilih di *validation* dari pilihan 1 atau 2.

Tabel 2.4 Konstanta, musiman, *dummy*, dan *lag*.

2.5 Yang pernah diuji tetapi tidak dipakai

Model ini dikembangkan bertahap. Banyak pilihan diuji lalu dibuang karena tidak memperbaiki akurasi. Daftar ini penting agar pembaca tahu bahwa variabel yang "hilang" bukan terlupa, melainkan sudah diuji.

Yang diuji	Versi	Hasil	Keputusan
BVARX dalam level (bukan perubahan)	v1–v2	*Forecast* tertarik ke rata-rata historis (Mar 2027 = 16.798, apresiasi 6%); test kalah jauh dari *random walk* (1,29 / 1,37 / 1,66)	Diganti model perubahan; arsip `archive/v2_levels`
Dummy sum-of-coefficients (untuk model level) (Doan, Litterman, & Sims, 1984; Sims & Zha, 1998)	v2	Tidak terpilih di *validation*	Dibuang bersama model level
Yield UST10Y di BVARX	v3.3	Tidak terpilih di *validation*	Tidak dipakai di BVARX (tetap dipakai di BMA)
Selisih BI rate − Fed funds sebagai eksogen	v3.3–v3.4	Tidak terpilih	Tidak dipakai
VIX sebagai eksogen (Forbes & Warnock, 2012; Rey, 2013)	v3.4–v3.5	Terpilih tanpa *dummy*, tetapi tidak terpilih setelah *dummy outlier* tersedia	Tidak dipakai
Prior UIP (selisih bunga dengan koefisien berpusat di 1/12) (Engel, 2014)	v3.6	Tidak terpilih	Tidak dipakai
Dummy Lebaran	v3.2	Tidak memperbaiki residual *trade balance*; akurasi turun	Dibatalkan
VAR biasa tanpa *prior* (Sims, 1980)	v3.4 (di luar repo)	*Lag* 1 setara BVARX; *lag* 2 overfit (1,11 / 1,16 / 1,07 di *validation*)	Tidak dipakai

Yang diuji	Versi	Hasil	Keputusan
Random walk + drift selisih BI–Fed, dan kombinasinya dengan BVARX (Bates & Granger, 1969)	v3.3–v3.6	Lebih baik dari BVARX, tetapi kalah dari BMA (rata-rata 0,965 dan 0,962 vs BMA 0,950; v4.2: 0,944; v4.3: 0,939)	Hanya pembanding di tabel (T6, T12)
BVARX sebagai baseline	v3–v3.6	Test 1,05 / 1,04 / 0,98; rentang terlalu sempit	Diganti BMA; arsip `archive/v3_5_bvarx`
g = 1, 4, n di BMA	BMA	Skor *validation* 0,973 / 0,992 / 0,987 vs 0,968 untuk g = 0,25	g = 0,25
Prediktor pasar BMA dari rata-rata bulanan data harian	v4.2	0,944 vs 0,950; lebih baik di 6 dari 6 kombinasi periode × horizon	**Dipakai**
BMA dengan prediktor disamakan dengan BVARX (tanpa UST; *lag* kedua)	v4.1 (scratchpad)	0,954 dan 0,955 vs 0,950	Tidak dipakai
Uji ulang BVARX + selisih BI–Fed, VIX, UST (level dan perubahan)	v4.1 (scratchpad)	Skor *validation* 0,949–1,092 vs 0,927; efek VIX ke kurs signifikan (+0,13% per 10%), selisih bunga tidak	Tidak dipakai
ARIMA(p,1,q), p, q ≤ 2, sebagai baseline	v4.2 (scratchpad)	Terpilih ARIMA(1,1,1): *validation* 0,87 tetapi test 1,03 / 1,01 / 1,06; koefisien MA = −1; *forecast* Mar 2027 17.321	Tidak dipakai

Tabel 2.5 Riwayat pengujian. Angka relative RMSE untuk h = 1 / 3 / 6 bulan; di bawah 1 berarti lebih akurat dari *random walk*. Detail di CHANGELOG.md.

2.6 Riwayat versi singkat

Versi	Perubahan utama
v1	Port Stata dari manual R: BVARX dalam level
v2	*Forecast* akhir pindah ke model perubahan karena model level menarik kurs ke rata-rata
v3 – v3.6	Semua tahap memakai BVARX perubahan; *prior trade balance*; grid λ diperluas; uji UST, selisih bunga, VIX, *dummy*, UIP
v4	Baseline diganti BMA; BVARX hanya untuk efek skenario; penggabungan di 10_hybrid.do
v4.1	Asumsi skenario dipindah ke sheet Excel `scenario_inputs`; v4.1.1: perbaikan impor sheet dan tabel bantu angka asli
v4.2	Prediktor pasar BMA (kurs, DXY, UST) memakai rata-rata bulanan dari data harian
v4.3	Data sampai Oktober 2026 (*anchor* Oktober); Adverse dan Severe Adverse memakai *outflow* asing absolut setiap bulan (estimasi dampak MSCI); skenario kelima Mild Adverse; 10.000 *draw* untuk skenario

Tabel 2.6 Riwayat versi.

3. Konsep Dasar yang Dipakai

Bab ini menjelaskan konsep yang dipakai berkali-kali di bab berikutnya, satu per satu, dengan contoh. Setiap konsep dijelaskan dengan pola yang sama: apa itu, mengapa perlu, dan bagaimana dipakai di model ini.

3.1 *Forecast* sebagai distribusi: median dan rentang

Apa itu. Tidak ada yang tahu pasti kurs bulan April 2027. Yang bisa dilakukan model adalah memberi **distribusi**: daftar kemungkinan nilai kurs beserta seberapa besar peluangnya. Bayangkan 10.000 kemungkinan masa depan yang berbeda; distribusi adalah kumpulan semua kemungkinan itu. Pendekatan ini disebut *probabilistic forecasting* (Gneiting & Katzfuss, 2014).

Ringkasan yang dilaporkan.

- **Median**: nilai tengah. Separuh kemungkinan berada di atasnya, separuh di bawahnya. Inilah angka "*forecast*" yang biasa dikutip.
- **Rentang 80%**: dari persentil ke-10 sampai ke-90. Dari 10 kemungkinan, 8 berada di dalam rentang ini.
- **Rentang 95%**: dari persentil ke-2,5 sampai ke-97,5.

Mengapa penting. Angka tengah saja bisa menyesatkan. *Forecast* 18.459 dengan rentang 17.508–19.461 memberi pesan yang berbeda dari 18.459 dengan rentang 18.350–18.550. Rentang menunjukkan seberapa yakin model. Rentang makin lebar untuk bulan yang makin jauh karena makin banyak hal tak terduga bisa terjadi.

3.2 Persen perubahan lewat logaritma

Apa itu. Model tidak bekerja dengan level kurs seperti 18.127, tetapi dengan perubahannya:

$$\Delta s_t = 100 \times [\ln S_t - \ln S_{t-1}]$$

Angka ini hampir sama dengan persen perubahan. Contoh: kurs naik dari 17.000 ke 17.170. Persen perubahannya 1,00%; perubahan lognya 100 × ln(17.170/17.000) = 0,995. Hampir sama.

Mengapa dipakai.

1. **Membandingkan secara adil.** Kenaikan Rp170 saat kurs 17.000 sama besarnya (1%) dengan kenaikan Rp97 saat kurs 9.700. Hubungan ekonomi lebih stabil dalam persen.
2. **Mudah dijumlahkan.** Perubahan log enam bulan sama dengan jumlah perubahan log enam bulan berturut-turut.
3. **Lebih stabil secara statistik** (lihat 3.3).

Kembali ke level. $S_{t+h} = S_t \times \exp(\text{perubahan}/100)$. Contoh: *anchor* 18.127 dan *forecast* perubahan enam bulan 1,81 menghasilkan 18.127 × exp(0,0181) = 18.459.

3.3 Stasioneritas dan *unit root*

Apa itu. Seri **stasioner** adalah seri yang selalu kembali ke rata-ratanya: kalau sedang tinggi, cenderung turun; kalau rendah, cenderung naik. Contohnya *trade balance* bulanan, yang naik turun di sekitar rata-rata tertentu. Seri dengan ***unit root*** tidak punya rata-rata yang dituju. Setiap *shock* menggeser posisinya secara permanen. Level kurs rupiah adalah contoh klasik: tidak ada "kurs normal" yang selalu dituju.

Mengapa penting. Jika model diberi seri ber-*unit root*, model cenderung "mengira" seri itu punya rata-rata dan menarik *forecast* ke rata-rata sampel. Inilah yang terjadi pada versi awal model ini: *forecast* kurs Maret 2027 turun ke 16.798 hanya karena model menarik kurs ke rata-rata 2013–2026, bukan karena alasan ekonomi. Masalah hubungan palsu pada seri ber-*unit root* sudah dikenal sejak Granger dan Newbold (1974).

Cara menguji. Uji Augmented Dickey-Fuller (ADF; Dickey & Fuller, 1979; Said & Dickey, 1984) dan Phillips-Perron (PP; Phillips & Perron, 1988). Keduanya menguji hipotesis nol "seri ini punya *unit root*". Nilai p di bawah 0,05 berarti hipotesis itu ditolak, sehingga seri dianggap stasioner. Hasilnya: level kurs, cadangan, dan DXY diperlakukan dalam bentuk perubahan; *trade balance* dan *flows* dipakai apa adanya (Bab 4.5).

3.4 *In-sample*, *out-of-sample*, dan *overfitting*

Apa itu. Model selalu terlihat bagus pada data yang dipakai untuk membuatnya (***in-sample***), seperti murid yang mengerjakan soal latihan yang jawabannya sudah pernah ia lihat. Ujian sebenarnya adalah meramal data yang belum pernah dilihat (***out-of-sample***) (Hastie, Tibshirani, & Friedman, 2009).

Overfitting terjadi saat model terlalu menyesuaikan diri dengan kebetulan-kebetulan di data lama. Pada kurs risikonya besar, karena bagian kurs yang bisa diramal sangat kecil dibanding bagian yang acak.

Di model ini. Semua penilaian dilakukan *out-of-sample*: model dibuat hanya dengan data sampai suatu bulan, lalu ramalannya dibandingkan dengan kenyataan setelah bulan itu. Ini diulang untuk puluhan bulan (Bab 8; West, 1996).

3.5 *Random walk*: patokan yang sulit dikalahkan

Apa itu. *Random walk* mengatakan: kurs bulan depan sama dengan kurs hari ini, ditambah *shock* yang tidak bisa diramal. Ramalannya selalu datar di angka terakhir.

Mengapa jadi patokan. Meese dan Rogoff (1983) menemukan bahwa model kurs berbasis teori ekonomi umumnya tidak lebih akurat daripada ramalan sesederhana ini. Temuan itu masih bertahan sampai sekarang (Rossi, 2013). Jadi model kurs dianggap berguna jika bisa mengalahkan *random walk*, walaupun hanya sedikit.

Ukuran yang dipakai:

$$\text{relative RMSE} = \text{kesalahan rata-rata model} \div \text{kesalahan rata-rata } \textit{random walk}$$

Angka 0,86 berarti kesalahan model 14% lebih kecil daripada *random walk*. Angka 1,05 berarti 5% lebih besar.

***Drift*.** *Drift* adalah kecenderungan bergerak ke satu arah. Rupiah melemah rata-rata sekitar 0,38% per bulan dari Januari 2013 (9.740) ke Oktober 2026 (18.127). *Random walk* yang dipakai sebagai patokan di sini *tanpa drift*: ia mengabaikan kecenderungan itu.

3.6 Cara berpikir Bayesian: *prior*, *likelihood*, *posterior*

Kedua model memakai statistik Bayesian (pengantar: Koop, 2003; Gelman et al., 2013). Istilahnya terdengar rumit, tetapi idenya sama dengan cara orang biasa memperbarui pendapat ketika mendapat informasi baru.

> **Dalam bahasa sederhana.** Sebelum melihat data, Anda punya *prior* (***prior***). Lalu Anda melihat data, dan data punya "pendapat" sendiri (***likelihood***). Kesimpulan akhir Anda (***posterior***) adalah gabungan keduanya. Jika data kuat dan jelas, kesimpulan akhir mengikuti data. Jika data lemah atau berisik, kesimpulan akhir tetap dekat dengan *prior*.

Tiga istilah

- ***Prior***: *prior* tentang suatu parameter sebelum melihat data, dinyatakan sebagai distribusi. Contoh: "efek DXY ke rupiah kemungkinan besar sekitar 0, dan hampir pasti antara −1 dan +1". *Prior* bukan tebakan sembarangan; di model ini *prior* selalu berbentuk "kemungkinan besar tidak ada efek", lalu kekuatannya dipilih lewat uji akurasi.
- ***Likelihood***: seberapa cocok data dengan setiap kemungkinan nilai parameter. Ini bagian yang sama dengan regresi biasa. Jika hanya *likelihood* yang dipakai, hasilnya sama dengan OLS.
- ***Posterior***: distribusi parameter setelah *prior* dan data digabung. Hasilnya bukan satu angka, melainkan rentang nilai yang masuk akal beserta peluangnya.

Contoh angka: memperkirakan efek DXY

> Misalkan kita ingin tahu: jika DXY naik 1%, berapa persen rupiah melemah?
>
> ***Prior*.** *Prior mean*: efeknya 0, dengan ketidakpastian simpangan baku 0,5. Artinya kita menganggap efek antara −1 dan +1 masuk akal.
> **Data (OLS).** Regresi memberi estimasi 0,40 dengan standar error 0,10.
>
> ***Posterior*** adalah rata-rata tertimbang keduanya. Bobotnya adalah *presisi*, yaitu 1 dibagi varians (Koop, 2003, Bab 2):
> • Presisi *prior* = $1 / 0{,}5^2 = 4$
> • Presisi data = $1 / 0{,}10^2 = 100$
> • Rata-rata *posterior* = $(4 \times 0 + 100 \times 0{,}40) / (4 + 100) = 0{,}385$
> • Simpangan baku *posterior* = $\sqrt{(1 / 104)} = 0{,}098$
>
> Data jauh lebih presisi daripada *prior*, sehingga *posterior* (0,385) hampir sama dengan OLS (0,40).
>
> **Bandingkan jika datanya lemah.** Misalkan OLS memberi 0,40 tetapi standar error 0,50. Presisi data = 4, sama dengan *prior*. *Posterior* = $(4 \times 0 + 4 \times 0{,}40) / 8 = 0{,}20$. Karena data tidak meyakinkan, estimasi ditarik setengah jalan ke arah 0.

***Shrinkage*.** Contoh di atas memperlihatkan efek terpenting *prior*: estimasi yang tidak didukung data kuat di-*shrink* ke arah 0. Untuk *forecast* kurs ini sangat berguna. Koefisien OLS yang besar sering hanya kebetulan sampel; menyusutkannya membuat ramalan lebih hati-hati dan biasanya lebih akurat (Hastie et al., 2009; Bańbura, Giannone, & Reichlin, 2010). Di model ini, seberapa kuat *shrinkage* diatur oleh satu angka (λ di BVARX, *g* di BMA), dan angka itu dipilih lewat uji *validation*, bukan ditebak.

Ketidakpastian parameter ikut dihitung. Karena *posterior* adalah distribusi, model tahu bahwa efek DXY "sekitar 0,38, bisa 0,28 bisa 0,49". Ketidakpastian ini ikut masuk ke rentang *forecast*. Regresi biasa umumnya memperlakukan koefisien seolah pasti.

3.7 Simulasi Monte Carlo dan "*draw*"

Apa itu. Untuk model yang rumit, distribusi *forecast* sulit dihitung dengan rumus. Jalan keluarnya simulasi: komputer mengambil satu set nilai parameter secara acak dari *posterior* (satu ***draw***), lalu

membuat satu kemungkinan jalur masa depan dengan *shock* acak. Ini diulang 10.000 kali. Hasilnya 10.000 kemungkinan jalur kurs (Koop, 2003).

Analogi. Seperti melempar dadu 10.000 kali untuk mengetahui peluang tiap angka, alih-alih menghitungnya dengan rumus. Makin banyak lemparan, makin akurat gambaran peluangnya.

Di model ini. BVARX memakai 10.000 *draw* untuk *forecast* akhir dan skenario. Median adalah jalur ke-5.000 jika diurutkan; rentang 80% adalah jalur ke-1.000 sampai ke-9.000. Persentil dihitung dengan metode kuantil tipe 7 (Hyndman & Fan, 1996). Jumlah *draw* diatur lewat `global profile`: quick (600), standard (10.000), publication (30.000). BMA tidak perlu simulasi karena rata-rata dan simpangan bakunya bisa dihitung dengan rumus.

3.8 Dua cara meramal beberapa bulan ke depan

- **Langsung (direct).** Buat satu regresi khusus untuk setiap horizon. Untuk meramal 6 bulan ke depan, variabel terikatnya adalah perubahan kurs 6 bulan, dan variabel bebasnya data yang sudah ada hari ini. Tidak perlu meramal variabel lain. **BMA memakai cara ini.**
- **Bertahap (iterated).** Buat model satu bulan ke depan untuk semua variabel, lalu pakai ramalan bulan depan sebagai input untuk bulan berikutnya, dan seterusnya. Cara ini butuh model untuk setiap variabel, tetapi justru karena itu jalur variabel tertentu bisa diatur sesuai asumsi. **BVARX memakai cara ini**, dan itulah yang memungkinkan skenario. Perbandingan kedua cara dibahas oleh Marcellino, Stock, dan Watson (2006).

4. Data

4.1 Variabel dan sumbernya

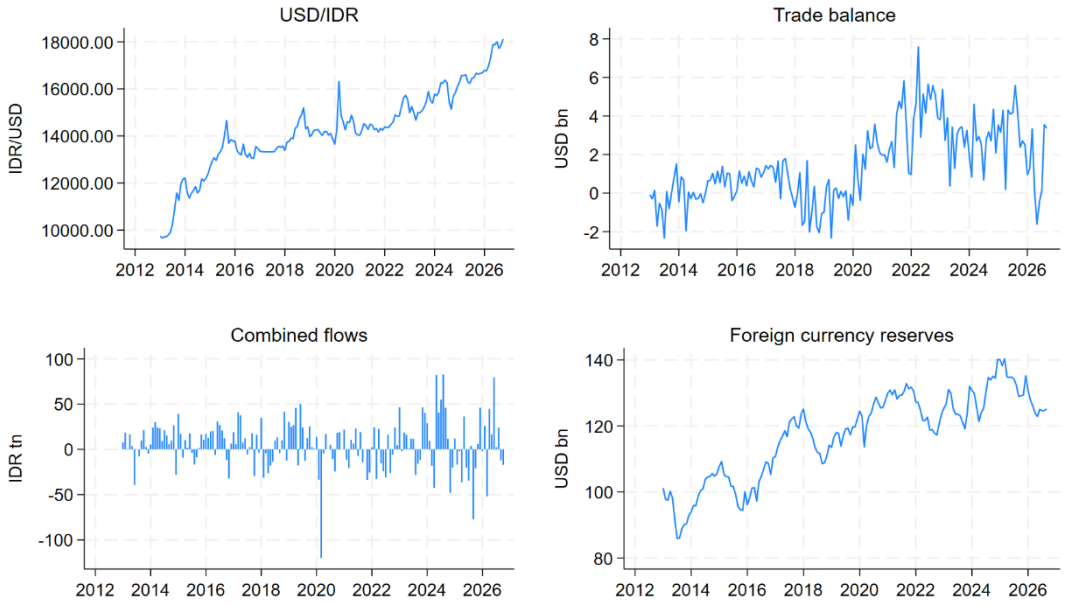
Semua data ada di satu file: `input/Database_Rupiah_Bulanan.xlsx`, sheet `database_monthly`, satu baris per bulan dari Januari 2013. Kode tidak pernah menulis ke file ini; file hanya dibaca. Definisi lengkap setiap kolom ada di sheet `sources`.

Variabel	Definisi	Satuan	Agregasi bulanan	Sumber
USD/IDR	Kurs pasar rupiah per dolar (bukan JISDOR)	IDR per USD	Nilai akhir bulan	Bloomberg
Trade balance	Ekspor FOB dikurangi impor CIF	USD miliar	Total bulan	BPS; IMF ITG untuk impor 2013–2015
Net flows asing	Saham + SBN + SRBI oleh nonresiden	Rp triliun	Jumlah bulanan	Bloomberg/BEI, DJPPR, BI
Cadangan devisa	Foreign currency reserves (IRFCL I.A.1)	USD miliar	Posisi akhir bulan	IMF IRFCL; BI SDDS untuk Sep 2026
DXY	US Dollar Index	Indeks	Nilai akhir bulan	Bloomberg
UST10Y	Yield US Treasury 10 tahun	Persen	Nilai akhir bulan	Bloomberg

Tabel 4.1 Enam variabel yang dipakai model. Sheet juga memuat VIX, BI rate, Fed funds, selisih BI–Fed, dan penanda rating; variabel itu diuji tetapi tidak terpakai di spesifikasi akhir (Bagian 6.10).

Variabel	N	Rata-rata	Simp. baku	Min	Maks
USD/IDR	166	14.243	1.756	9.664	18.127
Trade balance (USD bn)	165	1,46	1,95	−2,33	7,58
Net flows (Rp tn)	166	5,4	26,8	−120,0	82,6
Cadangan devisa (USD bn)	165	117,2	13,0	85,9	140,3
DXY	166	96,1	7,3	79,2	112,1

Tabel 4.2 Statistik deskriptif, Januari 2013 – Oktober 2026. *Trade balance* dan cadangan devisa Oktober 2026 belum tersedia (N = 165). Sumber: T1_descriptive.

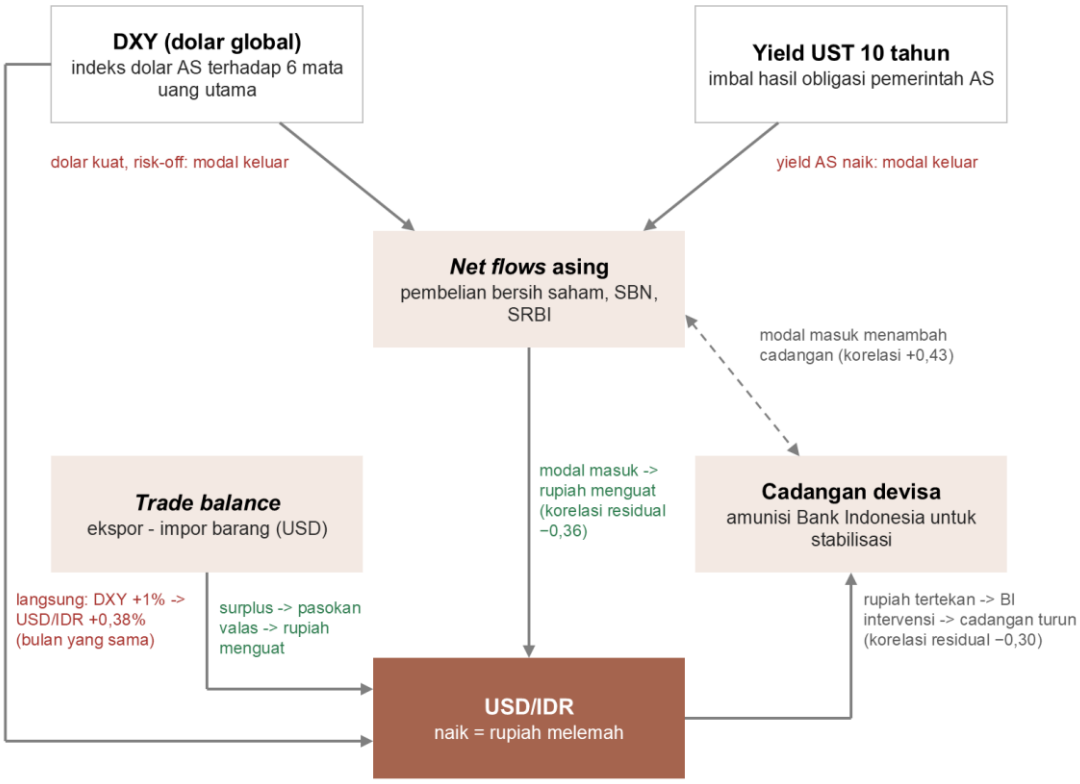


Gambar 4.1 Empat seri inti: USD/IDR, *trade balance*, *net flows*, dan cadangan devisa.

Rata-rata bulanan (v4.2). Untuk prediktor pasar BMA, kurs, DXY, dan UST10Y dipakai sebagai rata-rata bulanan dari data harian Bloomberg (kolom `usdidr_avg`, `dxy_avg`, `ust10y_avg`). Rata-rata sebulan tidak terpengaruh lonjakan satu hari di akhir bulan. Yang diramal tetap kurs akhir bulan, dan BVARX tetap memakai nilai akhir bulan.

4.2 Logika ekonomi: bagaimana setiap variabel memengaruhi rupiah

Kurs adalah harga dolar dalam rupiah, ditentukan oleh permintaan dan penawaran dolar di pasar valas domestik. Setiap variabel dalam model dipilih karena memengaruhi salah satu sisi itu.



Gambar 4.2 Peta hubungan antarvariabel. Warna merah = tekanan pelemahan rupiah, hijau = penguatan. Angka korelasi berasal dari residual BVARX (D4_residual_corr) dan efek kontemporer DXY (D6_dxy_effect).

DXY: kekuatan dolar global

Saat dolar menguat terhadap mata uang utama dunia (DXY naik), dolar biasanya juga menguat terhadap mata uang negara berkembang, termasuk rupiah (Lustig, Roussanov, & Verdelhan, 2011; Verdelhan, 2018). Penyebabnya bisa kebijakan moneter AS yang lebih ketat, permintaan aset aman (*safe haven*) saat pasar global tegang, atau perbedaan pertumbuhan. Dalam BVARX, kenaikan DXY 1% dalam satu bulan disertai pelemahan rupiah rata-rata 0,38% di bulan yang sama (interval 90%: 0,28–0,49%), arus modal keluar Rp3,2 triliun, dan cadangan devisa turun 0,28%. Ketiganya berbeda nyata dari nol. DXY diperlakukan sebagai **variabel eksogen**: memengaruhi ekonomi Indonesia, tetapi tidak dipengaruhi balik oleh variabel Indonesia.

Yield UST 10 tahun

Kenaikan yield obligasi AS membuat aset dolar lebih menarik dibanding aset rupiah, sehingga investor asing cenderung menjual SBN dan saham Indonesia (Eichengreen & Gupta, 2015). Variabel ini masuk sebagai prediktor di BMA. Di BVARX, opsi memasukkan UST diuji di *validation* tetapi tidak meningkatkan akurasi, sehingga tidak dipakai.

Net flows asing

Pembelian bersih asing atas saham, SBN, dan SRBI berarti dolar masuk dan ditukar ke rupiah: permintaan rupiah naik, rupiah menguat (Evans & Lyons, 2002; Forbes & Warnock, 2012). Penjualan bersih berarti sebaliknya. Ini kanal tercepat dan paling volatil: simpangan baku bulanan Rp26,8 triliun, dengan arus keluar terbesar Rp120 triliun (Maret 2020). Di residual BVARX, *shock flows* berkorelasi −0,36 dengan *shock* perubahan kurs: bulan dengan arus masuk lebih besar dari perkiraan cenderung disertai rupiah yang lebih kuat dari perkiraan.

Trade balance

Surplus perdagangan berarti eksportir menerima lebih banyak dolar daripada yang dibutuhkan importir; pasokan dolar di pasar domestik bertambah dan rupiah cenderung menguat (Obstfeld & Rogoff, 1996). Efeknya lebih lambat dan lebih halus dari *flows*, karena eksportir tidak selalu langsung mengonversi devisa hasil ekspor. *Trade balance* sangat persisten (autokorelasi *lag* 1 sekitar 0,69): surplus bulan ini biasanya diikuti surplus bulan depan. Sifat ini dimasukkan ke *prior* BVARX (Bagian 6.4).

Cadangan devisa

Cadangan devisa adalah amunisi Bank Indonesia untuk menstabilkan rupiah (Fratzscher et al., 2019). Hubungannya dua arah: saat rupiah tertekan, BI menjual dolar dari cadangan (intervensi), sehingga cadangan turun bersamaan dengan pelemahan rupiah (korelasi residual −0,30); saat modal masuk, BI dapat menambah cadangan (korelasi residual cadangan dengan *flows* +0,43). Karena itu cadangan diperlakukan sebagai bagian dari sistem (endogen), bukan penyebab satu arah.

> **Korelasi bukan kausalitas.** Angka korelasi residual menunjukkan variabel mana yang bergerak bersama ketika terjadi *shock*, bukan siapa menyebabkan siapa. Model memakai pola ko-pergerakan itu untuk *forecast* bersyarat (Bagian 6.7), tanpa mengklaim efek kausal tunggal. Karena itu hasil skenario dibaca sebagai "proyeksi yang konsisten dengan pola historis", bukan "dampak kausal kebijakan X".

4.3 Transformasi ke bentuk model

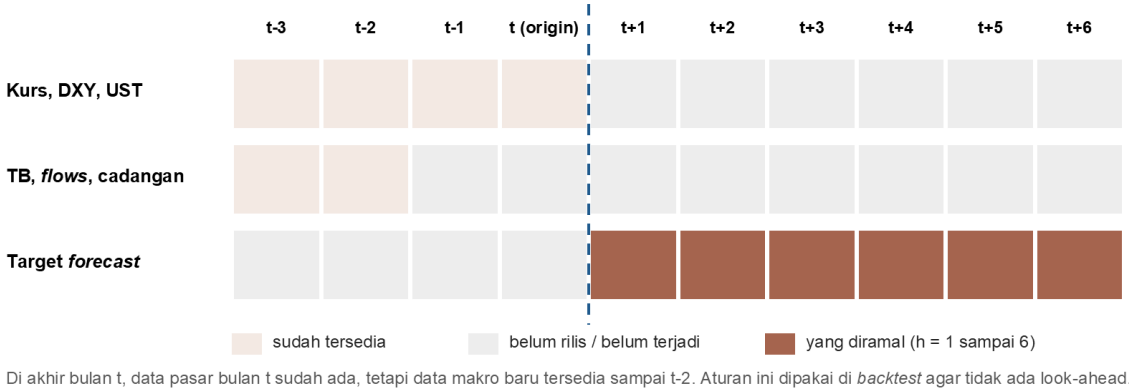
Bentuk setiap variabel di kedua model sudah dirangkum di Tabel 2.3 (Bab 2). Kodenya ada di `01_import_audit.do` (BVARX) dan `09_bma.do` (BMA). Dua komponen tambahan perlu penjelasan lebih rinci:

Musiman dengan sinus-kosinus. Daripada memakai 11 *dummy* bulan, musiman diwakili empat variabel: sin(2π·bulan/12), cos(2π·bulan/12), sin(4π·bulan/12), cos(4π·bulan/12) (Hyndman & Athanasopoulos, 2021). Pasangan pertama menangkap gelombang satu siklus per tahun, pasangan kedua dua siklus per tahun. Hasilnya pola musiman yang halus dengan hanya empat parameter.

***Dummy outlier*.** Empat bulan dengan perubahan kurs lebih dari 2,5 simpangan baku diberi impulse *dummy* (bernilai 1 hanya di bulan itu): Oktober 2015, November 2018, Maret 2020, dan April 2020. Tanpa *dummy*, satu bulan *outlier* seperti Maret 2020 bisa menarik koefisien dan memperlebar estimasi varians *shock* (Hendry et al., 2008; Lenza & Primiceri, 2022). *Dummy* hanya ada di BVARX dan bernilai 0 untuk semua bulan *forecast*.

4.4 Information set dan jeda rilis

Satu prinsip dipegang ketat di seluruh model: ***forecast* di bulan *t* hanya boleh memakai data yang sudah tersedia di akhir bulan *t***. Data pasar (kurs, DXY, UST) tersedia seketika. Data makro dirilis terlambat: neraca perdagangan dirilis BPS sekitar pertengahan bulan berikutnya, dan cadangan devisa awal bulan berikutnya. Model memakai aturan konservatif: data makro dianggap tersedia sampai bulan *t*−2 (`global release_lag 2`).



Di akhir bulan t, data pasar bulan t sudah ada, tetapi data makro baru tersedia sampai t-2. Aturan ini dipakai di *backtest* agar tidak ada look-ahead.

Gambar 4.3 Data yang boleh dipakai saat membuat *forecast* di bulan *t*.

Pelanggaran prinsip ini disebut **look-ahead bias**: memakai informasi yang belum ada saat *forecast* dibuat, sehingga akurasi *backtest* terlihat lebih baik dari kenyataan (Croushore & Stark, 2001). Satu keterbatasan tetap ada: database berisi data versi terakhir (*latest vintage*). Jika suatu angka direvisi setelah rilis pertama, *backtest* memakai angka revisi, bukan angka yang sebenarnya diketahui saat itu. Karena itu *backtest* disebut *pseudo-real-time*.

Data Oktober 2026 (*anchor*)

Pada *anchor* Oktober 2026, kurs, DXY, UST, dan *flows* Oktober sudah ada, tetapi *trade balance* dan cadangan devisa Oktober belum dirilis. *Flows* Oktober masih sementara: saham sampai 30 Oktober, SBN dari perubahan kepemilikan harian sampai 29 Oktober, dan SRBI dari data mingguan BI sampai 29 Oktober. Bulan lengkap terakhir (`latest_complete`) adalah September 2026, dan *anchor* pasar (`final_origin`) adalah Oktober 2026. Untuk *forecast* resmi, BVARX diestimasi sampai September, lalu data Oktober yang sudah ada (kurs dan *flows*) dipakai sebagai kondisi *bridge* (Bagian 6.8). *Trade balance* dan cadangan Oktober dibiarkan kosong dan diperkirakan model, tidak diisi nol atau interpolasi.

4.5 Audit dan uji *unit root*

Sebelum model dijalankan, `01_import_audit.do` memeriksa: bulan berurutan tanpa celah, tidak ada duplikat, kurs/DXY/cadangan positif, kolom `core_complete` konsisten dengan kelengkapan lima variabel inti, dan *net flows* tepat sama dengan jumlah saham + SBN + SRBI di sheet `flow_components`. Jika satu syarat gagal, run berhenti dengan pesan error.

Seri (sampel 2014 – Sep 2026)	Spesifikasi	*Lag*	ADF τ	ADF p	PP p	Kesimpulan
Log USD/IDR (level)	konstanta + tren	0	−3,74	0,020	0,027	Stasioner di sekitar tren
Δ log USD/IDR	konstanta	0	−13,41	< 0,001	< 0,001	Stasioner
Log cadangan (level)	konstanta + tren	0	−2,66	0,252	0,192	*Unit root*
Δ log cadangan	konstanta	0	−11,85	< 0,001	< 0,001	Stasioner

Seri (sampel 2014 – Sep 2026)	Spesifikasi	*Lag*	ADF τ	ADF p	PP p	Kesimpulan
Log DXY (level)	konstanta + tren	0	−2,79	0,200	0,152	*Unit root*
Δ log DXY	konstanta	0	−11,48	< 0,001	< 0,001	Stasioner
Trade balance	konstanta	1	−3,27	0,001	< 0,001	Stasioner
Net flows	konstanta	0	−10,40	< 0,001	< 0,001	Stasioner

Tabel 4.3 Uji *unit root* (D2_unit_root): ADF (Dickey & Fuller, 1979; Said & Dickey, 1984) dengan *lag* dipilih BIC (Schwarz, 1978; Ng & Perron, 1995), dan Phillips-Perron (Phillips & Perron, 1988). H_0 = *unit root*; p < 0,05 berarti stasioner.

Cara membaca. Cadangan dan DXY jelas ber-*unit root* di level dan stasioner setelah diambil perubahannya. *Trade balance* dan *flows* stasioner di level, sehingga dipakai apa adanya. Log USD/IDR menarik: uji menolak *unit root* di sekitar tren linear (p 0,020). Artinya, dalam sampel ini rupiah bergerak di sekitar tren depresiasi yang cukup teratur. Model tetap memakai perubahan kurs karena (1) uji *unit root* berdaya rendah pada sampel 12 tahun (Hamilton, 1994, Bab 17), (2) memakai tren deterministik untuk *forecast* berisiko jika tren berubah, dan (3) versi level terbukti kalah dari *random walk* di uji *out-of-sample*. Tren depresiasi masuk lewat konstanta (*drift*) di BMA.

5. Model 1: Bayesian *Model Averaging* (Baseline)

5.1 Intuisi: *model averaging*

Bayangkan 64 analis. Masing-masing memakai regresi sederhana untuk meramal kurs, tetapi dengan kombinasi indikator yang berbeda: ada yang hanya memakai perubahan kurs bulan ini, ada yang memakai DXY dan *flows*, ada yang memakai semuanya, ada juga yang tidak memakai indikator apa pun (hanya rata-rata historis). Daripada memilih satu analis "terbaik" (yang bisa jadi hanya beruntung di masa lalu), BMA mengambil **rata-rata pendapat semua analis**, dengan bobot sesuai seberapa baik masing-masing menjelaskan data, dengan penalti untuk model yang terlalu rumit.

Keuntungannya: ketidakpastian tentang "variabel mana yang benar-benar penting" ikut diperhitungkan. Jika data tidak bisa membedakan model-model itu, bobotnya hampir rata, dan *forecast* menjadi rata-rata yang hati-hati. Kerangka ini diuraikan oleh Raftery, Madigan, dan Hoeting (1997) dan Hoeting et al. (1999).

5.2 Persamaan: regresi prediktif langsung

Untuk setiap horizon h = 1, …, 6 diestimasi satu persamaan terpisah:

$$y_{t,h} = \alpha + \beta_1 \cdot ds_t + \beta_2 \cdot ddxy_t + \beta_3 \cdot dust_t + \beta_4 \cdot flow2_t + \beta_5 \cdot tb2_t + \beta_6 \cdot dres2_t + \varepsilon_{t+h}$$

dengan $y_{t,h} = 100 \times [\ln S_{t+h} - \ln S_t]$, yaitu persen perubahan kurs dari bulan t ke $t+h$. Semua variabel di kanan diketahui di akhir bulan t. Akibatnya, untuk meramal tidak diperlukan *forecast* variabel lain: cukup masukkan nilai prediktor bulan terakhir ke persamaan.

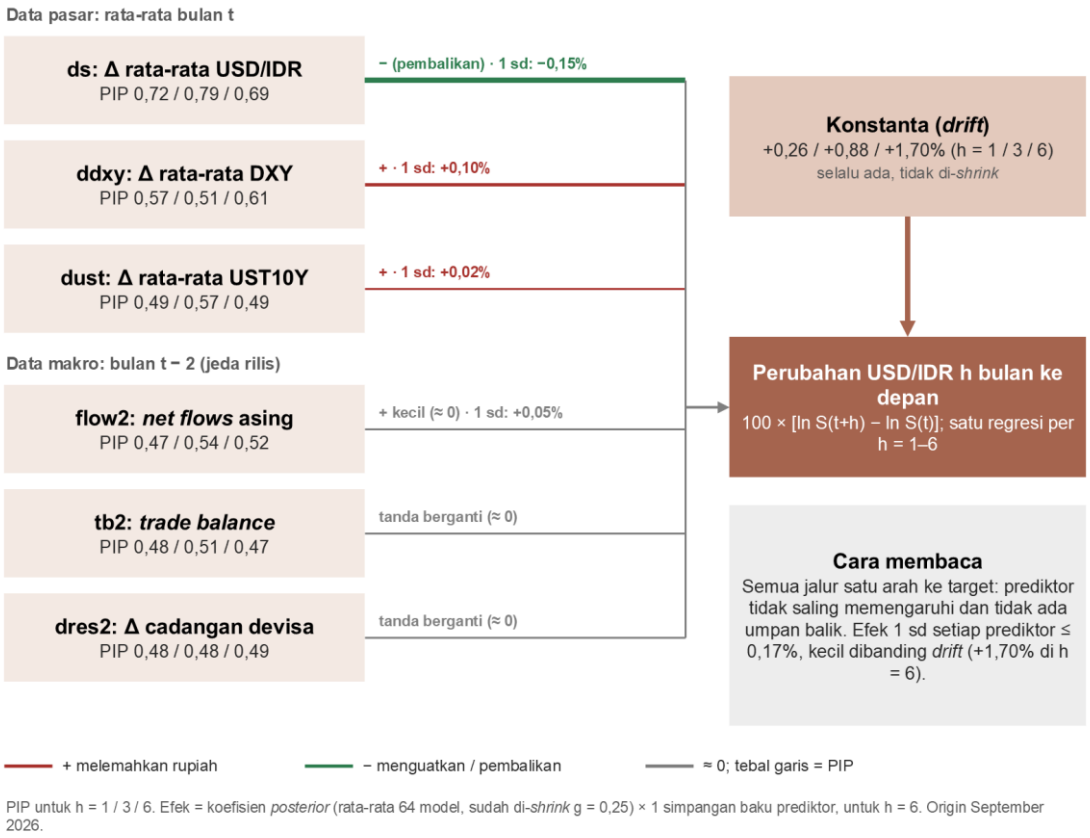
Kode	Prediktor	Bulan data	Logika ekonomi	Tanda yang diharapkan
ds	Perubahan rata-rata bulanan USD/IDR (100 × Δln)	t	Momentum (tekanan berlanjut) atau pembalikan	+ momentum / − pembalikan
ddxy	Perubahan rata-rata bulanan DXY (100 × Δln)	t	Penguatan dolar global merambat ke rupiah dengan jeda	+
dust	Perubahan rata-rata bulanan UST10Y (poin persen)	t	Yield AS naik mendorong arus modal keluar	+
flow2	*Net flows* asing (Rp10 tn)	$t-2$	Arus masuk memperkuat rupiah, atau berbalik	− (atau + jika berbalik)
tb2	*Trade balance* (USD bn)	$t-2$	Surplus menambah pasokan valas	−
dres2	Perubahan cadangan (100 × Δln)	$t-2$	Kapasitas stabilisasi BI; penurunan menandakan intervensi	−

Tabel 5.1 Enam kandidat prediktor BMA. Tanda + berarti nilai prediktor yang lebih tinggi meramal rupiah lebih lemah.

Mengapa regresi langsung, bukan VAR? Regresi langsung tidak membutuhkan model untuk meramal *trade balance*, *flows*, atau DXY ke depan (Marcellino et al., 2006). Setiap kesalahan spesifikasi di persamaan variabel lain tidak menular ke *forecast* kurs. Ini salah satu alasan BMA lebih akurat daripada BVARX di uji *out-of-sample*. Harga yang dibayar: BMA tidak bisa menjawab pertanyaan skenario, karena tidak ada tempat untuk memasukkan asumsi jalur variabel ke depan.

Data training. Untuk origin *r* dan horizon *h*, baris yang dipakai adalah bulan *t* sejak Januari 2014 dengan $t + h \le r$, sehingga targetnya sudah terealisasi. Contoh: untuk *forecast* resmi (origin Oktober 2026) dan $h = 6$, baris terakhir adalah April 2026, yang targetnya adalah perubahan April→Oktober 2026.

Hubungan antarvariabel. Gambar 5.1 merangkum hubungan antarvariabel di BMA. Setiap prediktor hanya punya satu jalur, yaitu langsung ke perubahan kurs *h* bulan ke depan. Prediktor tidak saling memengaruhi, dan kurs tidak memengaruhi balik prediktor. Tanda yang dihasilkan data (estimasi origin September 2026; di origin Oktober 2026 PIP hampir sama, Tabel 5.3): perubahan kurs bulan ini bertanda **negatif**, artinya pembalikan (setelah rupiah melemah, model memperkirakan sedikit penguatan), bukan momentum. DXY dan UST10Y bertanda positif sesuai teori. *Flows*, *trade balance*, dan cadangan praktis nol: *flows* bertanda positif kecil (pola "berbalik" di Tabel 5.1), sedangkan tanda *trade balance* dan cadangan berganti antar-horizon. Semua efek kecil: satu simpangan baku pergerakan prediktor menggeser *forecast* paling banyak sekitar 0,17%, dibanding *drift* +1,70% di $h = 6$.



Gambar 5.1 Hubungan antarvariabel di BMA: enam prediktor dan konstanta menuju satu target. Warna = tanda koefisien *posterior*; tebal garis = PIP.

5.3 Ruang model: 64 kombinasi

Setiap prediktor bisa masuk atau tidak masuk, sehingga ada $2^6 = 64$ model, dari model tanpa prediktor (hanya konstanta) sampai model dengan keenam prediktor. Konstanta α selalu ada di semua model. Semua 64 model diestimasi (**enumerasi penuh**), tidak ada yang dilewati.

***Prior* atas model.** Setiap prediktor diberi peluang awal 50% untuk masuk (`mprior(binomial 0.5)`; Ley & Steel, 2009). Ini setara dengan memberi peluang awal yang sama, 1/64, kepada setiap model. Dengan kata lain, sebelum melihat data, model tidak memihak kombinasi tertentu.

5.4 g-*prior* Zellner: seberapa kuat koefisien di-*shrink*

> **Dalam bahasa sederhana.** Setiap dari 64 regresi tidak memakai koefisien OLS apa adanya. Koefisiennya "dikecilkan" ke arah nol, dengan cara yang sama seperti contoh efek DXY di Bab 3.6. Seberapa kuat dikecilkan diatur oleh satu angka, *g*. Dengan *g* = 0,25, setiap koefisien tinggal 20% dari nilai OLS-nya. Konstanta tidak ikut dikecilkan. Alasannya: hubungan antara indikator dan kurs di masa depan sangat lemah, sehingga koefisien OLS yang besar kemungkinan besar hanya kebetulan.

Untuk setiap model, koefisien β diberi *prior* normal berpusat di nol:

$$\beta \mid \sigma^2, M \sim N(0, g \cdot \sigma^2 \cdot (X'X)^{-1})$$

Bentuk varians ini (Zellner, 1986) membuat *prior* mengikuti skala dan korelasi data, sehingga cukup satu angka *g* untuk mengatur kekuatannya. Konstanta α dan varians σ² diberi *prior* datar (tidak informatif), mengikuti Fernández, Ley, dan Steel (2001). Akibatnya konstanta, yang mewakili *drift* depresiasi, tidak ikut di-*shrink*.

Dengan *prior* ini, rata-rata *posterior* koefisien punya bentuk yang sangat sederhana:

$$E[\beta \mid \text{data}, M] = g / (1 + g) \times \beta_{OLS}$$

> **Contoh angka.** Dengan *g* = 0,25, faktor *shrinkage* = 0,25/1,25 = 0,20. Jika OLS memberi koefisien flow2 = −0,50 (arus masuk Rp10 triliun meramal rupiah 0,5% lebih kuat), BMA memakai −0,10 untuk model itu. Dengan *g* = 4, faktornya 0,8, sehingga koefisien menjadi −0,40. Makin kecil *g*, makin kecil peran prediktor dan makin dekat *forecast* ke *drift* historis.

Bagaimana *g* dipilih. Nilai *g* tidak ditebak. Empat kandidat (0,25; 1; 4; *n*) diuji di periode *validation* (origin Januari 2021 – Juni 2023). Kandidat *g* = *n* (jumlah observasi) dikenal sebagai *unit information prior*, *prior* yang lemah (Kass & Wasserman, 1995). Skornya adalah rata-rata relative RMSE di horizon 1, 3, dan 6.

g	h = 1	h = 3	h = 6	Skor
0,25 (terpilih)	**0,99**	**0,98**	**0,93**	**0,968**
1	1,00	0,99	0,93	0,973
4	1,00	1,04	0,93	0,992
n (unit information)	1,00	1,03	0,94	0,987

Tabel 5.2 Pemilihan *g* di *validation* (v4, prediktor akhir bulan). Dengan prediktor rata-rata bulanan (v4.2), *g* = 0,25 memberi 0,98 / 0,98 / 0,92 (skor 0,961).

Shrinkage paling kuat (*g* = 0,25) memberi skor terbaik, sejalan dengan temuan Wright (2008) bahwa BMA untuk kurs bekerja paling baik dengan *shrinkage* kuat. Setelah dipilih, *g* dikunci di 0,25 (`global bma_g_grid "0.25"`) agar run lebih cepat. Untuk memvalidasi ulang, kembalikan ke `"0.25 1 4 n"`.

5.5 Bobot model: marginal *likelihood*

> **Dalam bahasa sederhana.** Setelah 64 regresi diestimasi, masing-masing diberi nilai: seberapa baik ia menjelaskan perubahan kurs di masa lalu, dikurangi penalti untuk setiap indikator tambahan yang dipakai. Nilai ini mirip kriteria BIC atau adjusted R^2 yang dikenal di ekonometrika dasar. Regresi dengan nilai tinggi mendapat bobot besar dalam rata-rata akhir. Jika semua regresi nilainya mirip, bobotnya hampir rata, dan itulah yang terjadi di model ini.

Bobot setiap model adalah **probabilitas *posterior* model**:

$$\mathrm{P(M \mid data)} \propto \mathrm{p(data \mid M)} \times \mathrm{P(M)}$$

Karena P(M) sama untuk semua model, bobot ditentukan oleh **marginal *likelihood*** p(data | M): peluang data teramati jika model M benar, setelah dirata-ratakan atas semua kemungkinan nilai koefisien menurut *prior*. Untuk g-*prior* (Liang et al., 2008), ukuran ini bergantung pada R^2 model (R^2_M), jumlah prediktor k_M, dan jumlah observasi n:

$$\mathrm{p(data \mid M)} \propto (1+g)^{(n-1-k_M)/2} \times [1+g(1-R^2_M)]^{-(n-1)/2}$$

Dua kekuatan bekerja di sini: R^2 yang lebih tinggi menaikkan bobot (model lebih cocok dengan data), sedangkan setiap prediktor tambahan memberi penalti $(1+g)^{-1/2}$. Inilah cara BMA menyeimbangkan kecocokan dan kesederhanaan, mirip kriteria informasi seperti BIC (Schwarz, 1978; Kass & Raftery, 1995).

> **Contoh angka: mengapa PIP dekat 0,5.** Bandingkan model dengan satu prediktor yang menjelaskan 2% variasi (R^2 = 0,02) dengan model tanpa prediktor, n = 150.
> • Dengan g = 0,25: penalti = $1{,}25^{-0{,}5}$ = 0,89; keuntungan dari R^2 = $[1{,}25 / (1 + 0{,}25\times0{,}98)]^{74{,}5}$ = 1,35. Rasio bobot = 0,89 × 1,35 ≈ 1,2. Peluang prediktor itu masuk ≈ 1,2/2,2 = 0,55.
> • Dengan $g = n$ = 150: penalti = $151^{-0{,}5}$ = 0,08; keuntungan = 4,5. Rasio ≈ 0,36, sehingga peluang masuk ≈ 0,27.
> Dengan g kecil, data hanya bisa menggeser bobot sedikit dari *prior* 50:50. Ini menjelaskan mengapa PIP semua prediktor berada di kisaran 0,47–0,79 (Bagian 5.6): sinyal kurs memang lemah, dan g kecil membuat BMA tidak mudah "yakin".

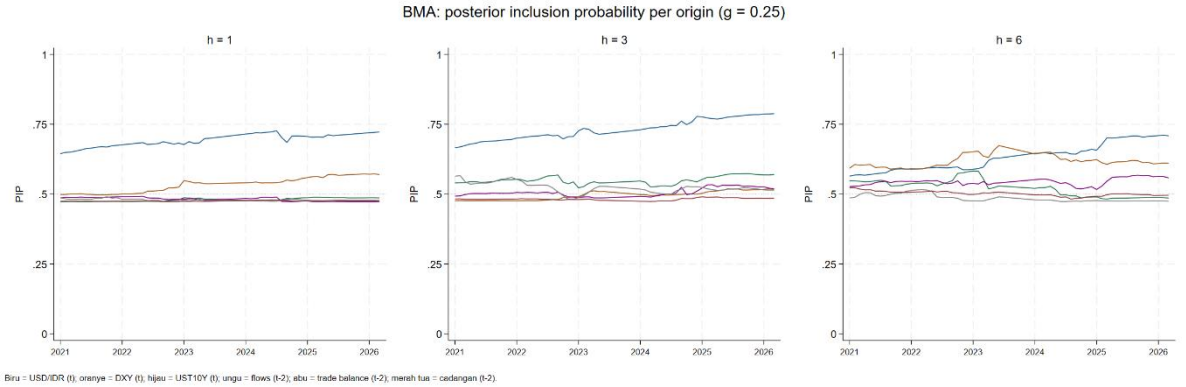
5.6 *Posterior inclusion probability* (PIP)

PIP sebuah prediktor adalah jumlah bobot semua model yang memuat prediktor itu (Hoeting et al., 1999). PIP adalah ukuran utama "seberapa penting" suatu variabel di BMA, menggantikan peran nilai-p di regresi biasa.

- PIP mendekati 1: data sangat yakin prediktor itu relevan.
- PIP sekitar 0,5: data tidak mengubah keyakinan awal (*prior* 0,5); tidak ada bukti kuat ke arah mana pun.
- PIP mendekati 0: data yakin prediktor itu tidak relevan.

Prediktor	PIP h = 1	PIP h = 3	PIP h = 6
ds: perubahan rata-rata USD/IDR	0,72	0,79	0,69
ddxy: perubahan rata-rata DXY	0,57	0,51	0,60
dust: perubahan rata-rata UST10Y	0,49	0,57	0,49
flow2: *net flows* (t−2)	0,47	0,54	0,53
tb2: *trade balance* (t−2)	0,48	0,51	0,47
dres2: perubahan cadangan (t−2)	0,48	0,48	0,49

Tabel 5.3 PIP sampel penuh (sampai origin Oktober 2026). Sumber: B4_bma_pip_final.



Gambar 5.2 PIP per origin *backtest* (2021–2026). Garis putus-putus = *prior* 0,5.

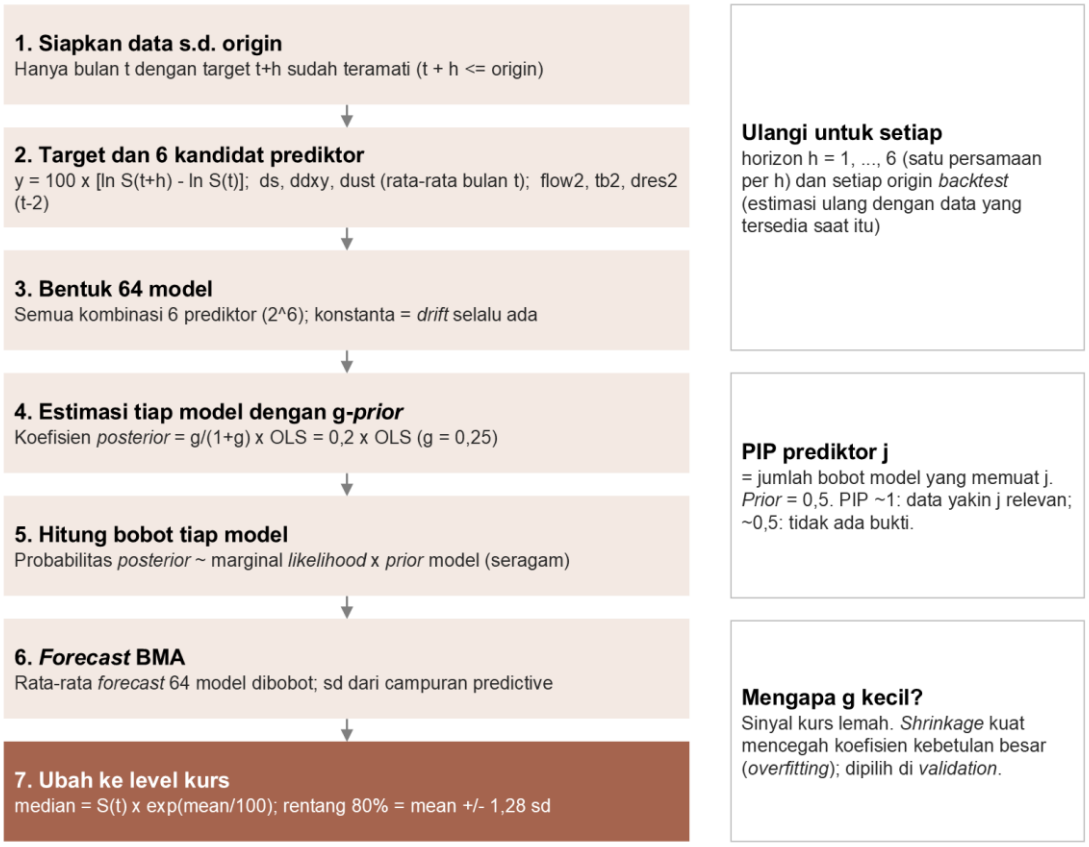
Prediktor paling kuat adalah perubahan kurs rata-rata bulan ini (PIP 0,72 / 0,79 / 0,69 untuk h = 1 / 3 / 6), dengan tanda negatif: pembalikan, bukan momentum (Gambar 5.1). Prediktor lain sekitar 0,5, dengan DXY sedikit di atasnya di 6 bulan (0,60). Bobot tetap tersebar: sepuluh model teratas di h = 3 hanya memegang sekitar 30% total bobot, dan model teratas hanya 3,4%.

Peringkat	Prediktor dalam model	Probabilitas *posterior*
1	USD/IDR + UST10Y + *flows* + *trade balance*	3,4%
2	USD/IDR + DXY + UST10Y + *flows* + *trade balance*	3,3%
3	USD/IDR + DXY + UST10Y + *flows*	3,2%
4	USD/IDR + UST10Y + *flows*	3,2%
5	USD/IDR + UST10Y + *flows* + *trade balance* + cadangan	3,0%

Tabel 5.4 Lima model dengan probabilitas *posterior* tertinggi, h = 3 (B6_bma_top_models_h3). Bandingkan dengan *prior* 1/64 = 1,6%.

5.7 Dari 64 model ke satu *forecast*

> **Dalam bahasa sederhana.** Masukkan data bulan terakhir ke setiap regresi, sehingga didapat 64 ramalan perubahan kurs. Ambil rata-ratanya dengan bobot dari Bagian 5.5. Untuk rentang, gabungkan tiga sumber ketidakpastian: *shock* acak di masa depan, ketidakpastian koefisien, dan perbedaan pendapat antar-regresi. Terakhir, ubah persen perubahan menjadi level kurs.



Gambar 5.3 Alur perhitungan BMA untuk satu origin dan satu horizon.

Forecast BMA adalah rata-rata *forecast* 64 model, dibobot probabilitas posteriornya:

$$\hat{y}_{BMA} = \Sigma_M \, P(M \mid data) \times \hat{y}_M$$

Ketidakpastiannya (simpangan baku predictive) memuat tiga sumber: *shock* acak masa depan (σ^2), ketidakpastian koefisien dalam tiap model, dan ketidakpastian model (perbedaan *forecast* antar-model). Stata menghitung mean dan simpangan baku ini secara analitis lewat `bmapredict` (StataCorp, 2025). Rentang dibentuk dengan pendekatan normal:

$$\text{rentang } 80\% = \hat{y} \pm 1{,}28 \times \text{sd};\ \text{rentang } 95\% = \hat{y} \pm 1{,}96 \times \text{sd}$$

lalu diubah ke level kurs: $S_{t+h} = S_t \times \exp(\text{nilai}/100)$. Karena transformasi eksponensial, rentang dalam rupiah sedikit tidak simetris (lebih panjang ke atas).

Bulan	h	Mean (%)	Sd (%)	Median	Rentang 80%	Rentang 95%
Nov 2026	1	0,26	2,27	18.175	17.653 – 18.712	17.382 – 19.003
Des 2026	2	0,54	3,06	18.226	17.526 – 18.954	17.166 – 19.351
Jan 2027	3	0,83	3,45	18.278	17.487 – 19.104	17.083 – 19.557
Feb 2027	4	1,17	3,68	18.340	17.496 – 19.226	17.064 – 19.712
Mar 2027	5	1,51	3,95	18.403	17.495 – 19.358	17.032 – 19.884
Apr 2027	6	1,81	4,13	18.459	17.508 – 19.461	17.025 – 20.013

Tabel 5.5 *Forecast* BMA dari *anchor* Oktober 2026 = 18.127 (B5_bma_final_forecast).

Contoh hitung April 2027. Mean = 1,81%, sd = 4,13%.
Median = 18.127 × exp(1,81/100) = 18.127 × 1,01829 = 18.459.
Batas bawah 80% = 18.127 × exp((1,81 − 1,2816 × 4,13)/100) = 17.508.
Batas atas 80% = 18.127 × exp((1,81 + 1,2816 × 4,13)/100) = 19.461.

5.8 Satu persamaan per horizon, estimasi ulang setiap origin

Karena persamaan untuk *h* = 1 berbeda dari persamaan untuk *h* = 6, *forecast* bulan November 2026 dan April 2027 berasal dari dua regresi berbeda. Itu sebabnya jalur baseline tidak harus berupa garis lurus. Di *backtest*, untuk setiap origin dari Januari 2021 sampai Maret 2026, seluruh 64 model diestimasi ulang hanya dengan data yang tersedia saat itu. Tidak ada informasi masa depan yang bocor ke pemilihan bobot.

5.9 Mengapa baseline naik bertahap: peran *drift*

Baseline BMA naik sekitar 0,3% per bulan. Penyebab utamanya adalah konstanta α, yang ada di semua 64 model dan tidak di-*shrink*. Konstanta ini mencerminkan rata-rata perubahan kurs *h* bulan di sampel 2014–2026, yaitu tren depresiasi historis rupiah. Prediktor hanya menggeser *forecast* sedikit dari *drift* itu, karena koefisiennya tinggal sekitar 20% dari OLS dan PIP-nya sekitar 0,5.

Implikasi penting. Keunggulan BMA atas *random walk* di periode test sebagian besar berasal dari *drift*, dan periode test 2024–2026 kebetulan periode depresiasi rupiah. Jika tren rupiah berbalik menguat dalam waktu lama, baseline BMA akan tertinggal sampai *drift* yang diestimasi menyesuaikan. Ini dicatat sebagai keterbatasan (Bab 11) dan menjadi alasan untuk mengevaluasi ulang model secara berkala dengan data baru.

6. Model 2: BVARX (Efek Skenario)

6.1 Intuisi: VAR sebagai sistem persamaan

VAR (vector autoregression) adalah sekumpulan regresi (Sims, 1980), satu untuk setiap variabel, dengan aturan sederhana: setiap variabel dijelaskan oleh nilai masa lalu *semua* variabel dalam sistem. Jadi perubahan kurs bulan ini dijelaskan oleh perubahan kurs, *trade balance*, *flows*, dan perubahan cadangan satu dan dua bulan lalu; begitu pula *trade balance*, *flows*, dan cadangan. Karena semua variabel dimodelkan, sistem bisa diramal bersama: *forecast* bulan depan semua variabel dipakai untuk meramal bulan berikutnya, dan seterusnya.

Huruf **X** berarti ada **variabel eksogen**: variabel yang memengaruhi sistem tetapi tidak dimodelkan, sehingga nilainya ke depan harus diberikan dari luar. Di sini eksogen utamanya adalah perubahan DXY. Inilah pintu masuk skenario: jalur DXY ke depan bisa diatur sesuai asumsi.

Huruf **B** berarti **Bayesian**: koefisien diberi *prior* yang menyusutkannya, karena VAR punya banyak sekali parameter dibanding panjang data.

6.2 Spesifikasi lengkap

> **Dalam bahasa sederhana.** Ada empat regresi yang dijalankan bersamaan. Contohnya persamaan kurs: perubahan kurs bulan ini dijelaskan oleh (1) perubahan kurs, *trade balance*, *flows*, dan perubahan cadangan pada satu dan dua bulan lalu, (2) perubahan DXY bulan ini, (3) pola musiman, dan (4) *dummy outlier*. Tiga persamaan lain sama, hanya variabel di kiri yang berbeda. *Shock* (residual) di keempat persamaan boleh saling berkorelasi, dan korelasi inilah yang nanti dipakai untuk skenario.

Vektor variabel endogen (ditentukan di dalam sistem) pada bulan t:

$$\mathbf{y}_t = [\, \Delta s_t,\ \mathrm{TB}_t,\ \mathrm{F}_t/10,\ \Delta r_t \,]'$$

dengan $\Delta s = 100 \times \Delta\ln$ USD/IDR, TB = *trade balance* (USD bn), F = *net flows* (Rp tn, dibagi 10), dan $\Delta r = 100 \times \Delta\ln$ cadangan devisa. Variabel eksogen:

$$\mathbf{x}_t = [\, \Delta d_t,\ \sin12_t,\ \cos12_t,\ \sin6_t,\ \cos6_t,\ \mathrm{D}_{2015\mathrm{m}10},\ \mathrm{D}_{2018\mathrm{m}11},\ \mathrm{D}_{2020\mathrm{m}3},\ \mathrm{D}_{2020\mathrm{m}4} \,]'$$

dengan $\Delta d = 100 \times \Delta\ln$ DXY. Model dengan *lag* $p = 2$:

$$\mathbf{y}_t = \mathbf{c} + \mathrm{A}_1\,\mathbf{y}_{t-1} + \mathrm{A}_2\,\mathbf{y}_{t-2} + \mathrm{B}\,\mathbf{x}_t + \mathbf{u}_t,\ \mathbf{u}_t \sim \mathrm{N}(0, \Sigma)$$

Ditulis per persamaan, persamaan kurs berbunyi:

$$\Delta s_t = \mathrm{c}_1 + \mathrm{a}_{11}\Delta s_{t-1} + \mathrm{a}_{12}\mathrm{TB}_{t-1} + \mathrm{a}_{13}\mathrm{F}_{t-1}/10 + \mathrm{a}_{14}\Delta r_{t-1} + (\text{empat koefisien } \textit{lag}\ 2) + \mathrm{b}_{11}\Delta d_t + (\text{musiman}) + (\textit{dummy}) + \mathrm{u}_{1t}$$

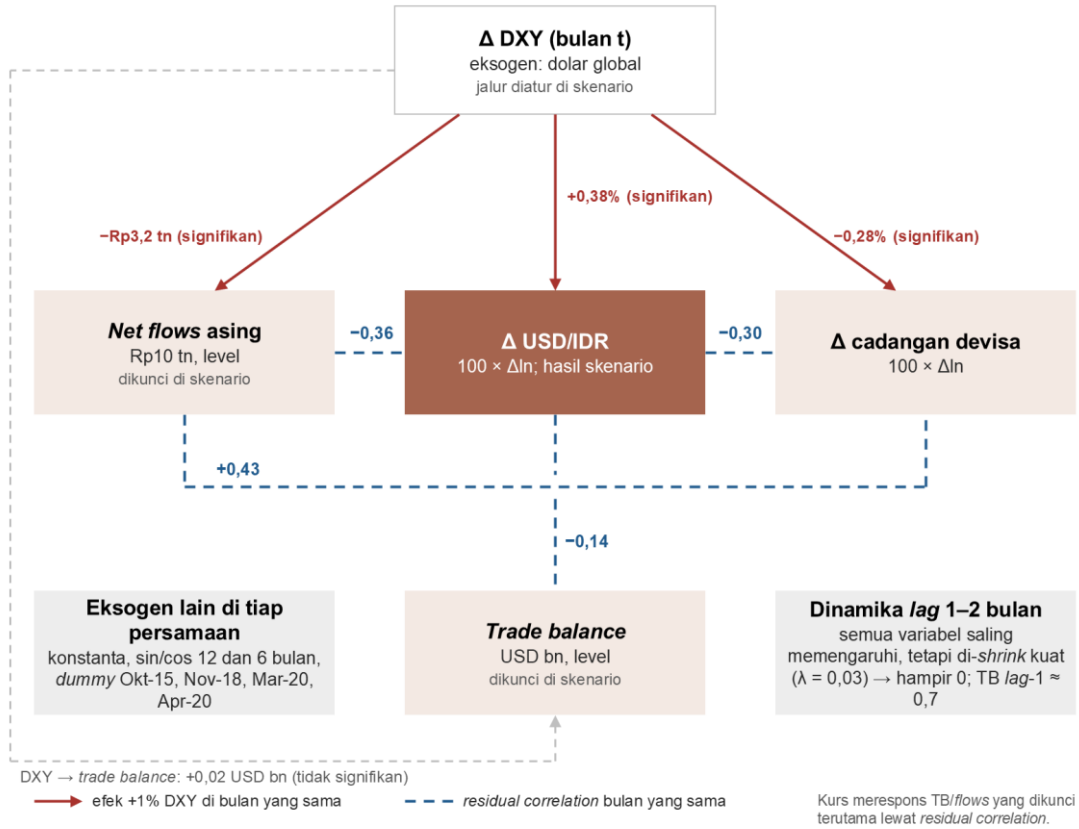
Tiga persamaan lain punya bentuk yang sama dengan variabel kiri berbeda. Setiap persamaan memiliki 18 koefisien: 1 konstanta, 8 koefisien *lag* (4 variabel × 2 *lag*), dan 9 koefisien eksogen. Total 72 koefisien ditambah 10 elemen unik matriks Σ, diestimasi dari 153 bulan (Januari 2014 – September 2026). Rasio parameter terhadap data ini menjelaskan mengapa *prior* diperlukan.

Matriks Σ adalah kovarians *shock* antarpersamaan. Elemen di luar diagonal menangkap fakta bahwa *shock* kurs, *flows*, dan cadangan cenderung terjadi bersamaan (korelasi −0,36, −0,30, dan +0,43 di Gambar 4.2). Informasi ini penting untuk *forecast* bersyarat: jika *flows* dikunci lebih rendah, model tahu kurs cenderung lebih lemah di bulan yang sama.

Standardisasi

Sebelum estimasi, setiap variabel dikurangi rata-ratanya dan dibagi simpangan bakunya, dihitung hanya dari data training. Tujuannya agar satu tingkat *shrinkage* (λ) berlaku adil untuk semua variabel walau satuannya berbeda: persen, USD miliar, dan Rp10 triliun. Standardisasi ini adalah pilihan rancangan model ini. *Prior* Minnesota klasik mencapai hal serupa dengan menskalakan varians *prior* memakai varians residual AR(1) (Litterman, 1986), dan penskalaan itu tetap dilakukan di sini. Hasil *forecast* dikembalikan ke satuan asli di akhir.

Hubungan antarvariabel. Gambar 6.1 merangkum hubungan antarvariabel di BVARX. Berbeda dengan BMA, keempat variabel endogen saling terhubung. Jalur pertama: DXY memengaruhi keempatnya di bulan yang sama. Dolar menguat 1% melemahkan rupiah 0,38%, menurunkan *flows* Rp3,2 triliun, dan menurunkan cadangan 0,28%; efeknya ke *trade balance* tidak signifikan. Jalur kedua: *shock* keempat persamaan saling berkorelasi (matriks Σ). *Flows* dan cadangan bergerak searah (+0,43), dan keduanya bergerak berlawanan dengan USD/IDR (−0,36 dan −0,30); *shock trade balance* hampir tidak berkorelasi dengan kurs (−0,14). Jalur ketiga, pengaruh *lag* 1–2 bulan antarvariabel, ada di model tetapi di-*shrink* hampir nol oleh *prior* (Bagian 6.4), kecuali *lag trade balance* terhadap dirinya sendiri. Saat skenario mengunci DXY, *trade balance*, dan *flows*, kurs bergeser terutama lewat jalur pertama dan kedua.



Gambar 6.1 Hubungan antarvariabel di BVARX: efek DXY di bulan yang sama (merah) dan *residual correlation* antarpersamaan (biru putus-putus).

6.3 Masalah utama: terlalu banyak parameter

Dengan 72 koefisien dan data 12 tahun, OLS per persamaan akan menghasilkan banyak koefisien yang besar karena kebetulan. *Forecast* dari koefisien seperti itu biasanya buruk di luar sampel: model "menemukan" hubungan yang tidak ada. Solusi standar sejak Doan, Litterman, dan Sims (1984) dan

Litterman (1986) adalah ***prior* Minnesota**: semua koefisien *lag* ditarik ke nilai yang masuk akal, dan data harus memberi bukti kuat untuk menggesernya.

6.4 *Prior* Minnesota

> **Dalam bahasa sederhana.** *Prior* Minnesota adalah distribusi *prior* untuk 72 koefisien VAR, dengan logika Bab 3.6. *Prior mean*-nya: "perubahan kurs bulan depan tidak bisa diramal dari data bulan-bulan lalu", kecuali *trade balance*, yang memang cenderung bertahan dari bulan ke bulan. Data harus memberi bukti kuat untuk menggeser koefisien dari dugaan itu. Seberapa kuat bukti yang dibutuhkan diatur oleh λ; makin kecil λ, makin skeptis model.

Prior Minnesota punya tiga ide (Litterman, 1986; Bańbura et al., 2010; Karlsson, 2013):

1. **Mean *prior*.** Untuk variabel dalam perubahan (kurs, cadangan) dan *flows*, semua koefisien *lag* berpusat di 0: perubahan bulan depan tidak bisa diramal dari masa lalu, dan dalam level ini sama dengan *random walk*. Pengecualian: koefisien *lag* 1 *trade balance* di persamaannya sendiri berpusat di 0,7 (`global tb_prior_mean 0.7`), karena *trade balance* terbukti persisten (autokorelasi *lag* 1 sebesar 0,69). Memusatkan *lag* sendiri pada nilai positif untuk variabel yang persisten mengikuti logika asli Minnesota, yang memusatkan *lag* sendiri variabel level di 1 (Litterman, 1986). Untuk variabel yang stasioner, mean *prior* 0 sesuai saran Bańbura et al. (2010).
2. **Keketatan (λ).** Simpangan baku *prior* koefisien *lag* *l* dari variabel *j* adalah $\lambda / (l \times \sigma_j)$, dengan σ_j^2 varians residual AR(1) variabel *j* (skala terstandar). λ kecil berarti *prior* ketat: koefisien ditahan dekat mean *prior*.
3. ***Lag* jauh lebih ketat.** Pembagi *l* membuat *lag* 2 dua kali lebih ketat daripada *lag* 1. Logikanya: informasi yang lebih lama biasanya kurang relevan.

Kelompok koefisien	Mean *prior*	Simpangan baku *prior* (skala terstandar)	Arti
Konstanta	0	10 (sangat longgar)	Rata-rata ditentukan data
Lag 1	0 (TB sendiri: 0,7)	$\lambda / \sigma_j = 0{,}03 / \sigma_j$	Sangat ketat
Lag 2	0	$\lambda / (2\sigma_j) = 0{,}015 / \sigma_j$	Lebih ketat lagi
Eksogen (DXY, musiman, *dummy*)	0	0,5 (cukup longgar)	Efek DXY ditentukan terutama oleh data
Σ (kovarians *shock*)	Inverse-Wishart dengan derajat bebas $K + 2 = 6$ dan skala diagonal dari varians AR(1); *prior* lemah		

Tabel 6.1 *Prior* BVARX pada spesifikasi terpilih (λ = 0,03, *lag* 2).

λ = 0,03 tergolong sangat ketat. Itu bukan pilihan subjektif: λ dipilih di *validation* dari grid 0,03; 0,05; 0,10; 0,30, dan nilai terkecil memberi akurasi terbaik. Memilih tingkat *shrinkage* dari akurasi *forecast* adalah praktik yang lazim (Carriero, Clark, & Marcellino, 2015), termasuk untuk BVAR kurs (Carriero, Kapetanios, & Marcellino, 2009); alternatifnya memilih lewat marginal *likelihood* (Giannone, Lenza, & Primiceri, 2015). Pesannya konsisten dengan literatur kurs: dinamika *lag* hanya mengandung sedikit informasi yang bisa diramal, sehingga model terbaik adalah yang paling skeptis terhadapnya. Sebaliknya, *prior* eksogen yang longgar membiarkan efek DXY dan *dummy* diestimasi dari data.

> ***Prior* sebagai data tambahan.** Cara mudah memahami *prior* Minnesota: bayangkan ada "pengamatan semu" yang semuanya berkata "koefisien ini nol". Makin kecil λ, makin banyak pengamatan semu itu. Koefisien *posterior* adalah kompromi antara pengamatan semu dan data sungguhan. Data yang konsisten dan kuat (misalnya efek DXY ke kurs) tetap terlihat; pola lemah yang mungkin kebetulan akan tertekan mendekati nol.

6.5 *Posterior*: rumus tertutup

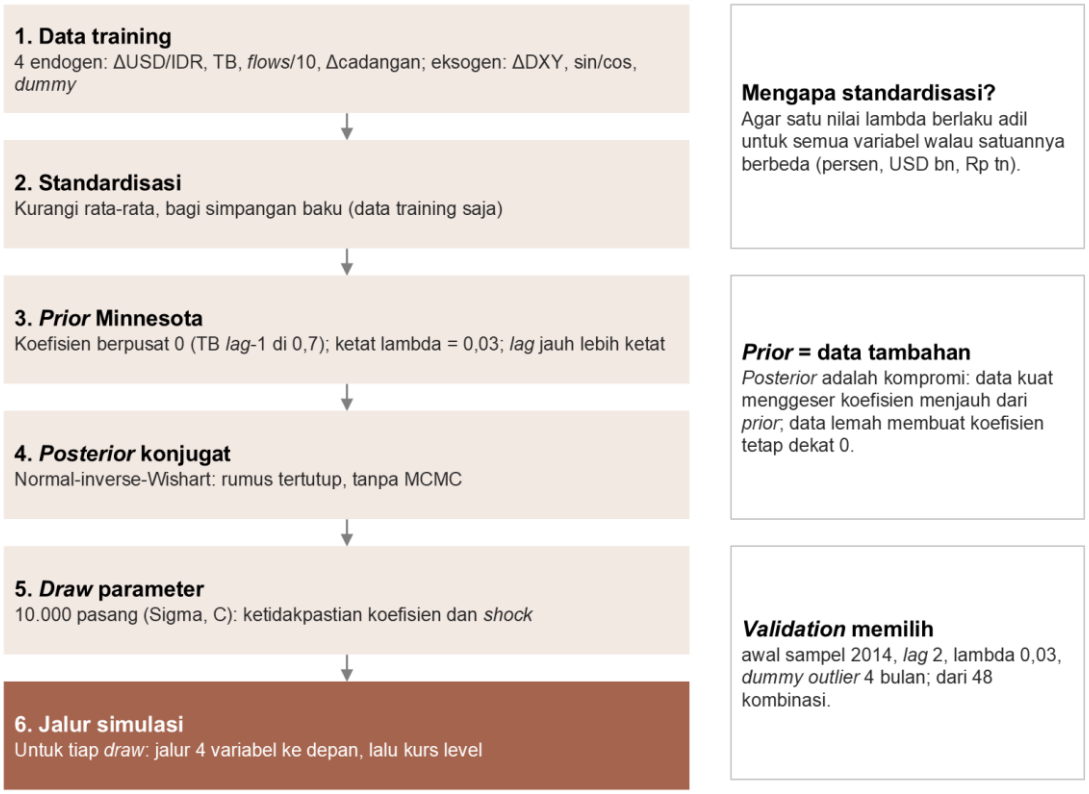
> **Dalam bahasa sederhana.** Bagian ini sama dengan contoh efek DXY di Bab 3.6, hanya dilakukan untuk 72 koefisien sekaligus dalam bentuk matriks. Hasil akhirnya: setiap koefisien adalah rata-rata tertimbang antara *prior* dan estimasi OLS. Rumus di bawah boleh dilewati jika hanya ingin memahami intuisinya.

Prior yang dipakai bersifat **konjugat** (Normal-inverse-Wishart): posteriornya punya bentuk yang sama dengan *prior*, sehingga dapat dihitung dengan rumus langsung tanpa MCMC (Kadiyala & Karlsson, 1997; Koop & Korobilis, 2010; Karlsson, 2013). Dengan Z matriks regresor (konstanta, *lag*, eksogen), Y matriks variabel kiri, C_0 mean *prior*, dan V_0 varians *prior* koefisien:

$$V_n = \left(V_0^{-1} + Z'Z \right)^{-1} \quad C_n = V_n \left(V_0^{-1} C_0 + Z'Y \right)$$

$$S_n = S_0 + \hat{E}'\hat{E} + (C_n - C_0)' \, V_0^{-1} \, (C_n - C_0) \quad \nu_n = \nu_0 + T$$

Perhatikan bentuk C_n: tanpa *prior* ($V_0^{-1} = 0$), $C_n = (Z'Z)^{-1}Z'Y$, yaitu OLS biasa. Dengan *prior*, C_n adalah rata-rata tertimbang antara C_0 dan OLS, dengan bobot presisi *prior* (V_0^{-1}) dan presisi data ($Z'Z$). Inilah wujud matematis dari "kompromi" di atas.



Gambar 6.2 Alur estimasi BVARX (02_bvarx_functions.do, fungsi bv_fit dan bv_draw).

6.6 Dari parameter ke jalur *forecast*

> **Dalam bahasa sederhana.** Untuk membuat satu kemungkinan masa depan: ambil satu set koefisien dari *posterior*, lalu jalankan model bulan demi bulan ke depan sambil menambahkan *shock* acak di setiap bulan. Ulangi 10.000 kali dengan koefisien dan *shock* yang berbeda-beda (Bab 3.7). Kumpulan 10.000 jalur itulah *forecast* BVARX. Alurnya digambarkan di Gambar 1.2.

Forecast BVARX dibuat dengan simulasi. Untuk setiap *draw* ke-*b* (dari 10.000):

1. ***Draw* parameter.** Ambil Σ dari distribusi inverse-Wishart(S_n, ν_n), lalu ambil koefisien C dari distribusi normal matriks dengan mean C_n (Karlsson, 2013). Σ di-*draw* dengan dekomposisi Bartlett (Smith & Hocking, 1972). Langkah ini memasukkan ketidakpastian parameter.
2. **Jalur rata-rata μ.** Dengan koefisien C dan jalur eksogen (DXY, musiman), iterasikan model ke depan tanpa *shock*: *forecast* bulan pertama dipakai sebagai *lag* untuk bulan kedua, dan seterusnya.
3. **Tambah *shock*.** *Shock* masa depan dibangkitkan sebagai $\mathbf{z} \sim N(0, I)$, lalu dirambatkan ke seluruh jalur lewat matriks G: $\mathbf{Y} = \mu + G\mathbf{z}$. Matriks G dibangun dari representasi moving average VAR (Lütkepohl, 2005). Matriks G memuat dua hal: *residual correlation* (dari Σ) dan cara *shock* bulan tertentu merambat ke bulan-bulan berikutnya lewat koefisien *lag* (koefisien moving average).
4. **Kembali ke level.** Jalur dikembalikan ke satuan asli. Perubahan kurs dijumlahkan dari level terakhir: $\ln S_{T+h} = \ln S_T + \Sigma\, \Delta s/100$.

Hasilnya 10.000 jalur untuk keempat variabel. Median dan persentil dihitung per bulan.

> **Mengapa menulis jalur sebagai Y = μ + G z?** Bentuk ini membuat seluruh jalur masa depan (6 bulan × 4 variabel = 24 angka) menjadi fungsi linear dari 24 *shock* standar. Dengan bentuk linear itu, memaksa jalur memenuhi kondisi skenario cukup dengan satu rumus aljabar (Bagian 6.7), tanpa perlu simulasi coba-coba.

6.7 *Forecast* bersyarat (Waggoner dan Zha, 1999)

> **Dalam bahasa sederhana.** Dari 10.000 kemungkinan masa depan, skenario hanya ingin melihat masa depan di mana, misalnya, *flows* April 2027 benar-benar *outflow* Rp74 triliun, jauh di bawah baseline. Daripada membuang jalur yang tidak cocok, setiap jalur disesuaikan sedikit: *shock* acaknya diubah sekecil mungkin sampai *flows* April tepat sesuai asumsi. Karena *shock flows* dan *shock* kurs biasanya bergerak bersama (korelasi −0,36), menurunkan *flows* otomatis ikut mendorong kurs ke arah pelemahan. Besarnya dorongan itu mengikuti pola historis, tidak diatur manual.

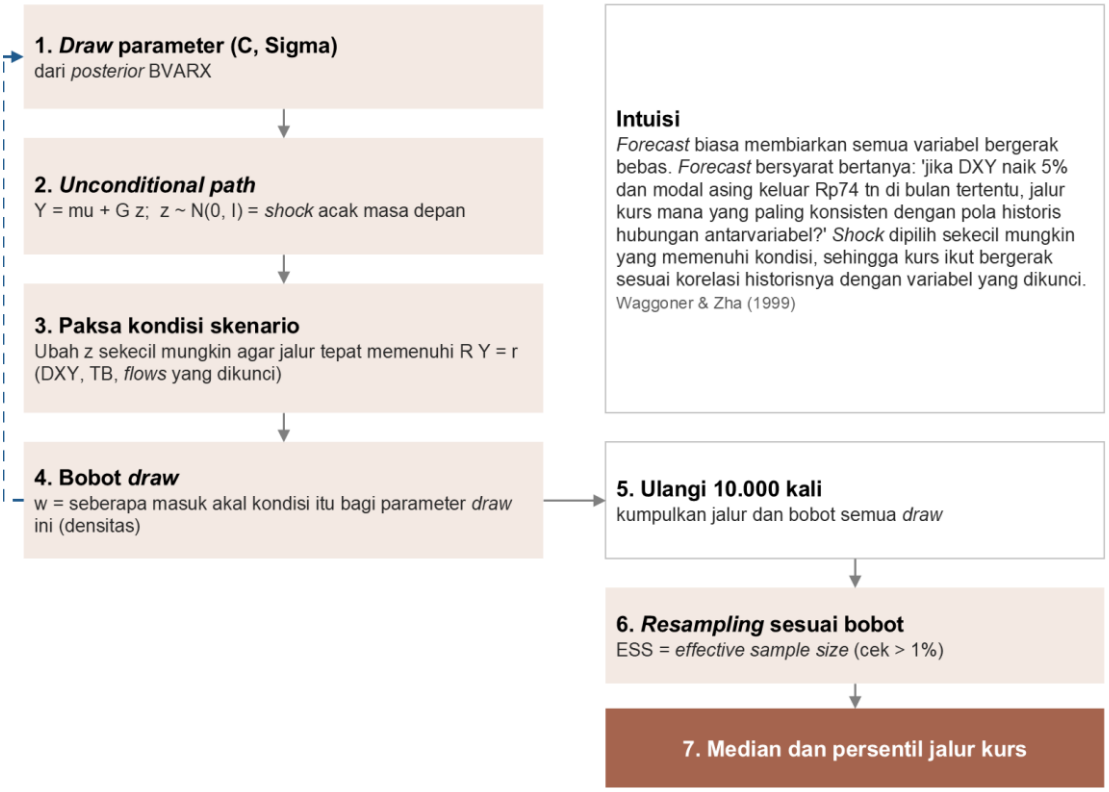
Forecast bersyarat menjawab: *jika variabel tertentu mengikuti jalur yang ditentukan, bagaimana jalur variabel lain?* Di model ini ada dua jenis kondisi:

- **DXY** adalah eksogen, sehingga jalurnya langsung dimasukkan ke $\mathbf{x}_t$. Tidak perlu trik apa pun.
- ***Trade balance* dan *flows*** adalah endogen: nilainya dihasilkan model. Untuk menguncinya pada nilai skenario di bulan tertentu, dipakai metode Waggoner dan Zha (1999); penerapannya untuk analisis skenario dibahas oleh Bańbura, Giannone, dan Lenza (2015).

Kondisi ditulis sebagai $R\mathbf{Y} = \mathbf{r}$: R memilih elemen jalur yang dikunci (misalnya *flows* April 2027), **r** adalah nilai yang diinginkan. Untuk setiap *draw*, *shock* acak **z** dikoreksi dengan perubahan sekecil mungkin agar kondisi terpenuhi tepat:

$$\mathbf{z}^* = \mathbf{z} + (\mathrm{RG})' \left[(\mathrm{RG})(\mathrm{RG})' \right]^{-1} \left(\mathbf{r} - \mathrm{R}\mu - \mathrm{RG}\mathbf{z} \right)$$

Lalu jalur dihitung ulang: **Y** = μ + G**z***. Karena *shock* kurs berkorelasi dengan *shock flows* (lewat Σ dan G), memaksa *flows* lebih rendah otomatis menggeser *shock* kurs ke arah pelemahan. Besarnya mengikuti pola historis, bukan ditentukan manual.



Gambar 6.3 Satu putaran *forecast* bersyarat untuk setiap *draw*, lalu *resampling*.

Bobot *draw* dan ESS

Draw parameter yang berbeda menilai kondisi skenario dengan tingkat "kewajaran" berbeda. Untuk *draw* yang menganggap kondisi itu sangat tidak mungkin, memaksanya terpenuhi memerlukan *shock* ekstrem. Karena itu setiap *draw* diberi bobot w_b = densitas kondisi di bawah *draw* itu, yaitu peluang N(Rμ, RGG'R') menghasilkan **r**. *Draw* lalu di-*resample* sesuai bobot (*sampling-importance resampling*; Rubin, 1988). Catatan: Waggoner dan Zha (1999) memakai sampler Gibbs untuk ketidakpastian parameter; pembobotan importance di sini adalah penyederhanaan yang dipilih untuk model ini.

ESS (*effective sample size*) = $1 / \Sigma w_b^2$ mengukur berapa *draw* yang efektif berkontribusi (Kong, Liu, & Wong, 1994). Jika bobot rata, ESS = 10.000. Jika satu *draw* mendominasi, ESS mendekati 1, dan hasil skenario tidak bisa dipercaya. Model memberi peringatan jika ESS < 100 atau ESS/*draw* < 1%.

Skenario	ESS	ESS / *draw*	*Draw* dengan akar > 1
Baseline	9.795	0,98	0%
Upside	9.179	0,92	0%
Mild Adverse	7.562	0,76	0%
Adverse	4.868	0,49	0%
Severe Adverse	927	0,09	0%

Tabel 6.2 ESS dan stabilitas per skenario (D5_scenario_ess_roots). Semua aman.

ESS Mild Adverse (76%), Adverse, dan Severe Adverse lebih rendah karena *flows* ketiganya dikunci di enam bulan berturut-turut pada *outflow*, jauh dari perkiraan model. Severe Adverse paling rendah: 927 *effective draws* (9%), masih di atas batas aman. Karena itu jumlah *draw* dinaikkan dari 6.000 ke 10.000 di v4.3; dengan 6.000 *draw* ESS-nya hanya sekitar 530. Kolom "akar > 1" adalah persentase *draw* yang sistemnya tidak stabil (akar companion terbesar di atas 1, sehingga jalur bisa meledak; Lütkepohl, 2005); di semua skenario nilainya 0%.

6.8 *Bridge*: memakai data yang sudah teramati

BVARX resmi diestimasi sampai September 2026 (bulan lengkap terakhir), sedangkan *anchor* Oktober 2026. Untuk Oktober, kurs dan *flows* sudah teramati; nilainya dimasukkan sebagai kondisi tetap di semua skenario (*bridge*). DXY Oktober dimasukkan sebagai realisasi eksogen. *Trade balance* dan cadangan Oktober belum ada, sehingga diperkirakan model. Dengan cara ini *forecast* November 2026 dan seterusnya berangkat dari kondisi Oktober yang sebenarnya.

Di *backtest*, logikanya sama: model diestimasi sampai origin − 2, kurs untuk origin − 1 dan origin dimasukkan sebagai kondisi, dan DXY memakai realisasi sampai origin. Setelah origin, DXY diasumsikan datar.

6.9 Efek DXY dan diagnostik

Efek kontemporer DXY

Variabel	Efek +1% DXY	Interval 90%	Kesimpulan
USD/IDR	+0,38%	0,28 s/d 0,49	Rupiah melemah, signifikan
Trade balance	+USD0,02 bn	−0,07 s/d 0,12	Tidak jelas
Net flows	−Rp3,2 tn	−4,9 s/d −1,6	Modal keluar, signifikan
Cadangan devisa	−0,28%	−0,41 s/d −0,15	Cadangan turun, signifikan

Tabel 6.3 Efek kenaikan DXY 1% pada bulan yang sama (D6_dxy_effect). Interval dari distribusi *posterior* koefisien.

Ini hanya efek di bulan yang sama. Efek total dalam skenario lebih besar karena DXY naik bertahap beberapa bulan dan efeknya merambat lewat *lag* dan *residual correlation*.

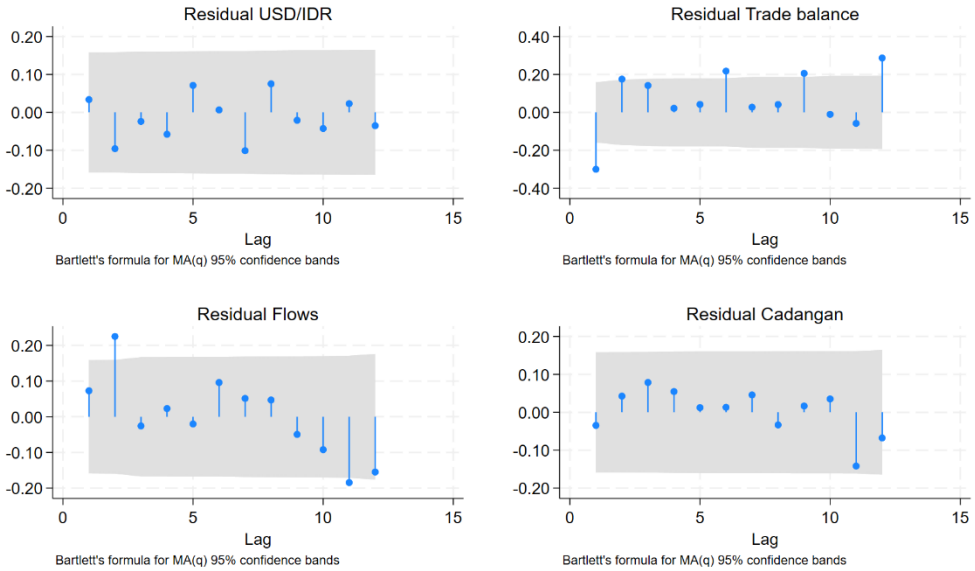
Diagnostik residual

Apa yang diperiksa. Residual adalah bagian data yang tidak bisa dijelaskan model, yaitu "*shock*". Pada model yang baik, *shock* bulan ini tidak bisa diramal dari *shock* bulan-bulan sebelumnya. Jika masih bisa diramal (residual **berautokorelasi**), berarti ada pola yang belum ditangkap model. Uji Ljung-Box (Ljung & Box, 1978) memeriksa hal ini sampai 12 bulan ke belakang; p di bawah 0,05 berarti masih ada pola. Uji normalitas skewness-kurtosis (D'Agostino, Belanger, & D'Agostino, 1990) memeriksa apakah *shock* berbentuk lonceng (normal), sesuai asumsi model.

Persamaan	SD residual	Ljung-Box Q(12) p	Normalitas p	Status
Δ USD/IDR	1,49	0,90	0,09	Bersih
Trade balance	1,36	< 0,001	0,27	Masih berautokorelasi
Net flows	2,36	0,03	0,21	Sedikit berautokorelasi
Δ cadangan	1,91	0,87	0,89	Bersih

Tabel 6.4 Uji residual fit akhir (D3_residual_tests). Ljung-Box H_0: tidak ada autokorelasi sampai *lag* 12. Normalitas: uji skewness-kurtosis.

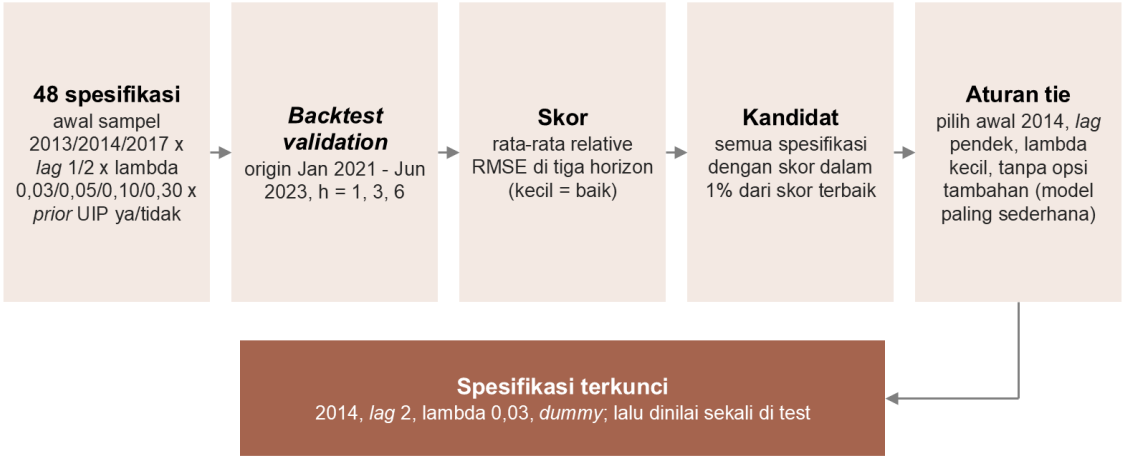
Persamaan kurs, yang paling penting untuk skenario, tidak menunjukkan autokorelasi tersisa (p 0,90). Residual *trade balance* masih berautokorelasi karena *prior* yang sangat ketat (λ = 0,03) menahan koefisien *lag*. Ini kompromi yang disengaja: λ yang lebih longgar memberi koefisien *lag* lebih banyak ruang, tetapi semua nilai λ yang lebih besar menghasilkan skor *validation* yang lebih buruk. *Prior* mean 0,7 untuk *lag* TB sendiri sudah ditambahkan untuk mengurangi masalah ini, tetapi belum menghilangkannya. Dampaknya terutama pada jalur TB tanpa kondisi; di bulan yang dikunci skenario, TB ditentukan asumsi.



Gambar 6.4 Autokorelasi residual empat persamaan. Batang di luar area abu-abu = autokorelasi signifikan di *lag* itu.

6.10 *Validation* BVARX: memilih spesifikasi

Spesifikasi BVARX (awal sampel, *lag*, λ, dan opsi tambahan) dipilih dengan *backtest* di periode *validation*, sebelum periode test disentuh.



Gambar 6.5 Proses pemilihan spesifikasi BVARX (03_validation.do).

Grid yang diuji di run terakhir: awal sampel (2013, 2014, 2017) × *lag* (1, 2) × λ (0,03; 0,05; 0,10; 0,30) × *prior* UIP (ya, tidak) = 48 spesifikasi. Di run sebelumnya juga diuji UST10Y, selisih BI rate − Fed

funds, dan VIX; ketiganya tidak memperbaiki skor, sehingga grid-nya dikunci ke 0 untuk menghemat waktu. *Dummy outlier* terpilih.

***Prior* UIP** (*uncovered interest parity*) adalah opsi yang memasukkan selisih suku bunga BI − Fed ke persamaan kurs dengan koefisien berpusat di 1/12, sesuai teori bahwa mata uang dengan bunga lebih tinggi cenderung terdepresiasi sebesar selisih bunganya (Engel, 2014). Secara empiris hubungan ini sering tidak berlaku dalam jangka pendek (Fama, 1984), sehingga di sini ia hanya diuji sebagai opsi *prior*. Opsi ini tidak terpilih.

Aturan tie ditetapkan sebelum melihat hasil: jika beberapa spesifikasi punya skor dalam 1% dari yang terbaik, pilih awal sampel 2014, lalu *lag* lebih pendek, lalu λ lebih kecil, lalu tanpa opsi tambahan. Logikanya: jika akurasi praktis sama, pilih model paling sederhana.

Spesifikasi terpilih	Nilai
Awal sampel	Januari 2014
Lag	2
λ	0,03
Eksogen tambahan	*Dummy outlier* (4 bulan) (tanpa UST, selisih bunga, VIX, UIP)
Skor *validation*	0,927 (relative RMSE 0,98 / 0,93 / 0,87 untuk h = 1 / 3 / 6)

Tabel 6.5 Spesifikasi BVARX terkunci (T2_validation_grid, S0_settings).

Di periode test, BVARX tidak mempertahankan keunggulannya: relative RMSE 1,04 / 1,02 / 0,96, dengan interval *bootstrap* yang memuat 1. Karena itulah BVARX tidak dipakai untuk baseline, tetapi hanya untuk persentase pergeseran skenario. Untuk peran itu yang dibutuhkan adalah arah dan besaran hubungan antarvariabel yang masuk akal (Tabel 6.3), bukan akurasi *forecast* titik.

7. Skenario dan Penggabungan

7.1 Apa itu skenario di model ini

Skenario adalah jawaban atas pertanyaan "bagaimana jika". Setiap skenario terdiri dari tiga asumsi jalur ke depan:

- **DXY**: berapa persen dolar global menguat atau melemah dibanding bulan *anchor*, di setiap bulan.
- ***Trade balance***: berapa USD miliar di atas atau di bawah perkiraan baseline, di bulan-bulan tertentu.
- ***Net flows* asing**: berapa Rp triliun di atas atau di bawah perkiraan baseline di bulan-bulan tertentu, atau (untuk Adverse dan Severe Adverse sejak v4.3) berapa *outflow* asing di setiap bulan.

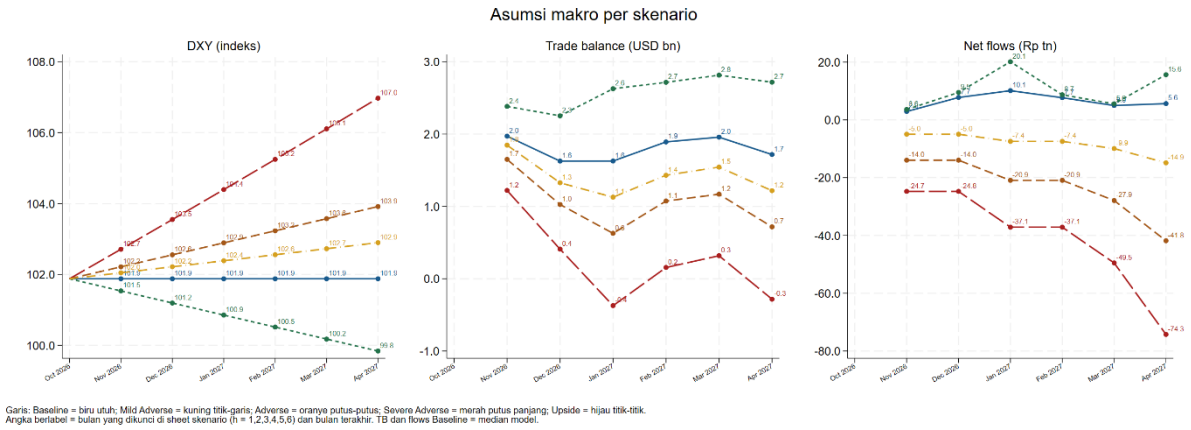
Skenario **bukan** ramalan bahwa kejadian itu akan terjadi, dan bukan estimasi efek kausal murni. Pendekatannya adalah analisis skenario dengan *forecast* bersyarat (Waggoner & Zha, 1999; Bańbura, Giannone, & Lenza, 2015). Skenario adalah proyeksi kurs yang konsisten dengan asumsi tersebut dan dengan pola hubungan historis antarvariabel.

Skenario	DXY s/d Apr-27	*Trade balance* vs baseline	*Net flows* asing (Rp tn)	Narasi
Baseline	datar (0%)	jalur model	jalur model	Tidak ada *shock* tambahan
Upside	−2%	+USD1 bn	+10 di atas baseline (Jan dan Apr)	Dolar melemah, ekspor membaik, modal masuk
Mild Adverse	+1%	−USD0,5 bn	*outflow* tiap bulan: 4,96 / 4,96 / 7,44 / 7,44 / 9,92 / 14,87 (total 49,58)	Dolar menguat ringan, modal keluar terbatas
Adverse	+2%	−USD1 bn	*outflow* tiap bulan: 13,95 / 13,95 / 20,92 / 20,92 / 27,90 / 41,84 (total 139,48)	Dolar menguat moderat, modal keluar berkelanjutan
Severe Adverse	+5%	−USD2 bn	*outflow* tiap bulan: 24,75 / 24,75 / 37,13 / 37,13 / 49,51 / 74,26 (total 247,53)	Dolar menguat tajam, modal keluar besar dan makin dalam

Tabel 7.1 Asumsi v4.3 (November 2026 – April 2027). DXY bergerak bertahap (geometrik) menuju angka akhir di April 2027; *trade balance* dikunci di Januari dan April 2027. *Flows* Upside digeser +Rp10 triliun dari baseline di Januari dan April; *flows* Mild Adverse, Adverse, dan Severe Adverse dikunci pada *outflow* absolut setiap bulan (estimasi dampak MSCI).

Besaran DXY dan *trade balance* mengikuti contoh ilustratif di manual asli model. Sejak v4.3, *flows* Mild Adverse, Adverse, dan Severe Adverse memakai jalur *outflow* absolut, total Rp49,58, Rp139,48, dan Rp247,53 triliun dalam enam bulan. *Outflow* bulanan terbesar (Rp74 triliun, Severe Adverse April 2027) masih di bawah rekor historis Maret 2020 (Rp120 triliun). Upside tetap +Rp10 triliun di atas baseline pada dua bulan, sehingga Upside dan Adverse tidak lagi simetris. Sebagai pembanding: pergerakan rupiah enam bulanan sejak 2014 punya median +1,8%, persentil ke-75 +4,5%, ke-90 +7,3%, dan ke-95 +8,3%. Mild Adverse (+4,3% dari *anchor*) setara kira-kira persentil 75, Adverse (+7,1%) kira-kira persentil 90, dan Severe Adverse (+11,3%) melampaui persentil 95.

Asal angka *outflow*. Angka *outflow* berasal dari estimasi dampak usulan reklasifikasi Indonesia ke Standalone Market oleh MSCI (bahan DEN 19 Oktober 2026; file `Estimasi_Outflow_MSCI_6_Bulan.xlsx`). Potensi *outflow* saham jika Indonesia menjadi Standalone adalah US$7,96 / 14,86 / 21,76 miliar untuk skenario ringan / tengah / berat. Dana pasif MSCI (US$4,5 miliar) tidak dihitung karena baru keluar setelah tanggal efektif, sesudah keputusan MSCI paling lambat 30 Juni 2027. Separuh sisanya diasumsikan dijual dalam enam bulan, sehingga *outflow* saham US$1,73 / 5,18 / 8,63 miliar. Ditambah penjualan SBN asing 2% / 5% / 10% dari kepemilikan US$50 miliar, totalnya US$2,73 / 7,68 / 13,63 miliar, atau Rp49,58 / 139,48 / 247,53 triliun pada kurs JISDOR 2 November 2026 (Rp18.161). Total ini dibagi ke enam bulan dengan bobot 10 / 10 / 15 / 15 / 20 / 30%, yang meningkat menjelang akhir konsultasi MSCI 30 April 2027. Semua hasil penjualan diasumsikan direpatriasi; *inflow* lain dan dampak lanjutan tidak dimasukkan. Porsi 50%, persentase SBN, dan bobot bulanan adalah asumsi analisis.



Gambar 7.1 Jalur DXY, *trade balance*, dan *flows* per skenario. Titik berlabel = bulan yang dikunci.

7.2 Mengisi asumsi: sheet `scenario_inputs`

Semua asumsi skenario diisi di sheet `scenario_inputs` pada `input/Database_Rupiah_Bulanan.xlsx`. Tidak ada angka skenario yang perlu diubah di do-file. Sheet berisi satu baris untuk setiap kombinasi skenario × bulan ke-*h*: 5 skenario × 6 bulan = 30 baris.

Kolom	Isi	Aturan
A `scenario`	Baseline, Adverse, Upside, Severe Adverse, Mild Adverse	Nama harus persis seperti ini; kelimanya wajib ada
B `h`	Bulan ke-*h* setelah *anchor* (1 = bulan pertama *forecast*)	Lengkap 1 sampai 6 untuk setiap skenario
C `dxy_pct`	DXY kumulatif dibanding DXY bulan *anchor*, dalam persen	Wajib diisi semua baris. 2 berarti DXY 2% di atas *anchor*
D `tb_shift_usdbn`	*Trade balance* bulan itu = median baseline BVARX + angka ini (USD miliar)	Kosong = bulan itu tidak dikunci
E `flows_shift_idrtn`	*Net flows* bulan itu = median baseline BVARX + angka ini (Rp triliun)	Kosong = bulan itu tidak dikunci
F `bulan (info)`	Label bulan dari sel *anchor* O3	Hanya tampilan; tidak dibaca kode

Tabel 7.2 Kolom sheet scenario_inputs. Kolom H–L berisi tabel bantu angka asli (lihat di bawah); petunjuk di kolom N.

scenario	h	dxy_pct	tb_shift_usdbn	flows_shift_idrtn	bulan
Adverse	1	0,33		−16,85	Nov-26
Adverse	2	0,66		−21,70	Des-26
Adverse	3	1,00	−1,0	−31,04	Jan-27
Adverse	4	1,34		−28,60	Feb-27
Adverse	5	1,68		−32,88	Mar-27
Adverse	6	2,00	−1,0	−47,47	Apr-27

Tabel 7.3 Isi kolom C–E untuk Adverse (v4.3). DXY naik bertahap menuju +2%; TB dikunci 1 miliar di bawah baseline pada Januari dan April. Kolom E adalah selisih *outflow* target (kolom K, misalnya −13,95 untuk November) dengan baseline model (kolom J, +2,90).

Tabel bantu: mengisi dengan angka asli

Kolom C–E tidak perlu diketik langsung. Isinya rumus dari tabel bantu di kolom H–L, tempat target diisi dalam satuan aslinya: *trade balance* dalam USD miliar (kolom I), *net flows* dalam Rp triliun (kolom K), dan DXY dalam level indeks (kolom L). Kolom H dan J menampilkan baseline model (median baseline BVARX dari `T9_scenario_paths_all`), dan sel O4 berisi DXY pada bulan *anchor*. Rumusnya: `tb_shift` = I − H, `flows_shift` = K − J, dan `dxy_pct` = (L ÷ O4 − 1) × 100. Target yang dikosongkan berarti bulan itu tidak dikunci.

Prinsip mengisi

- **Tanda.** Untuk TB dan *flows*, angka negatif berarti lebih buruk bagi rupiah. Untuk DXY, angka positif berarti dolar lebih kuat, yang juga lebih buruk bagi rupiah.
- **Relatif terhadap baseline.** Geser TB dan *flows* dihitung dari median baseline BVARX di bulan itu. Contoh: median TB baseline Januari 2027 = USD1,63 miliar, sehingga Adverse (−1,0) mengunci TB Januari di USD0,63 miliar. Nilai yang benar-benar dikunci tercatat di `T10_scenario_inputs`.
- **Target absolut.** *Outflow* Mild Adverse, Adverse, dan Severe Adverse diisi sebagai angka asli di kolom K (misalnya −41,84 untuk Adverse April 2027). Kolom E otomatis menjadi selisih terhadap baseline. Saat baseline (kolom J) diperbarui, isi K tidak diubah, sehingga yang dikunci tetap angka *outflow* yang sama.
- **Mengunci lebih banyak bulan** membuat skenario lebih tegas tetapi menurunkan ESS. Mild Adverse, Adverse, dan Severe Adverse v4.3 mengunci *flows* di keenam bulan; ESS Severe Adverse turun ke 9% (927 dari 10.000 *draw*), masih aman. Periksa D5 setiap kali asumsi diubah.
- **DXY Baseline** biasanya 0. Jika diisi (misalnya sesuai konsensus), semua skenario dihitung relatif terhadap jalur DXY baseline itu, karena efek skenario adalah rasio terhadap baseline BVARX.
- **Periode baru.** Kolom *h* selalu relatif terhadap *anchor*. Saat data November 2026 masuk, *h* = 1 otomatis menjadi Desember 2026. Perbarui sel O3 (bulan *anchor*), O4 (DXY pada *anchor*), dan baseline model di kolom H dan J. Target absolut seperti *outflow* perlu digeser satu baris agar tetap jatuh di bulan kalender yang dimaksud.

> **Validasi otomatis.** `06_final_scenarios.do` memeriksa isi sheet sebelum menghitung: nama skenario dikenal, *h* bilangan bulat 1–6, setiap skenario × *h* muncul tepat sekali, dan `dxy_pct` terisi.

> Jika ada yang salah, run berhenti dengan pesan yang menjelaskan masalahnya. Isian TB/*flows* pada baris Baseline diabaikan dengan catatan di log. Input yang dipakai disimpan ke `output/tables/T0_scenario_inputs.csv`.

7.3 Bagaimana skenario merambat ke kurs

Untuk setiap skenario, BVARX dijalankan ulang dengan jalur DXY dari sheet sebagai eksogen dan kondisi TB/*flows* sebagai kunci Waggoner-Zha (Bagian 6.7). Kurs merespons lewat tiga kanal:

1. **Efek langsung DXY** di bulan yang sama (sekitar 0,38% per 1% DXY).
2. ***Residual correlation*.** Mengunci *flows* lebih rendah berarti ada *shock flows* negatif; karena *shock flows* dan kurs berkorelasi −0,36, kurs ikut digeser ke arah pelemahan.
3. **Dinamika *lag*.** Perubahan di bulan *t* memengaruhi bulan berikutnya lewat koefisien *lag*. Karena *prior* sangat ketat, kanal ini kecil.

Bulan	Upside	Mild Adverse	Adverse	Severe Adverse
Nov 2026	−0,16%	+0,27%	+0,49%	+1,01%
Des 2026	−0,34%	+0,68%	+1,28%	+2,16%
Jan 2027	−0,78%	+1,13%	+2,13%	+3,83%
Feb 2027	−0,91%	+1,60%	+2,95%	+5,21%
Mar 2027	−1,14%	+1,89%	+3,82%	+6,81%
Apr 2027	−1,54%	+2,46%	+5,19%	+9,25%

Tabel 7.4 Efek skenario dari BVARX: median skenario ÷ median baseline BVARX − 1 (T15_hybrid_scenarios, kolom scen_shift_pct).

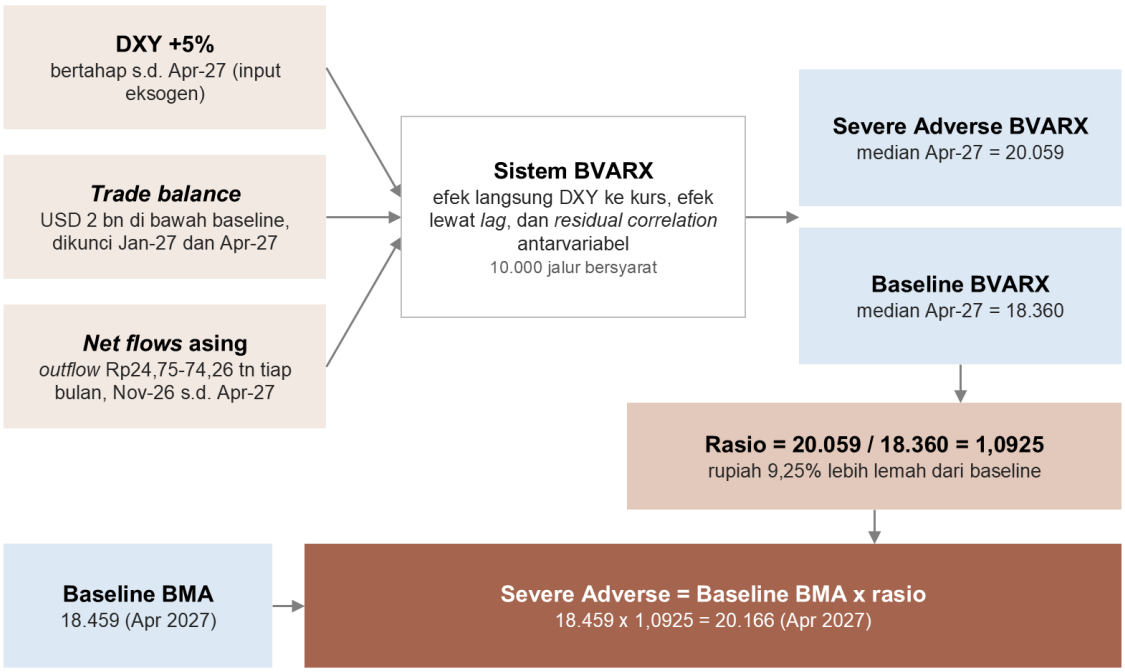
Efek Mild Adverse, Adverse, dan Severe Adverse membesar setiap bulan karena *outflow* dikunci di setiap bulan dan makin besar menjelang April. Upside bergeser terutama di Januari dan April, saat TB dan *flows*-nya dikunci. Kontribusi DXY bisa diperkirakan kasar: DXY +5% × 0,38 ≈ 1,9 poin; sisanya, sekitar 7,3 poin pada April 2027, datang dari *outflow* dan *trade balance*. Model ini linear: setiap Rp100 triliun *flows* di luar perkiraan baseline menggeser kurs sekitar 2,3%, berapa pun besarnya, sehingga efek kepanikan pada *outflow* ekstrem tidak tertangkap (Bab 11).

7.4 Rumus penggabungan

Untuk setiap skenario *s* dan bulan *m*:

$$\text{Skenario}(s, m) = \text{Baseline BMA}(m) \times [\ \text{median skenario BVARX}(s, m) \div \text{median baseline BVARX}(m)\ ]$$

Rentang 80% dan 95% skenario dihitung dengan mengalikan batas-batas rentang BMA dengan rasio yang sama.



Gambar 7.2 Contoh lengkap Severe Adverse untuk April 2027, dari asumsi sampai angka akhir.

Mengapa rasio, bukan selisih rupiah?

Level baseline BMA (18.459) dan BVARX (18.360) berbeda. Efek skenario yang stabil adalah efek **relatif** (persen), karena model bekerja dalam perubahan log. Rasio memindahkan "Severe Adverse 9,25% lebih lemah dari baseline" apa adanya ke baseline BMA. Selisih rupiah (20.059 − 18.360 = 1.699) akan menjadi 9,20% bila ditambahkan ke 18.459. Bedanya kecil di sini, tetapi rasio konsisten secara konsep.

Mengapa tidak memakai BVARX saja untuk skenario?

Karena baseline BVARX kurang akurat daripada BMA (Bab 8). Penggabungan memakai bagian terbaik dari setiap model: level dan rentang dari model yang paling akurat, dan respons terhadap asumsi dari model yang punya struktur antarvariabel. Rasio penggabungan ini adalah rancangan khusus model ini, bukan metode baku dari literatur. Yang paling dekat adalah literatur kombinasi *forecast* (Bates & Granger, 1969; Timmermann, 2006), tetapi di sini kedua model tidak dirata-rata: satu model menentukan level, model lain menentukan pergeseran.

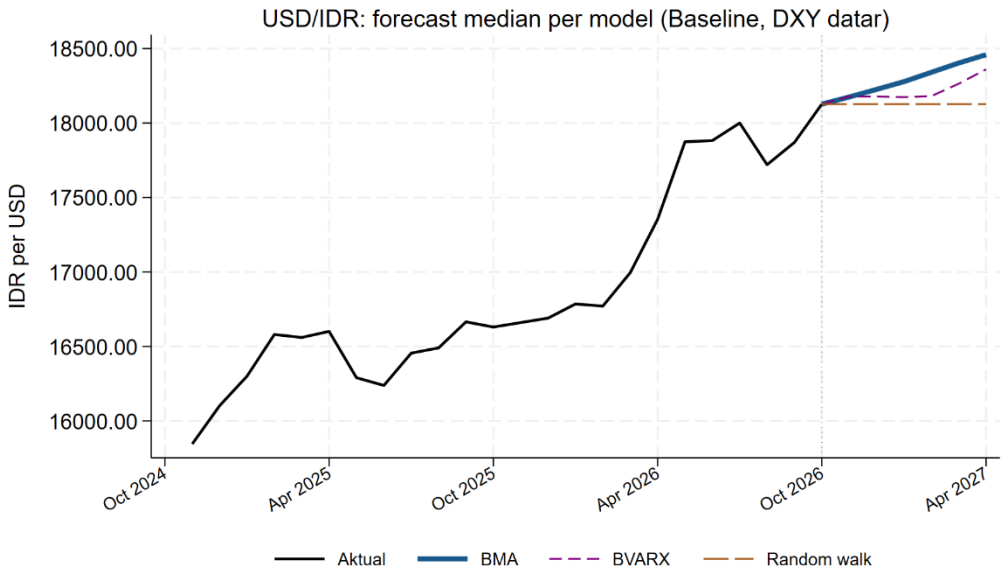
Konsekuensi yang perlu diingat

- Rentang skenario memuat ketidakpastian *forecast* BMA, tetapi tidak menambah ketidakpastian dari jalur skenario itu sendiri. Rentang skenario karena itu tidak lebih lebar dari rentang baseline, dalam persen.
- BMA dan BVARX adalah dua model dengan struktur berbeda. Rasio dari BVARX diasumsikan berlaku juga di sekitar baseline BMA. Asumsi ini wajar selama kedua baseline tidak berbeda jauh; saat ini selisihnya 0,5%.

7.5 Hasil skenario

Bulan	Baseline (BMA)	Upside	Mild Adverse	Adverse	Severe Adverse
Nov 2026	18.175	18.145	18.225	18.264	18.358
Des 2026	18.226	18.164	18.349	18.458	18.620
Jan 2027	18.278	18.135	18.484	18.668	18.978
Feb 2027	18.340	18.172	18.634	18.881	19.296
Mar 2027	18.403	18.193	18.751	19.105	19.656
Apr 2027	18.459	18.174	18.914	19.417	20.166
Rentang 80% Apr 2027	*17.508–19.461*	*17.238–19.161*	*17.939–19.941*	*18.417–20.472*	*19.128–21.262*

Tabel 7.5 Median USD/IDR per skenario (T15_hybrid_scenarios). *Anchor* Oktober 2026 = 18.127.



Gambar 7.3 Baseline BMA dibanding *forecast* baseline BVARX dan *random walk*. BVARX hanya ditampilkan sebagai pembanding.

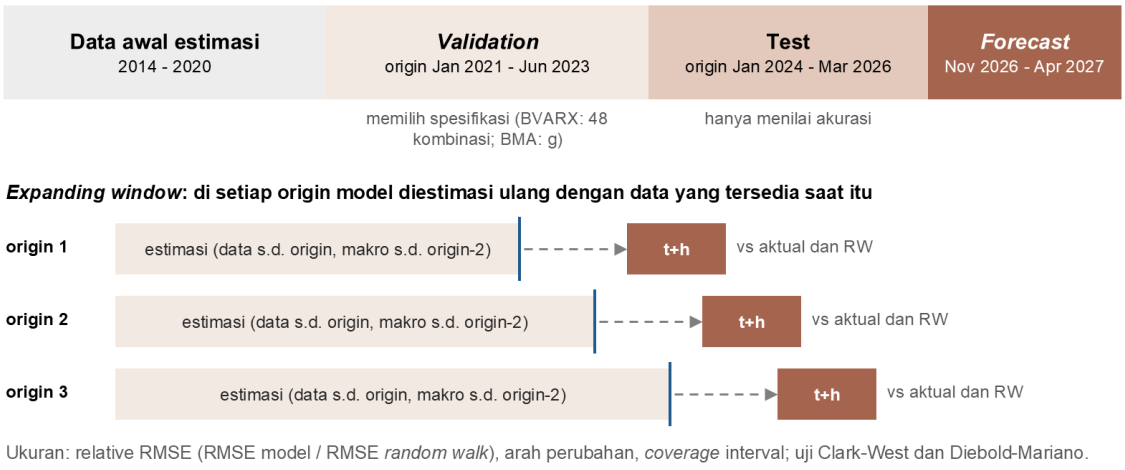
8. Evaluasi: Seberapa Bisa Dipercaya

8.1 Desain: *validation* dan test

Data *backtest* dibagi dua periode yang tidak tumpang tindih:

- ***Validation*** (origin Januari 2021 – Juni 2023): dipakai untuk *memilih* spesifikasi, yaitu λ, *lag*, dan awal sampel BVARX, serta *g* BMA. Target terakhirnya Desember 2023.
- **Test** (origin Januari 2024 – Maret 2026, 27 origin per horizon): dipakai *hanya* untuk menilai akurasi spesifikasi yang sudah dikunci.

Pemisahan ini mencegah model "dipilih karena kebetulan bagus di periode yang dinilai" (Hastie et al., 2009). Jika spesifikasi dipilih dan dinilai di periode yang sama, skor akan bias optimistis.



Gambar 8.1 Pembagian periode dan prosedur *expanding window*.

Di setiap origin, model diestimasi ulang dengan data sampai origin (data makro sampai origin − 2), lalu meramal h = 1, 3, dan 6 bulan. *Forecast* dibandingkan dengan realisasi dan dengan *random walk*. Jendela estimasi terus memanjang seiring origin bergeser (*expanding window*; West, 1996).

8.2 Ukuran akurasi

Ukuran	Rumus / definisi	Cara membaca
RMSE	√ rata-rata (aktual − *forecast*)², dalam rupiah	Kesalahan rata-rata; kesalahan besar dihukum lebih berat
Relative RMSE	RMSE model ÷ RMSE *random walk*	< 1: model lebih akurat dari *random walk*
MAE	rata-rata |aktual − *forecast*|	Kesalahan rata-rata tanpa penekanan pada kesalahan besar
Akurasi arah	Persentase origin di mana arah *forecast* (naik/turun dari level origin) sama dengan arah realisasi	50% = setara *random guess* (Pesaran & Timmermann, 1992)

Ukuran	Rumus / definisi	Cara membaca
Coverage 80% / 95%	Persentase realisasi yang jatuh di dalam rentang 80% / 95%	Ideal mendekati 0,80 / 0,95 (Christoffersen, 1998). Terlalu rendah = rentang terlalu sempit

Tabel 8.1 Ukuran akurasi *forecast*.

8.3 Uji statistik: apakah keunggulan itu kebetulan?

Relative RMSE 0,94 belum tentu berarti model benar-benar lebih baik; dengan 27 *forecast*, selisih kecil bisa terjadi karena kebetulan. Dua uji dipakai:

> **Dalam bahasa sederhana.** Kedua uji bertanya hal yang sama: "jika sebenarnya model dan *random walk* sama akuratnya, seberapa besar peluang kita melihat selisih kesalahan sebesar ini hanya karena kebetulan?" Peluang itu adalah nilai p. Nilai p kecil (di bawah 0,05) berarti selisihnya sulit dijelaskan sebagai kebetulan, sehingga keunggulan model dianggap nyata.

Diebold-Mariano dengan koreksi HLN

Hitung selisih kerugian setiap origin: d_t = (kesalahan model)² − (kesalahan RW)². Jika kedua *forecast* sama akurat, rata-rata d_t nol. Statistik DM = rata-rata d ÷ simpangan bakunya. Untuk $h > 1$, *forecast* yang berurutan saling tumpang tindih sehingga d_t berautokorelasi; simpangan baku dikoreksi dengan Newey-West (*lag* $h - 1$; Newey & West, 1987). Harvey, Leybourne, dan Newbold (1997) menambahkan koreksi untuk sampel kecil dan memakai distribusi *t*. Uji dua sisi.

Clark-West

Random walk adalah kasus khusus BMA: jika semua koefisien dan konstanta nol, BMA sama dengan *random walk*. Untuk model bersarang seperti ini, uji DM cenderung terlalu konservatif, karena model besar harus mengestimasi parameter yang mungkin sebenarnya nol, dan noise estimasi itu menambah kesalahannya. Clark dan West (2007) mengoreksi hal ini dengan menambahkan kembali bagian noise tersebut:

$$f_t = (\text{aktual} - \text{RW})^2 - [\,(\text{aktual} - \text{model})^2 - (\text{model} - \text{RW})^2\,]$$

lalu menguji apakah rata-rata f_t positif (uji satu sisi, varians Newey-West). Clark-West adalah uji utama untuk BMA vs *random walk*.

Bootstrap blok (BVARX)

Untuk BVARX, interval kepercayaan relative RMSE dihitung dengan *circular block bootstrap* (Künsch, 1989; Politis & Romano, 1992): pasangan (aktual, *forecast*) di-resample dalam blok 3, 6, atau 12 bulan berurutan (menjaga autokorelasi), 1.000 kali. Jika interval 95% memuat 1, belum ada bukti kuat bahwa model berbeda dari *random walk*.

8.4 Hasil: baseline BMA

Bagian ini merangkum hasil uji. Tabel lengkap, termasuk MAE, RMSE log, *bootstrap*, dan hasil *validation*, ada di Bab 9.6.

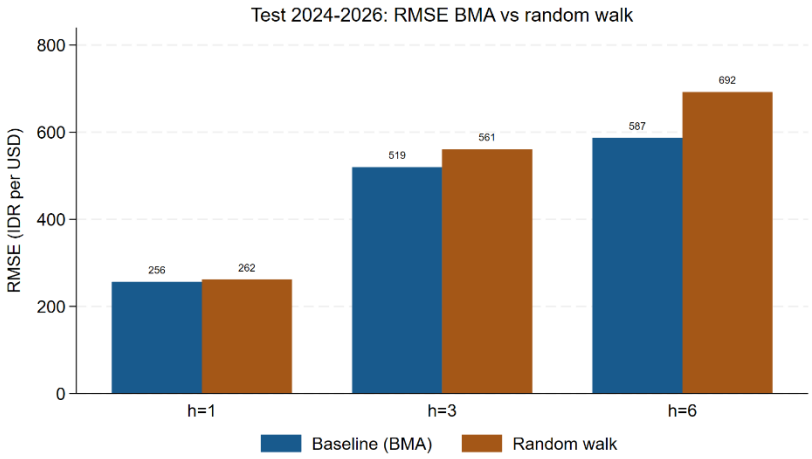
Horizon	RMSE BMA	RMSE RW	Rel. RMSE	Clark-West p	DM p	Arah benar	*Coverage* 80%	*Coverage* 95%
1 bulan	256	262	0,98	0,17	0,49	63%	0,93	0,96

Horizon	RMSE BMA	RMSE RW	Rel. RMSE	Clark-West p	DM p	Arah benar	*Coverage* 80%	*Coverage* 95%
3 bulan	519	561	0,93	0,04	0,22	74%	0,85	0,96
6 bulan	587	692	0,85	0,02	0,24	78%	0,81	1,00

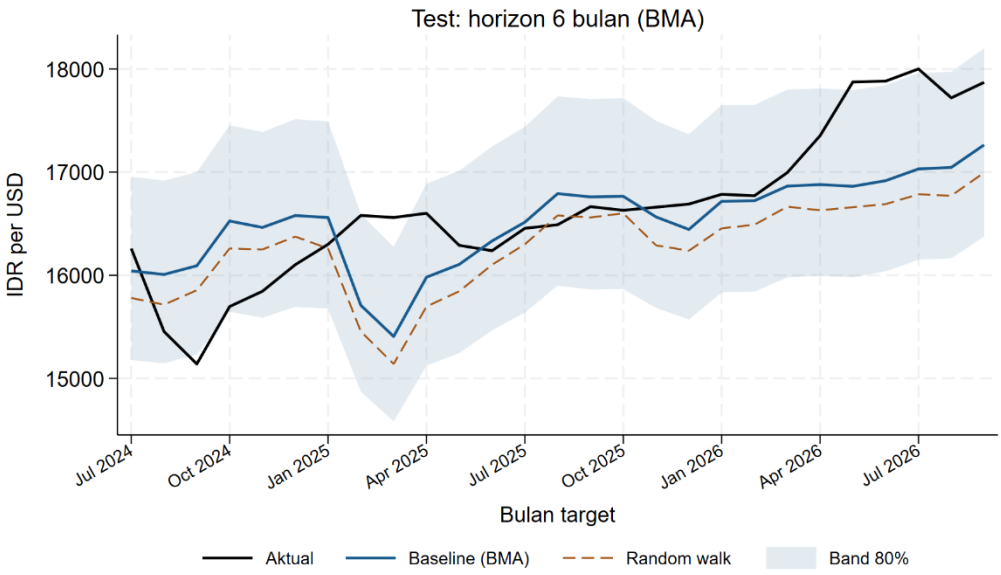
Tabel 8.2 Test 2024–2026, 27 *forecast* per horizon (B2_bma_test_scores, T17_hybrid_baseline_test). RMSE dalam rupiah per USD.

Cara membaca:

- BMA lebih akurat dari *random walk* di ketiga horizon, dan keunggulannya membesar dengan horizon: 2% di h = 1, 7% di h = 3, 15% di h = 6.
- Keunggulan di 6 bulan dan 3 bulan signifikan pada 5% (Clark-West p 0,016 dan 0,040), dan di 1 bulan belum terbukti (p 0,17).
- Uji DM tidak signifikan di semua horizon. Ini wajar untuk sampel 27 *forecast* dan model bersarang; DM dilaporkan sebagai pelengkap.
- Arah benar 63–78%, lebih baik dari 50%.
- *Coverage* mendekati target: rentang 80% memuat realisasi 81–93% dari waktu. Rentang tidak terlalu sempit.



Gambar 8.2 RMSE BMA dan *random walk* di periode test.



Gambar 8.3 *Backtest* horizon 6 bulan: realisasi (hitam), *forecast* BMA (biru) dengan band 80%, dan *random walk* (putus-putus). *Random walk* selalu tertinggal saat rupiah terdepresiasi; BMA ikut naik karena *drift*.

8.5 Hasil: BVARX dan perbandingan

Model	Val h=1	Val h=3	Val h=6	Test h=1	Test h=3	Test h=6
BMA (baseline)	0,98	0,98	0,92	**0,98**	**0,93**	**0,85**
BVARX	0,98	0,93	0,87	1,04	1,02	0,96
Random walk tanpa *drift*	1,00	1,00	1,00	1,00	1,00	1,00

Tabel 8.3 Relative RMSE terhadap *random walk*, *validation* dan test.

BVARX unggul di *validation* tetapi kalah dari *random walk* di test untuk h = 1 dan 3. Interval *bootstrap* 95% relative RMSE BVARX di test memuat 1 di semua horizon (misalnya 0,79–1,22 untuk h = 6 dengan blok 6). *Coverage* 80% BVARX juga terlalu rendah di h = 6 (0,70), artinya rentangnya terlalu sempit. Dua temuan ini menjadi alasan BVARX tidak dipakai untuk baseline maupun rentang.

BMA adalah satu-satunya model yang lebih akurat dari *random walk* di keenam kombinasi periode × horizon. Selisihnya kecil (2–15%), sejalan dengan literatur: kurs sulit diramal, dan keunggulan yang realistis memang tidak besar.

> **Catatan kejujuran metodologis.** Beberapa keputusan desain (memakai model perubahan, *dummy*, BMA, dan cara menyusun skenario) diambil setelah melihat hasil test 2024–2026 dari versi-versi sebelumnya. Akibatnya angka test di atas cenderung sedikit optimistis. Bukti yang benar-benar bersih hanya bisa datang dari data baru (Oktober 2026 dan seterusnya) dengan spesifikasi yang dibekukan. Contoh pertama: *forecast* v4.2 untuk Oktober 2026 (*anchor* September) adalah 17.927 dengan rentang 80% 17.411–18.458; realisasinya 18.127, masih di dalam rentang tetapi di atas median. Dianjurkan mencatat *forecast* setiap bulan dan membandingkannya dengan realisasi (Bab 10).

9. Hasil Lengkap

Bab ini memuat semua hasil model secara utuh, bukan potongan. Setiap tabel disertai tiga keterangan: **sumber** (file output), **apa yang ditunjukkan**, dan **artinya**. Semua angka berasal dari run 2 November 2026 (v4.3, data sampai Oktober 2026) dengan *anchor* Oktober 2026 (USD/IDR = 18.127) dan bisa dicek ulang di folder `output/` atau di workbook `output/rupiah_bvarx_results.xlsx` (satu sheet per tabel).

Bagian	Isi	File sumber
9.1	*Forecast* per skenario, lengkap per bulan	T15_hybrid_scenarios
9.2	Asumsi skenario yang benar-benar dipakai	T0, T9, T10, T11
9.3	Hasil mentah BVARX (sebelum digabung)	T8_scenarios
9.4	Hasil BMA: *forecast*, PIP, model teratas	B4, B5, B6
9.5	*Forecast* semua model dan pembanding	T12, T13, T19
9.6	Akurasi lengkap: test, *bootstrap*, *validation*	B2, T17, T4, T5, T6, T2
9.7	Diagnostik lengkap	D1, D3, D4, D5, D6
9.8	Kesimpulan dari semua hasil	

Tabel 9.0 Isi bab ini.

9.1 *Forecast* per skenario, lengkap

Sumber: `tables/T15_hybrid_scenarios.csv`. **Apa yang ditunjukkan:** untuk setiap skenario dan bulan: median USD/IDR, rentang 80% dan 95%, persen perubahan dibanding *anchor* (18.127), dan efek skenario (persen di atas atau di bawah baseline, berasal dari BVARX).

Bulan	Median	Rentang 80%	Rentang 95%	vs *anchor*
Nov 2026	18.175	17.653 – 18.712	17.382 – 19.003	+0,26%
Des 2026	18.226	17.526 – 18.954	17.166 – 19.351	+0,54%
Jan 2027	18.278	17.487 – 19.104	17.083 – 19.557	+0,83%
Feb 2027	18.340	17.496 – 19.226	17.064 – 19.712	+1,18%
Mar 2027	18.403	17.495 – 19.358	17.032 – 19.884	+1,52%
Apr 2027	18.459	17.508 – 19.461	17.025 – 20.013	+1,83%

Tabel 9.1 Baseline (BMA).

Bulan	Median	Rentang 80%	Rentang 95%	vs *anchor*	Efek skenario
Nov 2026	18.145	17.624 – 18.682	17.354 – 18.973	+0,10%	−0,16%
Des 2026	18.164	17.467 – 18.890	17.108 – 19.286	+0,21%	−0,34%
Jan 2027	18.135	17.351 – 18.955	16.949 – 19.404	+0,04%	−0,78%

Bulan	Median	Rentang 80%	Rentang 95%	vs *anchor*	Efek skenario
Feb 2027	18.172	17.335 – 19.050	16.908 – 19.531	+0,25%	−0,91%
Mar 2027	18.193	17.296 – 19.138	16.839 – 19.657	+0,37%	−1,14%
Apr 2027	18.174	17.238 – 19.161	16.762 – 19.705	+0,26%	−1,54%

Tabel 9.2 Upside.

Bulan	Median	Rentang 80%	Rentang 95%	vs *anchor*	Efek skenario
Nov 2026	18.225	17.701 – 18.764	17.430 – 19.056	+0,54%	+0,27%
Des 2026	18.349	17.645 – 19.082	17.282 – 19.482	+1,23%	+0,68%
Jan 2027	18.484	17.684 – 19.319	17.275 – 19.777	+1,97%	+1,13%
Feb 2027	18.634	17.776 – 19.534	17.337 – 20.027	+2,80%	+1,60%
Mar 2027	18.751	17.826 – 19.724	17.354 – 20.260	+3,44%	+1,89%
Apr 2027	18.914	17.939 – 19.941	17.444 – 20.507	+4,34%	+2,46%

Tabel 9.3 Mild Adverse (*outflow* total Rp49,58 triliun).

Bulan	Median	Rentang 80%	Rentang 95%	vs *anchor*	Efek skenario
Nov 2026	18.264	17.740 – 18.805	17.468 – 19.097	+0,76%	+0,49%
Des 2026	18.458	17.749 – 19.196	17.385 – 19.598	+1,83%	+1,28%
Jan 2027	18.668	17.860 – 19.512	17.447 – 19.974	+2,98%	+2,13%
Feb 2027	18.881	18.011 – 19.792	17.567 – 20.292	+4,16%	+2,95%
Mar 2027	19.105	18.163 – 20.097	17.683 – 20.643	+5,40%	+3,82%
Apr 2027	19.417	18.417 – 20.472	17.909 – 21.053	+7,12%	+5,19%

Tabel 9.4 Adverse (*outflow* total Rp139,48 triliun).

Bulan	Median	Rentang 80%	Rentang 95%	vs *anchor*	Efek skenario
Nov 2026	18.358	17.831 – 18.901	17.558 – 19.195	+1,28%	+1,01%
Des 2026	18.620	17.904 – 19.364	17.537 – 19.769	+2,72%	+2,16%
Jan 2027	18.978	18.158 – 19.836	17.738 – 20.306	+4,70%	+3,83%
Feb 2027	19.296	18.407 – 20.228	17.953 – 20.739	+6,45%	+5,21%
Mar 2027	19.656	18.686 – 20.676	18.192 – 21.237	+8,43%	+6,81%
Apr 2027	20.166	19.128 – 21.262	18.600 – 21.865	+11,25%	+9,25%

Tabel 9.5 Severe Adverse (*outflow* total Rp247,53 triliun).

Artinya:

- **Baseline** naik pelan dan stabil, sekitar 0,3% per bulan, sampai 18.459 pada April 2027 (+1,8%). Ini mencerminkan tren depresiasi historis (Bab 5.9).
- **Upside** hampir datar di sekitar 18.135–18.195. Dolar yang melemah dan arus modal masuk menahan tren depresiasi.
- **Mild Adverse**, **Adverse**, dan **Severe Adverse** melemah makin cepat sepanjang horizon, karena *outflow* dikunci di setiap bulan dan makin besar menjelang April. Severe Adverse melewati 20.000 di April 2027.
- **Rentang tetap lebar**, tetapi Severe Adverse menggeser seluruh distribusi: batas bawah 80% April 2027 (19.128) sudah 5,5% di atas *anchor*.
- Rentang 80% Baseline (17.508–19.461) memuat median Upside, Mild Adverse, dan Adverse, tetapi tidak median Severe Adverse (20.166). Severe Adverse adalah skenario yang jelas berbeda dari ketidakpastian *forecast* biasa.

9.2 Asumsi skenario yang benar-benar dipakai

Apa yang ditunjukkan: nilai asumsi dalam satuan aslinya, setelah diterjemahkan dari sheet `scenario_inputs`. Untuk TB dan *flows*, nilai yang dikunci = median baseline BVARX + geser; untuk *flows* Adverse dan Severe Adverse, gesernya diatur sehingga *flows* tepat sama dengan *outflow* target. Bulan yang tidak dikunci mengikuti model.

Bulan	Baseline	Upside	Mild Adverse	Adverse	Severe Adverse
Okt 2026 (*anchor*)	101,88	101,88	101,88	101,88	101,88
Nov 2026	101,88	101,54	102,05	102,22	102,71
Des 2026	101,88	101,20	102,22	102,55	103,55
Jan 2027	101,88	100,86	102,39	102,89	104,39
Feb 2027	101,88	100,52	102,56	103,23	105,25
Mar 2027	101,88	100,18	102,73	103,57	106,11
Apr 2027	101,88	99,84	102,90	103,92	106,97

Tabel 9.6 Jalur DXY (level indeks) per skenario (T11_global_paths).

Bulan	Baseline	Upside	Mild Adverse	Adverse	Severe Adverse
Nov 2026	1,97	2,38	1,85	1,65	1,22
Des 2026	1,63	2,25	1,33	1,03	0,41
Jan 2027	1,63	**2,63**	**1,13**	**0,63**	**–0,37**
Feb 2027	1,89	2,72	1,43	1,07	0,16
Mar 2027	1,96	2,81	1,54	1,17	0,32
Apr 2027	1,72	**2,72**	**1,22**	**0,72**	**–0,28**

Tabel 9.7 *Trade balance* (USD miliar, median) per skenario (T9_scenario_paths_all). Angka tebal = bulan yang dikunci.

Bulan	Baseline	Upside	Mild Adverse	Adverse	Severe Adverse
Nov 2026	2,9	3,6	**−4,96**	**−13,95**	**−24,75**
Des 2026	7,7	9,5	**−4,96**	**−13,95**	**−24,75**
Jan 2027	10,1	**20,1**	**−7,44**	**−20,92**	**−37,13**
Feb 2027	7,7	8,7	**−7,44**	**−20,92**	**−37,13**
Mar 2027	5,0	5,6	**−9,92**	**−27,90**	**−49,51**
Apr 2027	5,6	**15,6**	**−14,87**	**−41,84**	**−74,26**
Total 6 bulan	*39,1*	*63,1*	*−49,58*	*−139,48*	*−247,53*

Tabel 9.8 *Net flows* asing (Rp triliun, median) per skenario (T9_scenario_paths_all). Angka tebal = bulan yang dikunci.

Kondisi *bridge* Oktober 2026 (T10_scenario_inputs, baris "*bridge*"): perubahan USD/IDR +1,43% dari September dan *net flows* −Rp17,2 triliun (angka sementara). Keduanya dipakai sama di semua skenario. *Trade balance* dan cadangan devisa Oktober belum tersedia, sehingga diperkirakan model.

Artinya:

- DXY bergerak bertahap: Severe Adverse menambah sekitar 0,85 poin indeks per bulan sampai 106,97 (+5%).
- Pada bulan yang dikunci, nilainya tepat sesuai sheet: TB Mild Adverse 0,5, Adverse 1,0, dan Severe Adverse 2,0 di bawah baseline; *flows* Mild Adverse, Adverse, dan Severe Adverse sama persis dengan jalur *outflow*; *flows* Upside 10 di atas baseline.
- **Bulan yang tidak dikunci juga ikut bergeser.** TB Adverse dan Severe Adverse lebih rendah dari baseline juga di bulan yang tidak dikunci (misalnya Severe Adverse Desember 0,41 vs baseline 1,63), karena DXY yang naik dan kondisi lain yang tertekan. Ini perilaku model, bukan asumsi.

9.3 Hasil mentah BVARX sebelum digabung

Sumber: `tables/T8_scenarios.csv`. **Apa yang ditunjukkan:** *forecast* USD/IDR dari BVARX sendiri untuk setiap skenario. Dari tabel inilah rasio skenario diambil (median skenario ÷ median baseline BVARX).

Bulan	Baseline BVARX	Upside	Mild Adverse	Adverse	Severe Adverse
Nov 2026	18.178 17.835–18.531	18.149 17.801–18.505	18.228 17.904–18.559	18.268 17.959–18.600	18.362 18.057–18.699
Des 2026	18.178 17.678–18.701	18.117 17.606–18.634	18.302 17.837–18.794	18.410 17.930–18.878	18.571 18.077–19.075
Jan 2027	18.174 17.558–18.809	18.032 17.428–18.643	18.379 17.810–18.986	18.562 17.988–19.157	18.871 18.259–19.471
Feb 2027	18.181 17.472–18.936	18.014 17.306–18.746	18.472 17.797–19.167	18.716 18.038–19.419	19.128 18.403–19.881
Mar 2027	18.264 17.459–19.100	18.056 17.265–18.859	18.609 17.854–19.401	18.961 18.179–19.748	19.507 18.684–20.346

Bulan	Baseline BVARX	Upside	Mild Adverse	Adverse	Severe Adverse
Apr 2027	18.360 17.475–19.282	18.077 17.229–18.953	18.813 17.972–19.692	19.314 18.413–20.205	20.059 19.101–21.074

Tabel 9.9 *Forecast* BVARX: median dan rentang 80% (angka kecil).

Artinya: baseline BVARX hampir datar di sekitar 18.180 selama November–Februari, lalu naik ke 18.360. Ini karena BVARX dengan *prior* ketat hampir tidak membawa *drift*, berbeda dengan BMA. Karena itu level baseline diambil dari BMA (yang lebih akurat), sedangkan BVARX hanya menyumbang persentase pergeseran. Contoh April 2027: 20.059 ÷ 18.360 = 1,0925 untuk Severe Adverse, lalu 18.459 × 1,0925 = 20.166 (Tabel 9.5).

9.4 Hasil BMA lengkap

Forecast

Bulan	h	Rata-rata perubahan (%)	Simpangan baku (%)	Median	Rentang 80%	Rentang 95%
Nov 2026	1	0,26	2,27	18.175	17.653 – 18.712	17.382 – 19.003
Des 2026	2	0,54	3,06	18.226	17.526 – 18.954	17.166 – 19.351
Jan 2027	3	0,83	3,45	18.278	17.487 – 19.104	17.083 – 19.557
Feb 2027	4	1,17	3,68	18.340	17.496 – 19.226	17.064 – 19.712
Mar 2027	5	1,51	3,95	18.403	17.495 – 19.358	17.032 – 19.884
Apr 2027	6	1,81	4,13	18.459	17.508 – 19.461	17.025 – 20.013

Tabel 9.10 *Forecast* BMA (B5_bma_final_forecast). "Rata-rata perubahan" dalam persen log dari *anchor*; median = 18.127 × exp(rata-rata/100).

Artinya: simpangan baku naik dari 2,3% (1 bulan) ke 4,1% (6 bulan), tetapi tidak naik secepat $\sqrt{h}$ (yang akan memberi 5,6%). Ini wajar karena ada sedikit pembalikan dalam data kurs bulanan.

Posterior inclusion probability

Prediktor	h = 1	h = 3	h = 6	Bacaan
ds: perubahan rata-rata USD/IDR	0,721	0,788	0,690	Bukti terkuat di semua horizon
ddxy: perubahan rata-rata DXY	0,569	0,513	0,603	Sedikit bukti, terutama di 6 bulan
dust: perubahan rata-rata UST10Y	0,490	0,574	0,487	Sedikit bukti di 3 bulan
flow2: *net flows* (t−2)	0,475	0,537	0,530	Tidak ada bukti jelas
tb2: *trade balance* (t−2)	0,477	0,508	0,473	Tidak ada bukti jelas

Prediktor	h = 1	h = 3	h = 6	Bacaan
dres2: perubahan cadangan (t−2)	0,479	0,485	0,490	Tidak ada bukti jelas

Tabel 9.11 PIP sampel penuh (B4_bma_pip_final). *Prior* = 0,50.

Sepuluh model teratas per horizon

#	h = 1	Bobot	h = 3	Bobot	h = 6	Bobot
1	ds, ddxy	3,22%	ds, dust, flow2, tb2	3,35%	ds, ddxy, flow2	3,34%
2	ds, ddxy, dust	2,95%	ds, ddxy, dust, flow2, tb2	3,31%	ds, ddxy, dust, flow2	3,04%
3	ds, ddxy, dres2	2,91%	ds, ddxy, dust, flow2	3,24%	ds, ddxy, flow2, dres2	3,04%
4	ds, ddxy, tb2	2,90%	ds, dust, flow2	3,17%	ds, ddxy, flow2, tb2	3,03%
5	ds, ddxy, flow2	2,90%	ds, dust, flow2, tb2, dres2	3,00%	ds, ddxy, dres2	2,88%
6	ds, ddxy, dust, tb2	2,67%	keenam prediktor	2,97%	ds, ddxy, dust, flow2, dres2	2,77%
7	ds, ddxy, flow2, dres2	2,66%	ds, ddxy, dust, flow2, dres2	2,91%	ds, ddxy, flow2, tb2, dres2	2,76%
8	ds, ddxy, dust, dres2	2,66%	ds, dust, flow2, dres2	2,84%	ds, ddxy, dust, flow2, tb2	2,74%
9	ds, ddxy, dust, flow2	2,66%	ds, ddxy, dust, tb2, dres2	2,72%	ds, ddxy	2,72%
10	ds, ddxy, tb2, dres2	2,63%	ds, dust, tb2	2,71%	ds, ddxy, dust, dres2	2,61%
	Total 10 teratas	*28,2%*		*30,2%*		*29,9%*

Tabel 9.12 Model dengan probabilitas *posterior* tertinggi (B6_bma_top_models_h*, B6_bma_varinclusion_h*). Bobot awal setiap model = 1/64 = 1,56%.

Artinya:

- Di semua horizon, semua model teratas memuat perubahan kurs rata-rata bulanan (ds). Di 1 dan 6 bulan, semuanya juga memuat DXY (ddxy); di 3 bulan, semuanya memuat UST (dust).
- Model "konstanta saja" tidak masuk sepuluh besar di horizon mana pun. Rata-rata bulanan membuat sinyal perubahan kurs (pembalikan) lebih terbaca.
- Tidak ada satu model yang dominan: bobot tertinggi hanya sekitar 3,4%, dan sepuluh model teratas hanya memegang 28–30% bobot. Inilah alasan memakai rata-rata banyak model.

9.5 *Forecast* akhir semua model

Bulan	BMA	BVARX	*Random walk*	RW + *drift* BI–Fed	Kombinasi BVARX dan RW+*drift*
Nov 2026	18.175	18.178	18.127	18.155	18.167
Des 2026	18.226	18.178	18.127	18.184	18.181

Bulan	BMA	BVARX	*Random walk*	RW + *drift* BI–Fed	Kombinasi BVARX dan RW+*drift*
Jan 2027	18.278	18.174	18.127	18.212	18.193
Feb 2027	18.340	18.181	18.127	18.241	18.211
Mar 2027	18.403	18.264	18.127	18.269	18.267
Apr 2027	18.459	18.360	18.127	18.298	18.329
Rentang 80% Apr 2027	*17.508–19.461*	*17.475–19.282*	*16.844–19.508*	*17.002–19.692*	*17.239–19.487*

Tabel 9.13 Median *forecast* semua model, skenario baseline (T12_forecast_compare, T13_forecast_compare_wide, T19_hybrid_forecast_compare). RW + *drift*: *random walk* ditambah selisih BI rate − Fed funds per bulan.

Artinya: semua model selain *random walk* murni memperkirakan depresiasi ringan. Perbedaan antarmodel untuk April 2027 hanya sekitar 1% (18.298–18.459), jauh lebih kecil dari lebar rentang mana pun. Pilihan model lebih memengaruhi rentang dan akurasi jangka panjang daripada angka tengahnya.

9.6 Akurasi lengkap

BMA di periode test (origin Jan 2024 – Mar 2026, 27 *forecast* per horizon)

Horizon	RMSE BMA	RMSE RW	Rel. RMSE	Arah benar	DM (HLN)	DM p	Clark-West t	CW p	Cov. 80%	Cov. 95%
1 bulan	256,4	261,8	0,979	63,0%	−0,70	0,492	0,94	0,173	0,93	0,96
3 bulan	519,5	560,8	0,926	74,1%	−1,26	0,221	1,75	0,040	0,85	0,96
6 bulan	586,8	691,9	0,848	77,8%	−1,19	0,244	2,14	0,016	0,81	1,00

Tabel 9.14 Akurasi BMA (B2_bma_test_scores, T17_hybrid_baseline_test). Uji DM dengan koreksi HLN (Diebold & Mariano, 1995; Harvey et al., 1997) dan Clark-West (Clark & West, 2007). RMSE dalam rupiah. DM negatif = kesalahan BMA lebih kecil.

BVARX di periode test

Horizon	RMSE BVARX	RMSE RW	Rel. RMSE	MAE BVARX	MAE RW	Arah benar	Cov. 80%	Cov. 95%	Cov. 80% RW	Lebar 80%
1 bulan	271,2	261,8	1,036	191,8	187,3	44,4%	0,81	0,93	0,93	651
3 bulan	574,7	560,8	1,025	460,3	461,5	55,6%	0,74	0,81	0,89	1.182
6 bulan	667,4	691,9	0,965	535,7	558,4	74,1%	0,70	0,96	0,96	1.682

Tabel 9.15 Akurasi BVARX (T4_test_scores). Lebar 80% dalam rupiah. ESS ratio terendah di *backtest*: 0,34.

Horizon	Rel. RMSE	Blok 3 bulan	Blok 6 bulan	Blok 12 bulan
1 bulan	1,036	0,91 – 1,11	0,88 – 1,10	0,89 – 1,08
3 bulan	1,025	0,88 – 1,17	0,85 – 1,15	0,85 – 1,13

Horizon	Rel. RMSE	Blok 3 bulan	Blok 6 bulan	Blok 12 bulan
6 bulan	0,965	0,81 – 1,22	0,79 – 1,22	0,78 – 1,14

Tabel 9.16 Interval *bootstrap* 95% relative RMSE BVARX (T5_test_bootstrap), circular block *bootstrap* (Politis & Romano, 1992). Semua interval memuat 1.

Semua pembanding di *validation* dan test

Periode	Horizon	RMSE RW	BMA	BVARX	RW + *drift*	Kombinasi
Validation	1 bulan	220,5	0,98	0,98	0,99	0,98
Validation	3 bulan	366,2	0,98	0,93	0,98	0,94
Validation	6 bulan	555,0	0,92	0,87	0,93	0,88
Test	1 bulan	261,8	0,98	1,04	0,99	1,01
Test	3 bulan	560,8	0,93	1,02	0,97	0,99
Test	6 bulan	691,9	0,85	0,96	0,93	0,94
Rata-rata enam angka			*0,939*	*0,968*	*0,964*	*0,958*

Tabel 9.17 Relative RMSE terhadap *random walk* (T6_benchmarks, B1, B2). *Validation*: 30 origin; test: 27 origin.

Sepuluh spesifikasi BVARX terbaik di *validation*

#	Awal sampel	*Lag*	λ	*Prior* UIP	Skor	h=1	h=3	h=6	Status
1	2014	2	0,03	Tidak	0,927	0,98	0,93	0,87	**Terpilih**
2	2013	2	0,05	Tidak	0,933	0,96	0,93	0,91	Kandidat (dalam 1%)
3	2013	2	0,03	Ya	0,939	1,02	0,93	0,87	
4	2013	2	0,05	Ya	0,945	1,02	0,95	0,87	
5	2013	1	0,10	Tidak	0,946	0,94	0,95	0,94	
6	2013	1	0,05	Tidak	0,950	0,93	0,96	0,96	
7	2013	2	0,03	Tidak	0,956	0,99	0,96	0,92	
8	2013	2	0,10	Tidak	0,957	1,00	0,94	0,93	
9	2013	1	0,03	Tidak	0,957	0,93	0,99	0,95	
10	2014	1	0,05	Tidak	0,958	0,98	0,97	0,93	

Tabel 9.18 *Validation* grid BVARX (T2_validation_grid). Semua memakai *dummy outlier*. Skor = rata-rata relative RMSE di tiga horizon.

Artinya, dibaca bersama:

- **BMA** satu-satunya model yang lebih akurat dari *random walk* di keenam kombinasi periode × horizon, dengan rata-rata terbaik (0,939). Keunggulannya signifikan di 3 dan 6 bulan (CW p 0,040 dan 0,016) dan rentangnya terkalibrasi (*coverage* 80% antara 0,81 dan 0,93).

- **BVARX** paling bagus di *validation* (0,87 di 6 bulan), tetapi turun di test. Akurasi arah 1 bulannya hanya 44%, lebih buruk dari *random guess*, dan rentang 80%-nya terlalu sempit di 6 bulan (memuat kenyataan hanya 70% dari waktu). Ini konsisten dengan keputusan memakai BVARX hanya untuk efek skenario.
- **RW + *drift*** konsisten sedikit lebih baik dari *random walk*. Ini menunjukkan bahwa sebagian besar "sinyal" yang bisa diramal adalah *drift* depresiasi, temuan yang juga terlihat di BMA.
- **Pemilihan spesifikasi BVARX tidak sensitif**: sepuluh spesifikasi teratas punya skor 0,93–0,96. Hasil skenario tidak bergantung pada satu pilihan yang kebetulan.

9.7 Diagnostik lengkap

Data yang hilang

`diagnostics/D1_audit_missing.csv`: hanya empat sel kosong, yaitu *trade balance*, ekspor, impor, dan cadangan devisa Oktober 2026 (belum dirilis). Tidak ada data hilang lain di variabel inti. *Flows* Oktober 2026 terisi tetapi masih sementara (Bab 4.4).

Residual BVARX

Persamaan	N	SD residual	Ljung-Box Q(12)	p	Skewness p	Kurtosis p	Normalitas gabungan p
Δ USD/IDR (%)	153	1,49	6,3	0,900	0,467	0,037	0,085
Trade balance (USD bn)	153	1,36	51,8	< 0,001	0,522	0,129	0,252
Net flows (Rp10 tn)	153	2,36	22,9	0,029	0,539	0,101	0,211
Δ cadangan (%)	153	1,91	6,9	0,865	0,689	0,804	0,895

Tabel 9.19 Uji residual fit akhir (D3_residual_tests).

Artinya: *shock* kurs bulanan rata-rata sekitar 1,5% (dengan *dummy outlier*); *shock flows* sekitar Rp23,6 triliun. Persamaan kurs dan cadangan bersih. Ekor distribusi kurs sedikit lebih tebal dari normal (kurtosis p 0,04): bulan-bulan *outlier* sedikit lebih sering dari yang diasumsikan, walaupun normalitas gabungan tidak ditolak. *Trade balance* dan *flows* masih menyisakan pola (Bab 6.9).

Korelasi residual

	Δ USD/IDR	*Trade balance*	*Net flows*	Δ cadangan
Δ USD/IDR	1	−0,14	−0,36	−0,30
Trade balance	−0,14	1	−0,01	0,00
Net flows	−0,36	−0,01	1	0,43
Δ cadangan	−0,30	0,00	0,43	1

Tabel 9.20 *Residual correlation* antarpersamaan (D4_residual_corr).

Artinya: ini adalah *transmission mechanism* skenario. Saat *flows* dikunci lebih rendah, kurs ikut melemah karena korelasi −0,36. *Shock trade balance* hampir tidak berkorelasi dengan *shock* kurs di bulan yang sama (−0,14), sehingga efek TB di skenario lebih kecil daripada efek *flows*.

Efek DXY dan ESS

Variabel	Efek +1% DXY	Simpangan baku	Interval 90%
USD/IDR	+0,383%	0,064	0,278 – 0,488
Trade balance	+USD0,020 bn	0,057	−0,074 – 0,115
Net flows	−Rp3,26 tn	1,00	−4,91 – −1,61
Cadangan devisa	−0,277%	0,081	−0,410 – −0,145

Tabel 9.21 Efek kontemporer DXY (D6_dxy_effect). ESS per skenario ada di Tabel 6.2: Baseline dan Upside di atas 90%, Mild Adverse 76%, Adverse 49%, Severe Adverse 9% (927 dari 10.000 *draw*).

9.8 Kesimpulan dari semua hasil

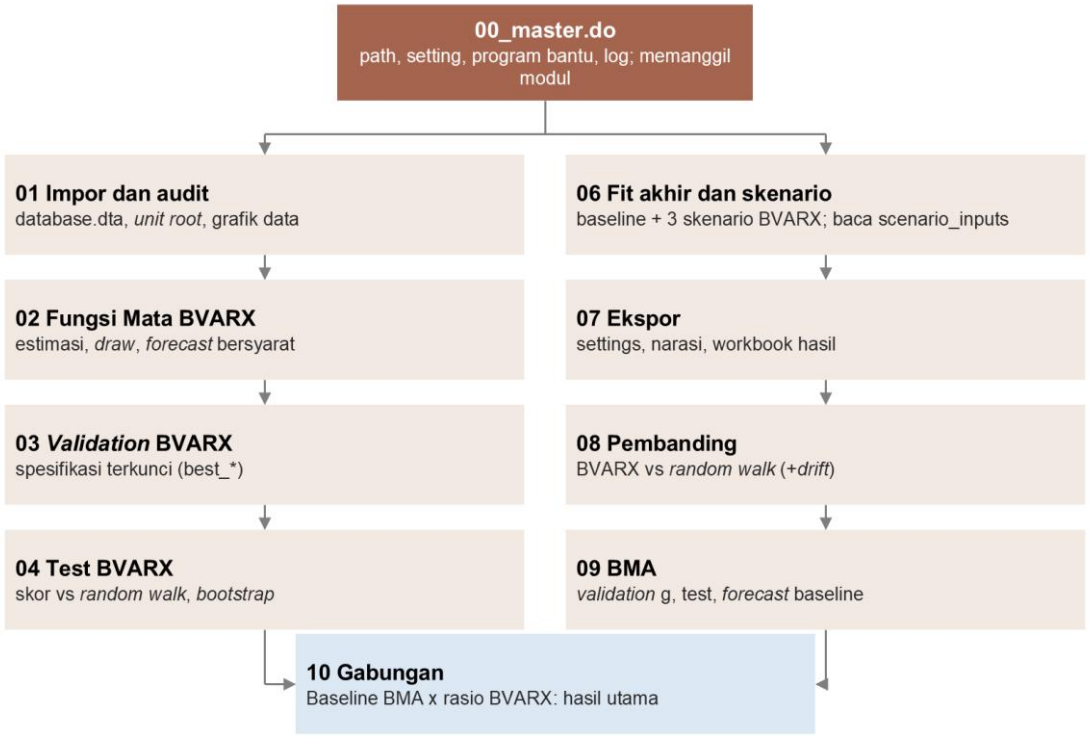
1. **Arah:** semua model kecuali *random walk* murni memperkirakan rupiah melemah ringan ke sekitar 18.300–18.460 pada April 2027. Baseline resmi (BMA) 18.459.
2. **Ketidakpastian besar:** rentang 80% baseline sekitar ±5% (17.508–19.461). Median Upside, Mild Adverse, dan Adverse masih di dalam rentang itu; median Severe Adverse (20.166) sudah di luar batas atasnya.
3. **Risiko condong ke pelemahan:** Mild Adverse menambah 2,5%, Adverse 5,2%, dan Severe Adverse 9,3% di atas baseline pada April 2027. Kanal utamanya *outflow* asing yang dikunci setiap bulan (melalui korelasi *flows*–kurs) dan DXY (0,38% per 1%).
4. **Kepercayaan pada baseline:** BMA lebih akurat dari *random walk* secara konsisten dan signifikan di 3 dan 6 bulan, dengan rentang yang terkalibrasi. Sumber utama keunggulannya adalah *drift*, sehingga perlu dipantau jika tren rupiah berubah.
5. **Kepercayaan pada skenario:** hubungan yang dipakai (efek DXY, korelasi *flows*–kurs) signifikan dan masuk akal, ESS aman, dan sistem stabil. Besaran *outflow* berasal dari estimasi dampak MSCI (Bab 7.1); hasilnya setara persentil 75 (Mild Adverse), 90 (Adverse), dan di atas persentil 95 (Severe Adverse) pergerakan rupiah enam bulanan historis. Karena model linear, efek kepanikan pada *outflow* ekstrem tidak tertangkap, sehingga Severe Adverse sebaiknya dibaca sebagai batas bawah dampak.

10. Menjalankan Model

10.1 Struktur folder

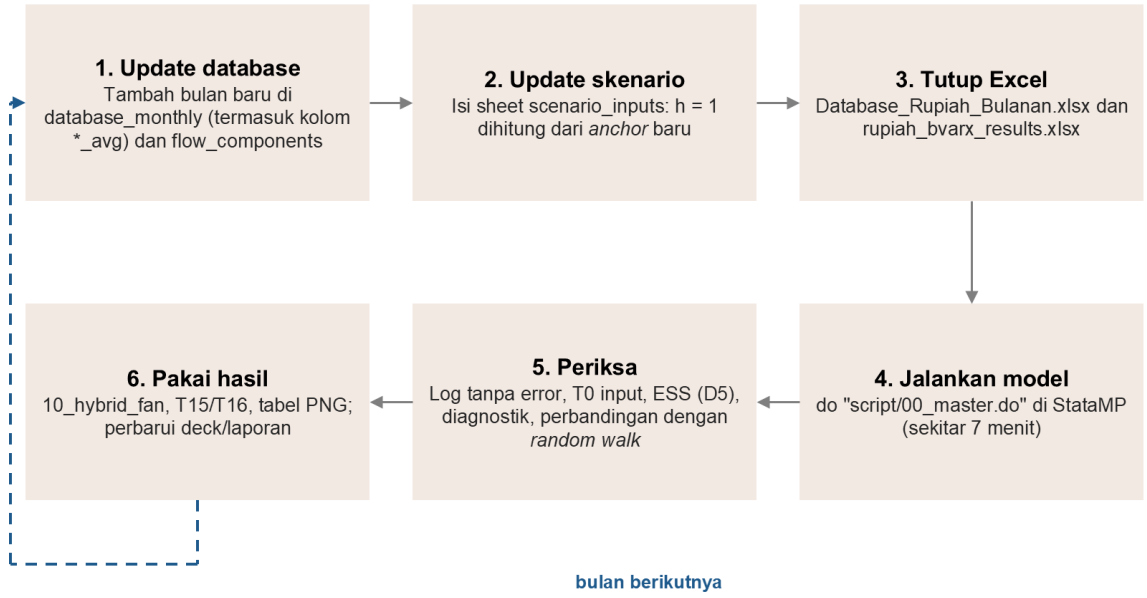
Folder / file	Isi
`input/Database_Rupiah_Bulanan.xlsx`	Data (database_monthly, flow_components, rating_events, sources) dan asumsi skenario (scenario_inputs). Hanya dibaca kode.
`input/reference/`	Manual R Markdown asli yang menjadi titik awal model
`script/00_master.do`	Satu-satunya file yang dijalankan: path, setting, lalu memanggil modul 01–10
`script/01-10_*.do`	Modul per tahap (Gambar 10.1)
`script/rupiah_bvarx_all.do`	Semua modul dalam satu file, untuk ditempel di Do-file Editor
`intermediate/`	Dataset Stata hasil olahan (.dta), ditulis ulang setiap run
`output/figures/`	Grafik hasil utama; subfolder `komponen_bvarx/` dan `komponen_bma/` untuk grafik komponen
`output/tables/`	Tabel hasil (CSV)
`output/diagnostics/`	Uji dan diagnostik (*unit root*, residual, ESS, PIP)
`output/rupiah_bvarx_results.xlsx`	Semua tabel dalam satu workbook, satu sheet per tabel
`output/run_log.log`	Log lengkap run terakhir
`archive/`	Versi lama model (v2 level, v3.5 BVARX saja), tidak dipakai

Tabel 10.1 Struktur repositori.



Gambar 10.1 Modul dan urutan eksekusi. Modul 10 membutuhkan hasil 06 (skenario BVARX) dan 09 (baseline BMA).

10.2 Siklus bulanan



Gambar 10.2 Langkah rutin setiap ada data baru.

1. **Update database.** Tambahkan baris bulan baru di `database_monthly` (dan komponen *flows* di `flow_components`). Isi `core_complete` = 1 hanya jika kurs, *trade balance*, *flows*, cadangan, dan DXY semuanya tersedia. Jika *trade balance* belum rilis, biarkan kosong; jangan diisi nol. Isi juga `usdidr_avg`, `dxy_avg`, dan `ust10y_avg` dengan rata-rata data harian bulan itu.

2. **Update skenario.** Tinjau sheet `scenario_inputs`. Ingat bahwa *h* = 1 sekarang bulan setelah *anchor* baru. Perbarui sel O3 (bulan *anchor*), O4 (DXY pada *anchor*), dan baseline model di kolom H dan J, lalu isi target di tabel bantu (kolom I, K, L).
3. **Tutup Excel.** Stata tidak bisa membaca file yang sedang terbuka di Excel, dan tidak bisa menulis workbook hasil yang sedang terbuka.
4. **Jalankan.** Di StataMP: `do "C:\Users\...\Simulasi-Rupiah\script\00_master.do"`. Run penuh dengan `profile standard` butuh sekitar 6–8 menit. Jika folder dipindah, ubah `global base` di baris awal 00_master.do.
5. **Periksa** dengan daftar periksa di Bagian 10.4.
6. **Pakai hasil.** Grafik dan tabel utama ada di `output/figures/10_*.png` dan `output/tables/T15–T19`.

10.3 Output utama dan cara membacanya

File	Isi	Dipakai untuk
`figures/10_hybrid_fan.png`	*Fan chart* baseline BMA + median skenario	Gambar utama laporan
`figures/10_hybrid_table.png`	*Forecast* bulanan per skenario, median [rentang 80%]	Tabel utama laporan
`figures/10_hybrid_scenario_table.png`	Asumsi makro + hasil kurs per skenario	Ringkasan satu halaman
`figures/10_hybrid_macro.png`	Jalur DXY, TB, *flows* per skenario	Menjelaskan asumsi
`figures/10_test_*.png`	*Backtest* baseline BMA	Bukti akurasi
`tables/T0_scenario_inputs`	Isi sheet skenario yang dipakai	Memastikan input benar
`tables/T15_hybrid_scenarios`	Semua skenario × bulan: median, rentang, % vs *anchor*, % efek skenario	Angka lengkap
`tables/T16_hybrid_summary`	Ringkasan bulan terakhir horizon	Angka headline
`tables/T17_hybrid_baseline_test`	Akurasi baseline: relative RMSE, uji, *coverage*	Bukti akurasi
`tables/T18_hybrid_scenario_assumptions`	Asumsi dan hasil per skenario	Tabel asumsi
`tables/B1–B6`	Komponen BMA: pemilihan g, skor test, *forecast*, PIP, model teratas	Analisis BMA
`tables/T2–T14`	Komponen BVARX: *validation*, test, skenario BVARX	Analisis BVARX
`diagnostics/D2–D6`	*Unit root*, residual, korelasi residual, ESS, efek DXY	Diagnostik

File	Isi	Dipakai untuk
`tables/S0_settings`	Semua setting dan spesifikasi terpilih run ini	Reproduksibilitas

Tabel 10.2 Output yang paling sering dipakai.

10.4 Daftar periksa setelah run



Gambar 10.3 Pertanyaan yang perlu dijawab "ya" sebelum hasil dipakai.

10.5 Setting di 00_master.do

Global	Arti	Nilai saat ini
`base`	Folder repositori	C:\Users\LENOVO05\github\Simulasi-Rupiah
`profile`	Jumlah *draw* BVARX: quick (cek alur), standard, publication (angka final yang lebih halus)	standard (10.000 *draw* skenario)
`scen_sheet`	Nama sheet asumsi skenario	scenario_inputs
`horizons`, `H_final`	Horizon evaluasi; horizon *forecast* akhir	1 3 6; 6
`release_lag`	Jeda rilis data makro (bulan)	2
`bma_preds`, `bma_g_grid`, `bma_start`, `bma_inc`	Prediktor BMA, kandidat g, awal sampel, *prior* inklusi	6 prediktor; 0.25; 2014; 0.5
`grid_start`, `grid_p`, `grid_lambda`	Grid *validation* BVARX	2013 2014 2017; 1 2; 0.03 0.05 0.10 0.30

Global	Arti	Nilai saat ini
`grid_dum`, `outlier_months`	*Dummy outlier*	1; 2015m10 2018m11 2020m3 2020m4
`grid_ust`, `grid_rate`, `grid_vix`, `grid_uip`	Opsi eksogen tambahan BVARX	0; 0; 0; 0 1
`tb_prior_mean`, `seas_harm`	*Prior lag* TB; jumlah harmonik musiman	0.7; 2
`val_from`, `val_to`, `test_from`	Periode *validation* dan awal test	2021m1–2023m6; 2024m1

Tabel 10.3 Setting utama.

> **Jangan mengubah setting berdasarkan hasil test.** Mengubah λ, g, atau prediktor karena angka test terlihat lebih baik akan membuat test kehilangan fungsinya sebagai penilaian independen. Perubahan spesifikasi seharusnya didorong oleh alasan ekonomi atau hasil *validation*, lalu dicatat di CHANGELOG.md.

10.6 Masalah yang sering terjadi

Gejala	Penyebab	Solusi
"Tidak dapat membaca … Tutup file di Excel"	Database terbuka di Excel	Tutup file, jalankan ulang
"Gagal menulis rupiah_bvarx_results.xlsx"	Workbook hasil terbuka	Tutup file, jalankan ulang
Error dari sheet scenario_inputs	Nama skenario salah ketik, *h* kurang/ganda, DXY kosong	Baca pesan di log; perbaiki sheet
"PERHATIAN: … ESS rendah"	Kondisi skenario terlalu ekstrem atau terlalu banyak bulan dikunci	Longgarkan kondisi atau pakai profile publication
"BMA: prediktor … kosong pada final_origin"	Data makro bulan *anchor* − 2 belum ada	Lengkapi database
Assertion gagal di 01	Bulan loncat, duplikat, *flows* ≠ jumlah komponen, atau core_complete tidak konsisten	Periksa baris terakhir database

Tabel 10.4 Pemecahan masalah.

11. Keterbatasan dan Pengembangan

11.1 Keterbatasan

1. **Periode test ikut memengaruhi desain.** Beberapa keputusan diambil setelah melihat hasil test versi sebelumnya, sehingga akurasi test cenderung optimistis. Bukti bersih hanya dari data baru.
2. **Keunggulan BMA terutama dari *drift*.** PIP semua prediktor sekitar 0,5 dan koefisien di-*shrink* 80%. Baseline pada dasarnya *drift* depresiasi historis ditambah sinyal kecil. Jika tren berbalik, baseline akan tertinggal.
3. **Skenario adalah gabungan dua model.** Rasio dari BVARX diterapkan ke baseline BMA. Rentang skenario tidak memuat ketidakpastian tambahan dari jalur skenario.
4. **Skenario *outflow* dibaca dengan model linear.** Setiap Rp100 triliun *flows* di luar perkiraan baseline menggeser kurs sekitar 2,3%, berapa pun besarnya, dan bulan krisis seperti Maret 2020 (*outflow* Rp120 triliun, rupiah +13% dalam sebulan) dikeluarkan lewat *dummy*. Efek kepanikan pada *outflow* ekstrem karena itu tidak tertangkap; Severe Adverse (setara di atas persentil 95 pergerakan enam bulanan) sebaiknya dibaca sebagai batas bawah dampak.
5. **Data Oktober 2026 masih sementara.** *Flows* Oktober belum memakai posisi akhir bulan SBN dan SRBI, dan *trade balance* serta cadangan devisa Oktober belum dirilis.
6. **Data *latest vintage*.** *Backtest* memakai data revisi terakhir, bukan data yang tersedia saat itu (Croushore & Stark, 2001).
7. **Baseline DXY datar.** BVARX baseline mengasumsikan DXY tidak berubah. Ini netral, tetapi bukan *forecast* DXY.
8. **Residual *trade balance* BVARX** masih berautokorelasi, dan bulan *dummy* dipilih dari seluruh sampel.
9. **Target tumpang tindih di BMA.** Untuk $h > 1$, target bulan-bulan berurutan saling tumpang tindih sehingga error regresi berautokorelasi (Hansen & Hodrick, 1980). BMA tidak memodelkan ini secara eksplisit; *coverage* yang baik di *backtest* menunjukkan dampaknya terbatas.

11.2 Arah pengembangan

1. **Efek nonlinear *outflow* besar.** Uji skenario berbasis episode historis (taper tantrum 2013, 2015, 2018, Maret 2020) atau model yang mengizinkan respons kurs berbeda saat tekanan tinggi, karena model linear cenderung meremehkan dampak *outflow* ekstrem.
2. **Bekukan spesifikasi dan catat *forecast* bulanan** untuk membangun rekam jejak *out-of-sample* yang bersih.
3. **Jalur DXY baseline** dari konsensus atau harga forward, bukan datar.
4. **Data real-time vintage** untuk data makro yang sering direvisi.

Lampiran A. Glosarium

Istilah	Penjelasan (dalam konteks model ini)
Anchor	Bulan terakhir data kurs yang dipakai sebagai titik awal *forecast* resmi (saat ini Oktober 2026)
Akar companion	Ukuran stabilitas VAR. Jika akar terbesar > 1, jalur *forecast* bisa meledak; dilaporkan sebagai persentase *draw* di D5
Backtest	Simulasi *forecast* masa lalu: model diestimasi dengan data sampai origin, *forecast* dibandingkan dengan realisasi
BMA	Bayesian *Model Averaging*: rata-rata *forecast* banyak model, dibobot probabilitas *posterior* masing-masing
Bootstrap blok	*Resampling* data dalam blok bulan berurutan untuk menghitung ketidakpastian statistik tanpa asumsi distribusi
Bridge	Data bulan setelah akhir sampel estimasi yang sudah teramati, dimasukkan sebagai kondisi tetap
BVARX	Bayesian Vector Autoregression dengan variabel eksogen
Clark-West	Uji akurasi *forecast* untuk model bersarang; uji utama BMA vs *random walk*
Conditional *forecast*	*Forecast* dengan sebagian jalur variabel ditetapkan (dikunci) sesuai asumsi
Konjugat	*Prior* yang membuat *posterior* punya bentuk sama dengan *prior*, sehingga *posterior* dihitung dengan rumus langsung
Coverage	Persentase realisasi yang jatuh di dalam rentang *forecast*
Diebold-Mariano (DM)	Uji apakah dua *forecast* berbeda akurasinya secara statistik; koreksi HLN untuk sampel kecil
Direct *forecast*	Regresi khusus untuk setiap horizon, memakai data yang diketahui di origin
Draw	Satu set nilai parameter yang diambil acak dari distribusi *posterior*
Drift	Kecenderungan rata-rata seri bergerak ke satu arah; di BMA diwakili konstanta
Dummy impulse	Variabel bernilai 1 di satu bulan tertentu dan 0 di bulan lain, untuk menetralkan *outlier*
Endogen / eksogen	Endogen: ditentukan di dalam sistem (kurs, TB, *flows*, cadangan). Eksogen: ditentukan di luar sistem dan diberikan sebagai input (DXY, musiman, *dummy*)
ESS	*Effective sample size*: jumlah *draw* yang efektif berkontribusi setelah pembobotan
Expanding window	Jendela estimasi yang terus memanjang seiring origin bergeser
g-*prior*	*Prior* Zellner untuk koefisien regresi; *g* mengatur kekuatan *shrinkage* (koefisien *posterior* = g/(1+g) × OLS)
Horizon (*h*)	Berapa bulan ke depan dari origin

Istilah	Penjelasan (dalam konteks model ini)
Importance *resampling*	Mengambil ulang *draw* dengan peluang sebanding bobotnya
Inverse-Wishart	Distribusi untuk matriks kovarians; dipakai sebagai *prior* dan *posterior* Σ
λ (lambda)	Tingkat keketatan *prior* Minnesota; kecil = ketat
Latest vintage	Data versi revisi terakhir, bukan versi saat pertama dirilis
Look-ahead bias	Kesalahan memakai informasi yang belum tersedia saat *forecast* dibuat
Marginal *likelihood*	Seberapa baik model menjelaskan data setelah dirata-ratakan atas *prior* koefisien; dasar bobot BMA
Median	Nilai tengah distribusi *forecast*; dilaporkan sebagai *forecast* titik
Origin	Bulan saat *forecast* dibuat
Out-of-sample	Penilaian pada data yang tidak dipakai untuk estimasi
Overfitting	Model menyesuaikan diri dengan kebetulan sampel sehingga buruk saat meramal data baru
PIP	*Posterior inclusion probability*: total bobot model yang memuat suatu prediktor
Posterior / *prior*	*Prior*: keyakinan sebelum melihat data. *Posterior*: keyakinan setelah data, gabungan *prior* dan *likelihood*
Prior Minnesota	*Prior* VAR yang menarik koefisien *lag* ke nilai sederhana (0 atau *random walk*), makin ketat untuk *lag* jauh
Random walk	*Forecast* kurs = kurs terakhir; *benchmark* utama
Rasio skenario	Median skenario BVARX ÷ median baseline BVARX; dipakai untuk menggeser baseline BMA
Relative RMSE	RMSE model ÷ RMSE *random walk*; < 1 berarti lebih akurat
Release *lag*	Jeda antara akhir bulan data dan rilisnya; diasumsikan 2 bulan untuk data makro
Rentang (interval) prediktif	Rentang yang memuat realisasi dengan peluang tertentu (80% atau 95%)
Shrinkage	*Shrinkage* koefisien ke arah nilai *prior* (biasanya nol) untuk mengurangi *overfitting*
Spesifikasi terkunci	Pilihan model hasil *validation* yang tidak diubah lagi saat test dan *forecast*
Stasioner / *unit root*	Stasioner: rata-rata dan varians tetap. *Unit root*: *shock* berdampak permanen
Test / *validation*	*Validation*: periode untuk memilih spesifikasi. Test: periode terpisah untuk menilai
UIP	Uncovered interest parity: mata uang berbunga lebih tinggi cenderung terdepresiasi sebesar selisih bunga
Waggoner-Zha	Metode memaksa jalur simulasi VAR memenuhi kondisi dengan koreksi *shock* sekecil mungkin

Lampiran B. Referensi

Format APA. Setiap referensi dikutip di teks; kolom kanan Tabel B.1 menunjukkan di bagian mana dan untuk apa.

- Bańbura, M., Giannone, D., & Lenza, M. (2015). Conditional forecasts and scenario analysis with vector autoregressions for large cross-sections. *International Journal of Forecasting*, 31(3), 739–756.
- Bańbura, M., Giannone, D., & Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71–92.
- Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468.
- Carriero, A., Clark, T. E., & Marcellino, M. (2015). Bayesian VARs: Specification choices and *forecast* accuracy. *Journal of Applied Econometrics*, 30(1), 46–73.
- Carriero, A., Kapetanios, G., & Marcellino, M. (2009). Forecasting exchange rates with a large Bayesian VAR. *International Journal of Forecasting*, 25(2), 400–417.
- Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- Clark, T. E., & West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- Croushore, D., & Stark, T. (2001). A real-time data set for macroeconomists. *Journal of Econometrics*, 105(1), 111–130.
- D'Agostino, R. B., Belanger, A., & D'Agostino, R. B., Jr. (1990). A suggestion for using powerful and informative tests of normality. *The American Statistician*, 44(4), 316–321.
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a *unit root*. *Journal of the American Statistical Association*, 74(366), 427–431.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Doan, T., Litterman, R., & Sims, C. (1984). Forecasting and conditional projection using realistic *prior* distributions. *Econometric Reviews*, 3(1), 1–100.
- Eichengreen, B., & Gupta, P. (2015). Tapering talk: The impact of expectations of reduced Federal Reserve security purchases on emerging markets. *Emerging Markets Review*, 25, 1–15.
- Engel, C. (2014). Exchange rates and interest parity. Dalam G. Gopinath, E. Helpman, & K. Rogoff (Eds.), *Handbook of International Economics* (Vol. 4, hlm. 453–522). Elsevier.
- Evans, M. D. D., & Lyons, R. K. (2002). Order flow and exchange rate dynamics. *Journal of Political Economy*, 110(1), 170–180.
- Fama, E. F. (1984). Forward and spot exchange rates. *Journal of Monetary Economics*, 14(3), 319–338.
- Fernández, C., Ley, E., & Steel, M. F. J. (2001). *Benchmark* priors for Bayesian *model averaging*. *Journal of Econometrics*, 100(2), 381–427.
- Forbes, K. J., & Warnock, F. E. (2012). Capital flow waves: Surges, stops, flight, and retrenchment. *Journal of International Economics*, 88(2), 235–251.
- Fratzscher, M., Gloede, O., Menkhoff, L., Sarno, L., & Stöhr, T. (2019). When is foreign exchange intervention effective? Evidence from 33 countries. *American Economic Journal: Macroeconomics*, 11(1), 132–156.

- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (edisi ke-3). CRC Press.
- Giannone, D., Lenza, M., & Primiceri, G. E. (2015). *Prior* selection for vector autoregressions. *Review of Economics and Statistics*, 97(2), 436–451.
- Gneiting, T., & Katzfuss, M. (2014). Probabilistic forecasting. *Annual Review of Statistics and Its Application*, 1, 125–151.
- Granger, C. W. J., & Newbold, P. (1974). Spurious regressions in econometrics. *Journal of Econometrics*, 2(2), 111–120.
- Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
- Hansen, L. P., & Hodrick, R. J. (1980). Forward exchange rates as optimal predictors of future spot rates: An econometric analysis. *Journal of Political Economy*, 88(5), 829–853.
- Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (edisi ke-2). Springer.
- Hendry, D. F., Johansen, S., & Santos, C. (2008). Automatic selection of indicators in a fully saturated regression. *Computational Statistics*, 23(2), 317–335.
- Hoeting, J. A., Madigan, D., Raftery, A. E., & Volinsky, C. T. (1999). Bayesian *model averaging*: A tutorial. *Statistical Science*, 14(4), 382–417.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (edisi ke-3). OTexts.
- Hyndman, R. J., & Fan, Y. (1996). Sample quantiles in statistical packages. *The American Statistician*, 50(4), 361–365.
- Kadiyala, K. R., & Karlsson, S. (1997). Numerical methods for estimation and inference in Bayesian VAR-models. *Journal of Applied Econometrics*, 12(2), 99–132.
- Karlsson, S. (2013). Forecasting with Bayesian vector autoregression. Dalam G. Elliott & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 2B, hlm. 791–897). Elsevier.
- Kass, R. E., & Raftery, A. E. (1995). Bayes factors. *Journal of the American Statistical Association*, 90(430), 773–795.
- Kass, R. E., & Wasserman, L. (1995). A reference Bayesian test for nested hypotheses and its relationship to the Schwarz criterion. *Journal of the American Statistical Association*, 90(431), 928–934.
- Kong, A., Liu, J. S., & Wong, W. H. (1994). Sequential imputations and Bayesian missing data problems. *Journal of the American Statistical Association*, 89(425), 278–288.
- Koop, G. (2003). *Bayesian Econometrics*. Wiley.
- Koop, G., & Korobilis, D. (2010). Bayesian multivariate time series methods for empirical macroeconomics. *Foundations and Trends in Econometrics*, 3(4), 267–358.
- Künsch, H. R. (1989). The jackknife and the *bootstrap* for general stationary observations. *The Annals of Statistics*, 17(3), 1217–1241.
- Lenza, M., & Primiceri, G. E. (2022). How to estimate a vector autoregression after March 2020. *Journal of Applied Econometrics*, 37(4), 688–699.
- Ley, E., & Steel, M. F. J. (2009). On the effect of *prior* assumptions in Bayesian *model averaging* with applications to growth regression. *Journal of Applied Econometrics*, 24(4), 651–674.
- Liang, F., Paulo, R., Molina, G., Clyde, M. A., & Berger, J. O. (2008). Mixtures of g priors for Bayesian variable selection. *Journal of the American Statistical Association*, 103(481), 410–423.

- Litterman, R. B. (1986). Forecasting with Bayesian vector autoregressions: Five years of experience. *Journal of Business & Economic Statistics*, 4(1), 25–38.
- Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Lustig, H., Roussanov, N., & Verdelhan, A. (2011). Common risk factors in currency markets. *Review of Financial Studies*, 24(11), 3731–3777.
- Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer.
- Marcellino, M., Stock, J. H., & Watson, M. W. (2006). A comparison of direct and iterated multistep AR methods for forecasting macroeconomic time series. *Journal of Econometrics*, 135(1–2), 499–526.
- Meese, R. A., & Rogoff, K. (1983). Empirical exchange rate models of the seventies: Do they fit out of sample? *Journal of International Economics*, 14(1–2), 3–24.
- Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Ng, S., & Perron, P. (1995). *Unit root* tests in ARMA models with data-dependent methods for the selection of the truncation *lag*. *Journal of the American Statistical Association*, 90(429), 268–281.
- Obstfeld, M., & Rogoff, K. (1996). *Foundations of International Macroeconomics*. MIT Press.
- Pesaran, M. H., & Timmermann, A. (1992). A simple nonparametric test of predictive performance. *Journal of Business & Economic Statistics*, 10(4), 461–465.
- Phillips, P. C. B., & Perron, P. (1988). Testing for a *unit root* in time series regression. *Biometrika*, 75(2), 335–346.
- Politis, D. N., & Romano, J. P. (1992). A circular block-*resampling* procedure for stationary data. Dalam R. LePage & L. Billard (Eds.), *Exploring the Limits of Bootstrap* (hlm. 263–270). Wiley.
- Raftery, A. E., Madigan, D., & Hoeting, J. A. (1997). Bayesian *model averaging* for linear regression models. *Journal of the American Statistical Association*, 92(437), 179–191.
- Rey, H. (2013). Dilemma not trilemma: The global financial cycle and monetary policy independence. *Proceedings of the Economic Policy Symposium, Jackson Hole* (hlm. 285–333). Federal Reserve Bank of Kansas City.
- Rossi, B. (2013). Exchange rate predictability. *Journal of Economic Literature*, 51(4), 1063–1119.
- Rubin, D. B. (1988). Using the SIR algorithm to simulate *posterior* distributions. Dalam J. M. Bernardo, M. H. DeGroot, D. V. Lindley, & A. F. M. Smith (Eds.), *Bayesian Statistics 3* (hlm. 395–402). Oxford University Press.
- Said, S. E., & Dickey, D. A. (1984). Testing for unit roots in autoregressive-moving average models of unknown order. *Biometrika*, 71(3), 599–607.
- Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461–464.
- Sims, C. A. (1980). Macroeconomics and reality. *Econometrica*, 48(1), 1–48.
- Sims, C. A., & Zha, T. (1998). Bayesian methods for dynamic multivariate models. *International Economic Review*, 39(4), 949–968.
- Smith, W. B., & Hocking, R. R. (1972). Algorithm AS 53: Wishart variate generator. *Journal of the Royal Statistical Society, Series C (Applied Statistics)*, 21(3), 341–345.
- StataCorp. (2025). *Stata Statistical Software: Release 19* (termasuk manual *Bayesian Model Averaging Reference Manual*: bmaregress, bmapredict, bmastats). StataCorp LLC.

- Timmermann, A. (2006). *Forecast* combinations. Dalam G. Elliott, C. W. J. Granger, & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 1, hlm. 135–196). Elsevier.
- Verdelhan, A. (2018). The share of systematic variation in bilateral exchange rates. *Journal of Finance*, 73(1), 375–418.
- Waggoner, D. F., & Zha, T. (1999). Conditional forecasts in dynamic multivariate models. *Review of Economics and Statistics*, 81(4), 639–651.
- West, K. D. (1996). Asymptotic inference about predictive ability. *Econometrica*, 64(5), 1067–1084.
- Wright, J. H. (2008). Bayesian *model averaging* and exchange rate forecasts. *Journal of Econometrics*, 146(2), 329–341.
- Zellner, A. (1986). On assessing *prior* distributions and Bayesian regression analysis with g-*prior* distributions. Dalam P. K. Goel & A. Zellner (Eds.), *Bayesian Inference and Decision Techniques* (hlm. 233–243). North-Holland.

Peta referensi: teori atau pilihan model dan dasarnya

Teori / metode / pilihan di model	Bagian	Referensi
Random walk sebagai *benchmark*; prediktabilitas kurs lemah	3.5, 8	Meese & Rogoff (1983); Rossi (2013)
Forecast sebagai distribusi; persentil	3.1, 3.7	Gneiting & Katzfuss (2014); Hyndman & Fan (1996)
Unit root, hubungan palsu, pemilihan *lag*	3.3, 4.5	Granger & Newbold (1974); Dickey & Fuller (1979); Said & Dickey (1984); Phillips & Perron (1988); Schwarz (1978); Ng & Perron (1995); Hamilton (1994)
Out-of-sample, *overfitting*, *validation*/test, *expanding window*	3.4, 8.1	Hastie et al. (2009); West (1996)
Dasar Bayesian, *shrinkage*, simulasi	3.6, 3.7	Koop (2003); Gelman et al. (2013); Bańbura et al. (2010)
Forecast langsung vs bertahap; target tumpang tindih	3.8, 5.2, 11	Marcellino et al. (2006); Hansen & Hodrick (1980)
Kanal DXY / faktor dolar	4.2	Lustig et al. (2011); Verdelhan (2018)
Yield AS dan arus modal ke negara berkembang	4.2	Eichengreen & Gupta (2015); Forbes & Warnock (2012); Rey (2013)
Arus modal / order flow dan kurs	4.2	Evans & Lyons (2002); Forbes & Warnock (2012)
Neraca perdagangan dan kurs	4.2	Obstfeld & Rogoff (1996)
Intervensi valas dan cadangan devisa	4.2	Fratzscher et al. (2019)
Musiman Fourier (sin/cos)	2.4, 4.3	Hyndman & Athanasopoulos (2021)

Teori / metode / pilihan di model	Bagian	Referensi
Dummy outlier / Maret 2020	2.4, 4.3	Hendry et al. (2008); Lenza & Primiceri (2022)
Data vintage dan look-ahead bias	4.4, 11	Croushore & Stark (2001)
BMA, ruang model, PIP	5	Raftery et al. (1997); Hoeting et al. (1999); Ley & Steel (2009)
g-*prior*, *prior* acuan, marginal *likelihood*	5.4, 5.5	Zellner (1986); Fernández et al. (2001); Liang et al. (2008); Kass & Wasserman (1995); Kass & Raftery (1995)
BMA untuk kurs; *shrinkage* kuat	5.4	Wright (2008)
Implementasi BMA	5.7	StataCorp (2025)
VAR dan endogen/eksogen	2.3, 6.1	Sims (1980); Lütkepohl (2005)
Prior Minnesota; mean own-*lag*; pemilihan λ	6.3, 6.4	Doan et al. (1984); Litterman (1986); Bańbura et al. (2010); Carriero et al. (2015); Giannone et al. (2015); Carriero et al. (2009)
Posterior konjugat Normal-inverse-Wishart; *draw*	6.5, 6.6	Kadiyala & Karlsson (1997); Koop & Korobilis (2010); Karlsson (2013); Smith & Hocking (1972)
Representasi moving average; stabilitas (akar companion)	6.6, 6.7	Lütkepohl (2005)
Forecast bersyarat dan skenario	6.7, 7.1	Waggoner & Zha (1999); Bańbura, Giannone, & Lenza (2015)
Importance *resampling* dan ESS	6.7	Rubin (1988); Kong et al. (1994)
Diagnostik residual	6.9	Ljung & Box (1978); D'Agostino et al. (1990)
Dummy sum-of-coefficients (diuji, tidak dipakai)	2.5	Doan et al. (1984); Sims & Zha (1998)
UIP (diuji, tidak dipakai)	2.5, 6.10	Fama (1984); Engel (2014)
VIX / siklus keuangan global (diuji, tidak dipakai)	2.5	Rey (2013); Forbes & Warnock (2012)
Kombinasi *forecast*; dasar terdekat untuk penggabungan	2.5, 7.4	Bates & Granger (1969); Timmermann (2006)
Akurasi arah dan evaluasi interval	8.2	Pesaran & Timmermann (1992); Christoffersen (1998)
Uji DM, HLN, Clark-West, Newey-West	8.3	Diebold & Mariano (1995); Harvey et al. (1997); Clark & West (2007); Newey & West (1987)
Block *bootstrap*	8.3, 9.6	Künsch (1989); Politis & Romano (1992)

Tabel B.1 Peta referensi.

Pilihan rancangan tanpa referensi langsung. Beberapa bagian model adalah keputusan rancangan sendiri. Semuanya diuji dengan *validation* atau *backtest*, bukan diambil dari literatur: (1)

penggabungan "baseline BMA × rasio BVARX" (Bagian 7.4); (2) standardisasi variabel sebelum *prior* Minnesota (Bagian 6.2); (3) mean *prior* 0,7 untuk *lag trade balance*, yang dikalibrasi dari autokorelasi data (Bagian 6.4); (4) ambang 2,5 simpangan baku untuk memilih bulan *dummy*; (5) jeda rilis 2 bulan untuk data makro; (6) besaran *shock* skenario.

Lampiran C. Sumber Data

Data	Sumber
USD/IDR, DXY, yield UST 10 tahun	Bloomberg (akhir bulan)
Rata-rata bulanan USD/IDR, DXY, UST10Y (v4.2)	Bloomberg harian (IDR REGN Curncy, DXY Curncy, USGG10YR Index), dirata-rata per bulan
Ekspor dan impor barang	Badan Pusat Statistik, tabel nilai ekspor dan impor; IMF International Trade in Goods untuk impor 2013–2015
Cadangan devisa (foreign currency reserves)	IMF, International Reserves and Foreign Currency Liquidity (IRFCL), I.A.1; Bank Indonesia SDDS untuk September 2026
Net flows saham	Bloomberg / Bursa Efek Indonesia
Net flows SBN	DJPPR Kementerian Keuangan (kepemilikan nonresiden)
Net flows SRBI	Bank Indonesia
VIX	Cboe Global Markets
BI rate	Bank for International Settlements, central bank policy rates
Fed funds target range	Federal Reserve Board melalui FRED
Rating dan outlook sovereign	Bank Indonesia, Indonesia Sovereign Rating

Tabel C.1 Sumber data (rincian dan tautan di sheet `sources` pada file input).